

研究论文

DOI: 10.11949/0438-1157.20240835

基于DVAE-WAFFN-GAN的不平衡样本的工业过程性能评估方法

付文峰¹, 王振雷¹, 王昕²(¹ 华东理工大学工业控制技术全国重点实验室, 上海 200237; ² 上海交通大学电工电子实验教学中心, 上海 200240)

摘要: 在复杂工业生产过程中, 为提高产品质量和生产效率, 建立准确的工业运行状态性能等级评估模型十分重要。近年来, 深度学习技术在这个领域中取得了一些进展。然而, 实际工业生产过程中经常遇到数据样本不平衡情况, 现有的深度学习性能评估方法在有限的少数样本中挖掘有价值的特征信息能力不佳, 从而导致性能评估准确度低。为此, 设计了一种双变分自编码器权重特征自适应融合的生成对抗网络 (generative adversarial network based on weighted adaptive feature fusion network of double variational autoencoder, DVAE-WAFFN-GAN), 对较少类别样本进行增强, 提高了性能评估的准确度。该方法将VAE和GAN网络进行结合, 首先用稀少类数据去预训练卷积变分自编码器 (CNN-VAE) 和长短时记忆变分自编码器 (LSTM-VAE) 提取真实数据的时空特征信息。训练生成网络时, 随机噪声先输入到预训练的两个解码器中, 解码器输出真实样本编码后的特征向量, 再利用注意力机制设计权重自适应特征融合网络 (WAFFN) 对两个变分自编码器解码器输出的特征向量赋予不同权重进行融合, 利用融合后的特征向量代替原始GAN中的随机噪声去生成数据, 从而提高生成器生成数据的质量, 提高性能评估的准确率。最后将该方法在样本不平衡的工业数据集上进行仿真实验。

关键词: 深度学习; 生成对抗网络; 特征融合; 注意力机制; 工业过程性能评估

中图分类号: TP 274

文献标志码: A

文章编号: 0438-1157 (2025) 02-0769-18

An industrial process performance evaluation method based on unbalanced samples generated by DVAE-WAFFN-GAN

FU Wenfeng¹, WANG Zhenlei¹, WANG Xin²

(¹ State Key Laboratory of Industrial Control Technology, East China University of Science and Technology, Shanghai 200237, China; ² Center of Electrical & Electronic Technology, Shanghai Jiao Tong University, Shanghai 200240, China)

Abstract: In complex industrial production process, it is very important to establish an accurate evaluation model of industrial running state performance grade in order to improve product quality and production efficiency. In recent years, deep learning techniques have made some progress in this area. However, unbalanced data samples are often encountered in the actual industrial production process, and the existing deep learning performance evaluation methods have poor ability to mine valuable feature information in a limited number of samples, resulting in low performance evaluation accuracy. To this end, this paper designs a generative adversarial network based on weighted adaptive feature fusion network of double variational autoencoder (DVAE-WAFFN-GAN) to enhance samples of fewer categories and improve the accuracy of performance evaluation. This method combines VAE and

收稿日期: 2024-07-23 修回日期: 2024-09-06

通信作者: 王振雷(1975—), 男, 博士, 教授, wangzhen_l@ecust.edu.cn

第一作者: 付文峰(2000—), 男, 硕士研究生, ff187499@163.com

基金项目: 国家重点研发计划项目(2023YFB3307800); 国家自然科学基金重大项目(62394343); 国家自然科学基金面上项目(62273149); 中央高校基本科研业务费专项资金项目(222202417006)

引用本文: 付文峰, 王振雷, 王昕. 基于DVAE-WAFFN-GAN的不平衡样本的工业过程性能评估方法[J]. 化工学报, 2025, 76(2): 769–786

Citation: FU Wenfeng, WANG Zhenlei, WANG Xin. An industrial process performance evaluation method based on unbalanced samples generated by DVAE-WAFFN-GAN[J]. CIESC Journal, 2025, 76(2): 769–786

GAN networks. First, sparse data are used to pre-train the convolutional variational autoencoder (CNN-VAE) and the long short-term memory variational autoencoder (LSTM-VAE) to extract temporal and spatial characteristics of real data. When training the generated network, the random noise is first input into the two pre-trained decoders, and the decoder outputs the encoded feature vector of the real sample. Then, the WAFFN is designed using the attention mechanism to give different weights to the feature vectors output by the two variational autoencoder decoders for fusion. The fused feature vectors are used to replace the random noise in the original GAN to generate data, so as to improve the quality of data generated by the generator and improve the accuracy of performance evaluation. Finally, the method is simulated on the unbalanced industrial data set.

Key words: deep learning; generative adversarial networks; feature fusion; attention mechanisms; industrial performance evaluation

引 言

随着工业化的迅猛发展,对工业过程进行监测和控制变得日益重要。工业运行状态性能评估是保证工业过程高效、可靠运行的关键环节之一。通过对工业过程的运行状态进行实时监测和评估,可以及时发现潜在的异常情况,如设备故障、工艺异常等,并采取相应的措施进行处理,从而降低生产事故和损失的发生概率。因此,在保障生产流程的安全性的基础上,对真实的工业过程运行状况进行深入的辨识和评估,具有极其重要的现实意义^[1-2]。

近年来,工业过程的运行状态评估逐渐受到研究者的关注。随着算力的提升和大数据技术的发展,数据驱动建模为更加准确和可靠的性能评估提供了方法。通过使用主元分析(PCA)特征提取技术,Liu等^[3-4]构建了一个性能级的离线模型,并据此评估在线数据的特性匹配情况。然而,由于PCA是一种无监督学习模式^[5],它无法充分利用带有标记的数据指导模型训练,这使得它抵抗噪声的能力相对较低。相比之下,偏最小二乘(PLS)作为一种有监督的学习方式,可以更好地处理数据的非线性特质。为了实现这一目标,Wang等^[6]采用基于核函数的PLS模型进行了预测。然而,这种方法需要依赖于预先设定好的核函数及参数,从而导致大量的成本消耗和时间投入。此外,王浩东等^[7]提出了一种基于多数据空间非线性迭代偏最小二乘算法去分析各个稳定性能级别的情况,建立了基于高斯过程回归的离线模型,以稳态评估阈值和过渡性能系数来判定现阶段的运行状况。然而,这个方法是把不同的等级数据分开处理,操作较为繁杂。曹晨鑫等^[8]提出了结合局部加权潜结构映射和神

经网络的策略,不但改善了数据间的非线性关系而且提高了训练数据与性能等级的匹配精度。但是,所使用的神经网络结构过于简单,限制了其表达能力和对于工业数据复杂非线性和动态特征的捕捉效果。

随着卷积神经网络(CNN)、变分自编码器(VAE)、长短期记忆(LSTM)、图神经网络(GNN)及其变体的发展,深度学习已经成为最流行的建模方法之一。Wu等^[9]提出了一种基于扩展CNN的软测量方法,将数据融合和相关分析相结合,提高了聚丙烯的熔融指数的预测精度。Yue等^[10]提出了一种基于卷积的关联-相似联合算法,该算法考虑了化学过程机制,包括潜在的变量相互作用,用于不等长变量序列之间的相关性分析,从而可以检测出冗余最小且相关性最强的特征,用于变量序列的多步预测建模。为了使数据驱动的动态化学过程模型具有较强的可解释性,Yue等^[11]提出了一种光注意-卷积门循环单元(light attention-convolution-gate recurrent unit, LACG)架构,用于学习化学过程的一般动态行为、瞬态干扰和其他输入因素。对脱烷过程进行建模,结果表明LACG模型在预测精度和模型泛化方面具有显著优势。

深度学习也在性能评估领域取得了一些成果。褚菲等^[12]提出了一种基于综合经济指标驱动的稀疏降噪自编码器(comprehensive economic index driven sparse denoising autoencoder, ISDAE)的复杂工业过程运行状态评价方法,使用ISDAE模型挖掘出与综合经济指标相关的原始数据特征。然而,深度神经网络智能评估模型是建立在充分的监测数据分析基础上的,训练数据越充分,智能评估模型的评估分类准确率就越高。在工业过程状态性能评估领域,各工业设备和过程通常都是正常运

行,正常数据数量远大于其他类别的数据。模型训练过程中往往会对样本较多的类别更为关注,忽略了样本较少类别的特征,导致模型在样本较少类别上分类效果差,模型过拟合。因此,如何提取较少类别数据特征是不平衡数据性能评估方法的关键。

很多研究成果着力于解决数据不平衡情况下少数类别重要特征提取不充分的问题,这些方法大致可以分为两类:基于算法层面的方法和基于数据层面的方法^[13-15]。算法层面的方法通常不会改变训练集中数据的分布,而是使用权重来实现。其中,一种方法是修改标准分类器以有效地识别少数类的样本。此外,还有基于代价敏感学习的方法,可以针对不同类别的样本赋予不同的代价权重,从而使得分类器更加关注少数类样本。另一种算法层面的方法是集成学习,即将多个分类器组合起来以获得更好的性能。其中一种常见的集成学习方法是基于 Boosting 的方法,如 AdaBoost^[16]通过反复迭代训练集并给错误分类的实例分配更高的权重来训练多个弱分类器,然后将它们组合起来进行分类。

数据层面的方法通过各种数据抽样方法来降低数据集不平衡的程度,包括对少数类样本的过采样或对多数类样本的欠采样来让数据集变得平衡。SMOTE 算法^[17]是一种常用的过采样算法,它可以通过在数据集中少数类样本和离它们最近的少数类样本之间进行插值生成新的少数类样本来平衡数据集。近年来,生成对抗网络(generative adversarial networks, GANs)^[18]在数据增强方面发挥了至关重要的作用。GAN 通过对抗训练的方式来生成数据,已经在计算机视觉、自然语言处理、人机交互等特定领域得到了广泛的应用。

Reed 等^[19]使用 GAN 从文本描述中自动合成真实图像。Radford 等^[20]提出了深度卷积生成对抗网络(deep convolution generative adversarial network, DCGAN),可以生成高分辨率的图像。Odena 等^[21]建立了辅助分类器生成对抗网络(auxiliary classifier generative adversarial network, ACGAN),在鉴别器中加入模式分类器,实现对 MNIST 数据集的准确分类。Wang 等^[22]提出了一种结合 K -means 聚类的增强 GAN 算法,以生成高质量的样本并平衡训练集。Ma 等^[23]提出一种简单而有效的两阶段稀疏约束 GAN 算法来生成振动信号。Liu 等^[24]提出了一种改

进的基于 GAN 的数据增强方法,利用特征提取器识别故障敏感特征,扩展小类样本。虽然这些工作在域层面上实现了从潜在空间到样本空间的映射,但无法保证真实数据与生成数据的变化趋势和判别表示的一致性。因此,可能会丢失各种类别的时空结构特征,并混淆细粒度信息,从而导致生成的数据集质量低、多样性低。Mirza 等^[25]提出的条件 GAN 已经初步尝试通过使用分类标签来指导数据生成来解决上述问题,而后 Chen 等^[26]引入了 InfoGAN,通过信息论正则化来学习可解释和有意义的表示。虽然文献中改进的算法可以在一定程度上帮助稳定 GAN 训练,但它们不能保证生成数据的质量。因此,使用 GAN 网络去生成数据存在以下不足:(1)模型训练不够稳定,且容易出现梯度消失的问题;(2)容易丢失数据的时空结构特征,键特征学习能力较差,导致生成的样本质量低且缺乏多样性。VAE 在工业领域也有广泛的应用。VAE 可以对输入数据进行重构,在高斯隐空间中学习特征信息,具有较好的特征学习能力。Laubscher 等^[27]将 VAE 与多层感知器结合,构建了预测模型,为更大规模工业问题的应用奠定了基础。Guo 等^[28]提出了一种基于 VAE 的实时学习(just-in-time modeling, JIT)框架,用于预测回归,并在实际的脱硝工业过程中进行了验证。

因此,本文将 VAE 与 GAN 结合起来,设计了一种双变分自编码器权重特征自适应融合的生成对抗网络(generative adversarial network based on weighted adaptive feature fusion network of double variational autoencoder, DVAE-WAFFN-GAN)。首先用稀少数据集去预训练卷积变分自编码器(CNN-VAE)和长短时记忆变分自编码器(LSTM-VAE)提取真实数据的时空特征信息。训练生成网络时,随机噪声先输入到预训练的两个解码器中,解码器输出真实样本编码后的特征向量,再利用注意力机制设计 WAFFN 对两个变分自编码器解码器输出的特征向量进行融合,利用融合后的特征向量代替原始 GAN 中的随机噪声去生成数据,从而提高生成器生成数据的质量。变分编码器通过高斯分布来建模潜在特征向量,使得生成数据具有多样性,同时预训练的变分自编码器初始化了网络参数一定程度上还可以减少 GAN 网络对于数据的依赖及避免模式崩溃和梯度消失。最后将本文方法用于 TE 过程运行状态性能评估

和乙烯裂解炉系统性能评估,对本文算法性能进行了验证。

1 背景理论

1.1 变分自编码器

VAE 是基于变量贝叶斯推理的深度生成网络^[29-30],VAE 一般由推断网络和生成网络组成,推断网络和生成网络可分别视为编码器网络和解码器网络。与标准编码器网络的数值潜变量不同,VAE 以给定输入数据 $\mathbf{x}$ 的概率分布形式描述潜变量。在解码过程中,期望从潜变量的每个概率分布中随机抽取一个向量来准确重构输入数据。VAE 的模型结构如图 1 所示,其原理是利用神经网络对两个复杂条件概率密度函数进行建模,分别是对潜在变量 z 的后验分布 $q_\phi(z|\mathbf{x})$ 的近似推理过程和重构数据的后验分布 $p_\theta(z)p_\theta(\mathbf{x}'|z)$ 的生成过程,其中 ϕ 和 θ 分别是推断网络和生成网络的参数。

VAE 的优化目标函数可表示为:

$$L(\theta, \phi) = E_{q_\phi(z|\mathbf{x})} \{ \lg [p_\theta(\mathbf{x}|z)] \} - KL[q_\phi(z|\mathbf{x}) \| p_\theta(z)] \quad (1)$$

式中,等号右边的第一项是给定 $p_\theta(\mathbf{x}|z)$ 时,

$\lg [p_\theta(\mathbf{x}|z)]$ 的期望,表示重建损失;第二项为近似分布 $q_\phi(z|\mathbf{x})$ 与真隐分布 $p_\theta(z)$ 之间的 KL 散度。

1.2 生成对抗网络

生成对抗网络由 Goodfellow 等^[31]于 2014 年提出,是一种无监督学习的方法。GAN 由生成模型 G 和判别模型 D 组成,具体结构如图 2 所示。

使用随机数 Z 作为生成器 G 的输入,生成一个尽可能符合真实数据分布的样本 $G(Z)$ 。鉴别器 D 的输入是原始样本 X 和 $G(Z)$ 。生成器 G 的目标是尽可能欺骗鉴别器 D 。生成器和鉴别器相互竞争,同时调整参数。最终目标是使鉴别器 D 无法将输出 $G(Z)$ 与真实样本 X 区分开来。给定输入 Z 的先验分布 $p_z(Z)$,若 $p_d(X)$ 表示真实数据的分布,则鉴别器的优化目标是最大化式(2)。

$$L(D) = \text{Max} \{ E_{X \sim p_d(X)} [\lg D(X)] + E_{Z \sim p_z(Z)} [\lg (1 - D(G(Z)))] \} \quad (2)$$

生成器训练的优化目标是使式(3)最小化:

$$L(G) = \text{Min} \{ E_{Z \sim p_z(Z)} [\lg (1 - D(G(Z)))] \} \quad (3)$$

式中, $D(X)$ 表示原样本 X 被判断为真实样本的概率; $D(G(Z))$ 表示生成的样本 $G(Z)$ 被鉴别器 D 鉴别




图1 变分自编码器结构

Fig.1 Structure of VAE




图2 生成对抗网络结构

Fig.2 Structure of GAN

为真实样本的概率。

1.3 注意力机制

注意力机制(attention mechanism)是一种用于加强神经网络对输入数据中不同部分的关注程度的方法^[32]。该模型模仿了人类在处理信息时的关注分配方式,让神经网络可以自动学习和聚焦于重要特征。在这种机制中,输入数据通常被划分为查询(query)和键值对(key-value pairs)两个部分。查询用于表示当前需要进行关注的内容,而键值对则包含了待关注的信息。注意力机制的基本思想是根据查询与键之间的相似度来计算一个权重,用于衡量不同键对于查询的重要性。这个权重可以视为查询对于不同键的关注度。然后,通过将权重与相应的值进行加权求和,表示网络对于不同键的关注程度。具体见式(4)~式(6)。

$$s_j = f(\mathbf{x}_j) \quad (4)$$

$$\partial_j = \text{softmax}(s_j) = \frac{\exp(s_j)}{\sum_{j=1}^N \exp(s_j)} \quad (5)$$

$$\mathbf{c} = \sum_{j=1}^N \partial_j \mathbf{h}_j \quad (6)$$

式中, $\mathbf{x}_j$ 表示输入 $\mathbf{x}$ 的第 j 个特征向量; $f(\cdot)$ 为学习函数,即前馈神经网络; s_j 表示 $\mathbf{x}_j$ 的得分; ∂_j 表示输入 $\mathbf{x}$ 第 j 个特征向量经过注意力网络后所对应的权重系数; $\mathbf{c}$ 表示所有 $\mathbf{h}_j$ 与对应注意力权重求和的结果。

1.4 不平衡样本分类问题概述

目前对不平衡数据的研究,学术界尚未有正式的定义。通常,由于数据集中各类样本的数量差异较大,导致分类器无法识别这种差异,从而引发了分类过程的错误。如图3所示,一般将不平衡数据集中数量较多样本的类别(红色)称为正例 $N = n_{\text{majority}}$,拥有较少数量样本的类别(绿色)称为负例 $P = p_{\text{minority}}$,正样本与负样本之间数量的比例称之为不平衡比(unbalance ratio, $UR = \frac{n_{\text{majority}}}{p_{\text{minority}}} = \frac{N}{P}$),其中不平衡比的数值越大,数据的类别分布越不平衡。

2 DVAE-WAFFN-GAN-LSTM 性能评估模型构建

针对工业过程运行状态样本分布不平衡导致直接性能评估准确度低的问题,本文对稀少样本类进行数据增强,使样本分布均匀,使得模型可以充




图3 不平衡数据分布

Fig.3 Distribution of unbalanced data sets

分挖掘各类样本中有效的特征信息,提高模型性能评估的准确率。因此,本研究运用DVAE-WAFFN-GAN样本扩展模型增加稀有类别的数据,然后通过LSTM分类模型对其运行状况进行性能评估,从而建立了DVAE-WAFFN-GAN-LSTM性能评估模型。

2.1 DVAE-WAFFN-GAN样本增广模型

尽管VAE和GAN模型在数据生成方面已经取得了良好的效果,但变分自编码器并没精确地求解概率分布,而是用下界近似概率分布,因此生成的数据往往比较模糊,对复杂模型的表达能力差。在GAN网络中,生成器和判别器的优化目标是相互对抗的。生成器的目标是尽可能地欺骗判别器,而判别器的目标是尽可能地准确区分生成的数据和真实数据,因此两个网络难以同时达到最佳状态。同时由于这种对抗性,训练过程容易出现不稳定性,判别器可能会快速学习区分生成的数据和真实数据,导致梯度消失和模式崩溃。

结合两种生成模型特点,本文将VAE和GAN网络进行结合。通过让两者互相促进,可以在提高生成数据质量的同时解决模型训练的不稳定性和难以收敛的问题。在对生成网络进行训练的过程中,利用变分自编码器预训练学习到的隐变量代替随机噪声作为GAN的输入,从而增强了生成网络初始参数与实际样本之间的关联性。预训练的变分自编码器初始化网络参数,一定程度上还可以减少GAN网络对于数据的依赖,提高模型训练的稳定性。由于工业过程数据往往都具有强烈的非线性和动态特性,若采用全连接层VAE会导致解码器提取数据特征信息不完全,因此将CNN和LSTM分别与VAE网络进行结合,在编码器预训练时充分提取稀少类的时空特征,再利用

注意力机制将两个解码器的输出特征分配权重,实现对重要信息的重点关注,提高生成器生成数据质量。

因此,本文设计了一种DVAE-WAFFN-GAN网络对稀少类数据进行增强,整体框架如图4所示。首先用稀少类样本分别对CNN-VAE和LSTM-VAE进行预训练提取真实数据的时空特征信息,提升生成网络中初始参数与真实样本间的关联性,然后将随机噪声分别输入到预训练好的解码器中,解码器将随机噪声解码成具有稀少类特征信息的向量,两个向量经过WAFFN网络分配权重进行特征融合,给予特征不同的权重分配,融合后的向量输入到全连接层中进行特征变换,生成和真实样本尺寸相同的新样本。然后将生成的样本和真实样本共同输入到判别器中,判别器对输入的数据进行特征提取和降维,最后通过SoftMax函数输出真伪标签。通过对整个网络的对抗性训练,优化判别器和生成器的目标函数,使得生成器生成高质量的稀少类数据。

2.2 双变分自编码器特征提取网络

卷积神经网络在特征提取和处理方面拥有强大的能力,可以提取变量之间的空间局部关系特征。与传统的自编码器相比,卷积变分自编码器生成的数据更加真实,并且具有更多的细节信息,生成更高质量的数据。实验中具体的卷积变分自编码器如图5所示。LSTM网络在处理序列数据方面拥有强大的能力,可以捕获连续数据之间的变化趋势提取时间特征,与传统的自编码器相比LSTM-VAE可以生成连续序列数据。实验中具体的LSTM变分自编码器如图6所示。使用稀少类别数据对两个网络进行预训练,使得解码器具有重构数据的特征,利用真实样本编码后的隐变量代替原始GAN中的随机噪声,增强了网络的表征能力,提高GAN生成数据的质量。

2.3 权重自适应特征融合网络

本质上,注意力机制是一种学习方式,其目标是模拟人类的视觉或者注意力行为。它通过给予不同输入的不同权重来选择性地聚焦于重要的信息,从而提高模型在任务中的表现。本文提出的




图4 DVAE-WAFFN-GAN网络结构

Fig.4 Structure of DVAE-WAFFN-GAN




图5 实验中卷积变分自编码器网络结构

Fig.5 Convolutional variational autoencoder network structure in the experiment




图6 实验中LSTM卷积变分自编码器网络结构

Fig.6 LSTM convolutional variational autoencoder network structure in the experiment

WAFFN网络结构如图7所示。随机噪声分别输入预训练的CNN-VAE解码器和LSTM-VAE解码器生成各自的特征向量,在输入GAN网络生成器之前,利用权重自适应特征融合网络对两个变分自编码学习的特征向量从时间和空间维度对数据分配权重,实现对重要信息的重点关注,提高生成数据质量。具体融合过程如下。

(1)首先将变分自编码器的输出层特征 F_1 和 F_2 进行维度上的拼接,生成时空特征信息 f_{12} 。然后将

时空特征信息输入到激励函数中进行非线性变换得到特征 f'_{12} 。

$$f_{12} = [F_1, F_2] \quad (7)$$

$$f'_{12} = \text{ReLU}(W \cdot f_{12} + b) \quad (8)$$

式中, W 和 b 分别表示权重和偏差。

(2)对特征 f'_{12} 进行归一化指数函数操作,生成每个变分自编码器输出层特征的权重向量 w_1 、 w_2 。

$$w_1 = \frac{e^{w_1 \cdot f'_{12}}}{\sum e^{w_j \cdot f'_{12}}} \quad (9)$$

$$w_2 = \frac{e^{w_2 \cdot f'_{12}}}{\sum e^{w_j \cdot f'_{12}}} \quad (10)$$

(3)将计算出来的权重向量和变分编码器输出特征进行加权融合。

$$F_U = F'_1 + F'_2 = w_1 \otimes F_1 + w_2 \otimes F_2 \quad (11)$$

式中, F_U 为融合特征; $\otimes$ 表示张量乘法运算。

2.4 DVAE-WAFFN-GAN-LSTM模型训练过程

DVAE-WAFFN-GAN-LSTM故障诊断模型的整体框架包含CNN-VAE训练和LSTM-VAE的预训练、生成稀少样本数据和LSTM网络训练及对测试集性能评估3个部分。模型训练过程如图8所示,步骤描述如下。

(1)变分自编码训练。用稀少类的数据 X 分别




图7 WAFFN结构

Fig.7 Structure of WAFFN




图8 DVAE-WAFFN-GAN网络训练结构图

Fig.8 Structure of DVAE-WAFFN-GAN net training

去训练 CNN-VAE 和 LSTM-VAE, 提取到真实数据的特征, 训练生成网络时, 利用变分自编码器真实样本编码后的隐变量代替原始 GAN 中的随机噪声。

(2) 稀少类数据增强。将稀少类的数据 X 输入 DVAE-WAFFN-GAN 模型进行训练。由于生成器网络在步骤(1)进行了预训练, 网络学习到了真实数据的特征分布, 改进的 GAN 网络在对抗模式下生成稀少类数据实现样本增强。

(3) 样本性能评估分类。经过数据增强步骤后, 数据集由不平衡变为了平衡数据集。用增强后的数据集对 LSTM 性能评估模型中进行训练, 接着利用训练完成的模型对测试数据进行分类评估。

2.5 DVAE-WAFFN-GAN-LSTM 模型实验相关参数设置

实验分为两部分进行处理, 第一部分采用本文提出的 DVAE-WAFFN-GAN 模型对稀少类数据进行增强, 第二部分采用 LSTM 对增广后的数据进行性能评估。预训练 CNN-VAE 和 LSTM-VAE 时, Batch-size 设置为 60, 采用 Adam 优化器, 学习率设置为 0.002, 迭代了 500 次。训练 DVAE-WAFFN-GAN 时, Batch-size 设置为 60, 采用 Adam 优化器, 判

别器的学习率设置为 0.0001, 生成器的学习率设置为 0.00005, 迭代了 2000 次。LSTM 分类模型, Batch-size 设置为 60, 采用 Adam 优化器, 学习率设置 0.002, 迭代了 500 次。

所有实验模型均采用以下硬件进行测试: 操作系统 Windows 10, Python 版本 3.7, 深度学习框架 TensorFlow 2.0 (CPU 版本), 处理器 Intel(R) Core(TM) i5-7300HQ CPU @ 2.50GHz, 内存 8 GB RAM。

表 1~表 4 分别列出了 DVAE-WAFFN-GAN+LSTM 模型中的具体参数, 其中, 卷积参数括号中的数值分别表示输入通道、输出通道、卷积核尺寸、步长和 padding 的大小, x 表示输入数据的维度, y 表示分类的类别数。

表 1 CNN-VAE 模型参数

Table 1 CNN-VAE model parameter

网络名称	结构组成	主要参数
CNN-VAE	输入层	神经元个数 x
	一维卷积+BN+Relu	卷积参数(1, 16, 15, 1, 0)
	一维卷积+BN+Relu	卷积参数(16, 64, 21, 1, 0)
	FLA+全连接层+Sigmoid	神经元个数(1152, 20)
	全连接层+UNFLA	神经元个数(20, 1152)
	一维反卷积+BN+Relu	卷积参数(64, 16, 21, 1, 0)
	一维反卷积+BN+Relu	卷积参数(16, 1, 15, 1, 0)

表2 LSTM-VAE模型参数

Table 2 LSTM-VAE model parameter

网络名称	结构组成	主要参数
LSTM-VAE	输入层	神经元个数 x
	全连接层+Sigmoid	神经元个数($x, 32$)
	LSTM	LSTM参数($32, 20, 2$)
	LSTM	LSTM参数($20, 32, 2$)
	全连接层+Sigmoid	卷积参数($32, x$)

表3 GAN模型参数

Table 3 GAN model parameter

网络名称	结构组成	主要参数
生成器	全连接层+Sigmoid	神经元个数($2x, 52$)
	全连接层+Sigmoid	神经元个数($52, 20$)
	全连接层+Sigmoid	神经元个数($20, x$)
判别器	全连接层+Sigmoid	神经元个数($x, 26$)
	全连接层+Sigmoid	神经元个数($26, 12$)
	全连接层+Sigmoid	神经元个数($12, 1$)

表4 LSTM模型参数

Table 4 LSTM model parameter

网络名称	结构组成	主要参数
LSTM	输入层	神经元个数 x
	全连接层+Sigmoid	神经元个数($x, 32$)
	LSTM	LSTM参数($32, 20, 2$)
	LSTM	LSTM参数($20, 32, 2$)
	全连接层+Sigmoid	卷积参数($32, y$)

3 TE过程数据集的仿真实验

基于真实的化工反应流程,TE数据集^[33]由Eastman化学公司开发的化工模拟系统 Tennessee Eastman(TE)生成,它具备动态变化、强耦合且非线性的特点,普遍应用于检测复杂工业进程中的控制

与故障识别模型。本文用TE数据集近似实际化工工业过程运行产生的数据来验证本文方法的有效性。

3.1 实验设置说明

为了验证本文算法在TE过程数据不平衡情况下性能分级评估的有效性,将实验数据的每一类分别设置为不平衡类别。某个状态等级设置为不平衡类别是指该状态等级样本为稀少样本,样本数量少于其他类别。不平衡比是指其他状态等级的样本数量与不平衡类别的样本数量之比。在本节实验中,不平衡比分别为40:1、20:1、10:1、5:1、2:1。为了减少随机性的影响,在每种情况下重复实验20次,取其平均值作为最终的性能评估的准确率。本文还比较了LSTM(no sampling)、AdaBoost、VAE-LSTM、LSTM(SMOTE)、NGAN-LSTM、CVGAN-LSTM、LVGAN-LSTM、DVGAN-LSTM在不同不平衡比下的精度,以上方法的描述说明如表5所示。

3.2 数据说明

TE过程共有41个过程变量和11个控制变量。TE进程包含21种故障类型,如表6所示。由于TE过程中存在多种类型的故障,从文献^[34]可以看出,故障4、故障5和故障11是难以检测的,为了验证本文所提方法的有效性,因此在本次实验中选用此3种故障数据和正常数据。

假设TE过程的52个变量可以作为评判运行状态性能优劣的参考依据,对应所出现的故障作为不同的性能等级,当TE运行状态处于正常,认为其运行状态等级为最优;当出现故障4时,反应器冷却水入口温度发生阶跃变化会影响反应速率,一定程度上影响生产过程中的产品产量和质量,将故障4的运行状态划分为良好;当出现故障5时,冷凝器冷却

表5 实验对比方法说明

Table 5 Description of the experimental comparison method

实验方法	方法主要描述说明
LSTM(no sampling)	不进行任何数据增强处理,直接用基础模型对原数据集进行性能评估
VAE-LSTM	直接用VAE对稀少类进行增强,再对新数据集进行性能评估
LSTM(SMOTE)	先对数据较少的那一类用SMOTE方法进行数据增强,再对新数据集进行性能评估
NGAN-LSTM	使用GAN网络对数据较少的类进行增强,再对新数据集进行性能评估
CVGAN-LSTM	先用较少类的样本训练卷积变分自编码器,利用卷积变分自编码器真实样本编码后的隐变量代替原始GAN中的随机噪声,从而对数据进行增强,再对新数据集进行性能评估
LVGAN-LSTM	先用较少类的样本训练LSTM变分自编码器,利用LSTM变分自编码器真实样本编码后的隐变量代替原始GAN中的随机噪声,从而对数据进行增强,再对新数据集进行性能评估
DVGAN-LSTM	先用较少类的样本训练卷积变分自编码器和LSTM变分自编码器,利用两个变分自编码真实样本编码后的隐变量直接代替原始GAN中的随机噪声,再对新数据集进行性能评估

表 6 TE 过程数据描述

Table 6 TE process data description

故障编号	故障描述	类型
1	A / C 进料比值变化, B 含量不变(管道 4)	阶跃
2	B 含量变化, A / C 进料比值不变(管道 4)	阶跃
3	物料 D 的温度发生变化	阶跃
4	反应器冷却水入口温度变化	阶跃
5	冷凝器冷却水入口温度变化	阶跃
6	A 供给量损失(管道 1)	阶跃
7	C 供给管压力头损失(管道 4)	阶跃
8	A、B、C 供给量变化(管道 4)	随机
9	D 进料温度变化(管道 2)	随机
10	C 进料温度变化(管道 2)	随机
11	反应器冷却水入口温度变化	随机
12	冷凝器冷却水入口温度	随机
13	反应动力学参数	缓慢漂移
14	反应器冷却水阀	阀黏滞
15	D 进料温度变化(管道 2)	阀黏滞
16	未知	未知
17	未知	未知
18	未知	未知
19	未知	未知
20	未知	未知
21	阀门位置(管道 4)	卡阀

水入口温度发生阶跃变化, 温度突然上升可能会降低冷凝器的冷凝效率, 导致冷凝器内部的温度升高, 从而影响整个热交换过程, 影响生产过程中的产品产量和质量, 因此将故障 5 的运行状态等级划分为中等; 当出现故障 11 时, 反应器冷却水入口温度发生随机变化, 反应器温度的随机变化可能会影响不同反应通道的选择性, 改变生产过程中的产品产量和质量, 因此将故障 11 的运行状态等级划分较差。具体状态等级划分见表 7。

每类训练数据包含 400 个样本, 共使用 1600 个训练样本。根据状态等级划分表, 训练数据被分为

表 7 数据运行状态等级划分及等级标签设置

Table 7 Data running status level division and level label

setting		
故障类型	状态等级	等级标签
正常	最优	1000
故障 4	良好	0100
故障 5	中等	0010
故障 11	较差	0001

4 个性能等级: 最优 $[X_1 \in \mathbf{R}^{400 \times 52}, Y_1 = 1000]$, 良好 $[X_2 \in \mathbf{R}^{400 \times 52}, Y_2 = 0100]$, 中等 $[X_3 \in \mathbf{R}^{400 \times 52}, Y_3 = 0010]$, 较差 $[X_4 \in \mathbf{R}^{400 \times 52}, Y_4 = 0001]$ 。其中分类标签 Y_1, Y_2, Y_3, Y_4 是指如果训练数据属于性能等级 i , 则第 i 个通道为 1, 其余全为 0, 在这里测试数据集每类包含 80 个样本。

3.3 仿真结果与分析

进行了三组实验, 分别将不同状态等级设置为不平衡类别, 数据样本不平衡比为 10:1 时, 得到的各性能状态的评估准确率分别如表 8~表 10 所示。由表 8~表 10 可以看出, 当某类数据比其他数据少时, 此类的性能评估准确度会大大降低, 其他类的评估准确度也可能会受到影响。如表 8 中运行状态良好被设置成不平衡类别, 此类的评估准确度远低于运行状态为最优、中等和较差, 同时运行状态为较差的评估准确度受到数据分布不平衡的影响低于运行状态最优和中等的评估准确度。在三组实验中不对数据做任何处理的 LSTM 方法评估准确率仅为 31.67%、40.83% 和 37.50%, 而本文提出的 DVAE-WAFFN-GAN-LSTM 评估准确率可达到 60.83%、58.02% 和 56.28%。与不经过数据增强的深度神经网络的评估方法相比, 准确率提高约 22%。为了进一步验证本文所提方法在处理不平衡问题时的有效性, 本文选取了过采样算法 SMOTE、AdaBoost、VAE 等方法进行对比, DVAE-WAFFN-

表 8 TE 过程运行状态良好、不平衡比为 10:1 时评估性能等级的准确率

Table 8 Performance evaluation accuracy of TE in good working condition for unbalance ratio 10:1

运行状态	LSTM(no sampling)	AdaBoost	VAE-LSTM	LSTM (SMOTE)	NGAN-LSTM	CVGAN-LSTM	LVGAN-LSTM	DVGAN-LSTM	DVAE-WAFFN-GAN-LSTM
最优	94.92%	94.21%	93.74%	93.21%	94.50%	94.08%	94.42%	94.32%	95.58%
良好	31.67%	53.48%	52.85%	40.00%	43.67%	52.30%	54.58%	57.54%	60.83%
中等	95.25%	95.36%	95.25%	95.62%	96.25%	94.58%	95.33%	95.35%	95.41%
较差	85.40%	84.65%	83.93%	83.40%	87.05%	82.50%	85.83%	86.75%	86.17%
总准确率	77.06%	81.93%	81.44%	78.06%	80.37%	80.83%	82.54%	83.49%	84.50%

表9 TE过程运行状态中等、不平衡比为10:1时评估性能等级的准确率

运行状态	LSTM(no sampling)	AdaBoost	VAE-LSTM	LSTM (SMOTE)	NGAN-LSTM	CVGAN-LSTM	LVGAN-LSTM	DVGAN-LSTM	DVAE-WAFFN-GAN-LSTM
最优	89.12%	93.27%	92.32%	96.25%	94.12%	95.12%	93.75%	93.42%	93.75%
良好	90.00%	92.64%	94.56%	92.27%	94.67%	95.41%	94.17%	94.83%	94.58%
中等	40.83%	54.48%	52.82%	46.85%	48.33%	50.58%	52.08%	56.45%	58.02%
较差	77.50%	76.55%	76.75%	72.64%	77.83%	82.50%	78.00%	78.65%	79.58%
总准确率	74.36%	79.24%	79.11%	77.00%	78.73%	78.75%	79.50%	80.73%	81.48%

表10 TE过程运行状态较差、不平衡比为10:1时评估性能等级的准确率

运行状态	LSTM(no sampling)	AdaBoost	VAE-LSTM	LSTM (SMOTE)	NGAN-LSTM	CVGAN-LSTM	LVGAN-LSTM	DVGAN-LSTM	DVAE-WAFFN-GAN-LSTM
最优	90.16%	92.46%	91.72%	92.50%	91.26%	92.22%	91.65%	90.48%	91.75%
良好	91.15%	93.58%	93.36%	92.25%	93.25%	94.21%	93.57%	94.75%	94.32%
中等	89.23%	93.75%	92.67%	92.18%	93.65%	94.28%	95.15%	95.25%	95.75%
较差	37.50%	50.42%	50.87%	39.50%	42.36%	48.30%	51.14%	55.32%	56.28%
总准确率	77.01%	82.55%	82.15%	79.11%	80.13%	82.25%	82.92%	83.95%	84.53%




图9 TE过程运行状态良好、不平衡比为10:1时LSTM模型训练过程

Fig.9 LSTM model training process of TE in good working condition for unbalance ratio 10:1

GAN-LSTM也具有显著的优势。对所提模型进行了消融实验:CVGAN-LSTM(去除了LSTM-VAE和WAFFN结构),LVGAN-LSTM(去除了CNN-VAE和WAFFN结构),DVGAN-LSTM(去除了WAFFN结构),发现去除CNN-VAE和LSTM-VAE结构会丢失数据的时空特征信息,导致生成的数据质量下降,最终影响性能评估的准确率。采用WAFFN自适应网络让神经网络可以自动学习和聚焦于重要特征,提高了数据的生成质量。

图9是运行状态为良好、不平衡比为10:1时LSTM模型训练过程。从图中可以发现,在前期随

着迭代次数的增加,模型学习速度较快,损失函数曲线下降较快,评估准确率曲线也在稳步上升。在300次迭代之后,损失函数曲线趋于收敛,性能评估准确率还在逐渐提高,最终收敛于60%左右。进一步说明模型在测试集上的拟合效果较好,有较好的性能评估能力。图10为设置不同类别不平衡比为10:1时,本文所提算法相对于其他现有方法对TE工业过程性能评估准确率的增量。从图中可以清楚地看出,本文提出的算法在数据不平衡性能评估方面具有明显的优势。

为了验证本文方法在数据不同不平衡比情况




图 10 TE 过程三种运行状态下不平衡比 10:1 时性能评估的增量

Fig.10 Performance evaluation accuracy increment under three working conditions of TE for unbalance ratio 10:1

下的有效性,在不平衡比为 40:1、20:1、10:1、5:1、2:1 下进行了实验。不同不平衡比的情况下性能评估准确率如表 11~表 13 所示。可以看出,随着数据不平衡比减小,即其他类别数量不变稀少类样本增加,LSTM 性能评估准确度越来越高,说明 DNN 状态评估结果依赖于样本量。在样本不平衡的情况下,基于 DNN 的性能评估算法会大大降低对不平衡样本性能评估的准确度。从表 11~表 13 中也可以清楚地看到,在不同的条件下,本文提出的 DVAE-WAFFN-GAN-LSTM 性能评估方法对于提高不平

衡性能评估的准确率都有很好的效果。

此外,还分析了 DVAE-WAFFN-GAN-LSTM 在高吞吐量预测和优化方面的潜力。由于数据维度较小,网络模型结构也相对简单,参数较少,各模型的空间复杂度都较少,对实验设备要求并不高,因此主要衡量各模型的时间消耗情况。对比模型都采用 LSTM 模型做分类评估,各模型耗时主要取决于生成算法的复杂度,如表 14 所示。本文所提的算法耗时最长,主要是因为预先训练 CNN-VAE 和 LSTM-VAE 网络,同时需要训练 WAFFN 网络自适

表 11 TE 过程不同不平衡比下性能为良好的评估准确度

Table 11 The evaluation accuracy of the TE performance is good at different unbalance ratios

不平衡比	LSTM(no sampling)	AdaBoost	VAE-LSTM	LSTM (SMOTE)	NGAN-LSTM	CVGAN-LSTM	LVGAN-LSTM	DVGAN-LSTM	DVAE-WAFFN-GAN-LSTM
40:1	5.00%	24.76%	20.35%	9.34%	16.25%	22.17%	27.32%	34.28%	36.50%
20:1	15.83%	36.84%	32.21%	21.65%	30.52%	38.75%	42.02%	48.63%	50.52%
10:1	31.67%	53.48%	52.85%	40.00%	43.67%	52.30%	54.58%	57.54%	60.83%
5:1	52.92%	62.64%	59.79%	53.14%	56.33%	61.25%	66.34%	70.85%	72.50%
2:1	85.00%	89.52%	88.64%	88.25%	88.12%	89.46%	91.04%	91.56%	92.48%

表 12 TE 过程不同不平衡比下性能为中等的评估准确度

Table 12 The evaluation accuracy of the TE performance is average at different unbalance ratios

不平衡比	LSTM(no sampling)	AdaBoost	VAE-LSTM	LSTM (SMOTE)	NGAN-LSTM	CVGAN-LSTM	LVGAN-LSTM	DVGAN-LSTM	DVAE-WAFFN-GAN-LSTM
40:1	17.12%	28.74%	32.55%	20.25%	26.24%	30.63%	35.79%	35.85%	38.08%
20:1	32.51%	37.45%	36.14%	32.42%	36.05%	39.25%	43.66%	44.75%	46.52%
10:1	40.83%	53.48%	52.85%	44.85%	48.33%	50.58%	52.08%	56.45%	58.02%
5:1	50.00%	62.64%	59.79%	52.16%	57.27%	63.19%	65.72%	68.75%	71.25%
2:1	82.08%	89.52%	88.64%	83.25%	85.24%	88.50%	90.48%	90.45%	91.74%

表 13 TE 过程不同不平衡比下性能为较差的评估准确度

Table 13 The evaluation accuracy of the TE performance is bad at different unbalance ratios

不平衡比	LSTM(no sampling)	AdaBoost	VAE-LSTM	LSTM (SMOTE)	NGAN-LSTM	CVGAN-LSTM	LVGAN-LSTM	DVGAN-LSTM	DVAE-WAFFN-GAN-LSTM
40:1	3.75%	20.31%	21.54%	5.83%	15.35%	21.18%	25.22%	30.32%	34.56%
20:1	12.58%	25.45%	36.53%	15.34%	23.22%	32.23%	39.41%	45.68%	48.72%
10:1	37.50%	46.72%	48.65%	39.50%	42.36%	48.30%	51.14%	54.85%	56.28%
5:1	42.25%	50.25%	51.46%	44.93%	47.33%	58.52%	62.54%	65.24%	68.77%
2:1	70.08%	72.65%	74.84%	71.23%	75.89%	77.36%	78.31%	80.35%	82.45%

表 14 TE 仿真实验中不同算法生成稀少数据的时间复杂度

Table 14 The time complexity of generating sparse data by different algorithms in TE simulation experiment

模型	模型训练时间/s	生成样本时间/s	生成单个样本时间/ms
VAE	246	0.154	0.770
NGAN	328	0.216	1.080
CVGAN	732	0.537	2.680
LVGAN	583	0.462	2.310
DVGAN	985	0.835	4.180
DVGAN-WAFFN	1196	1.175	5.870

应编码器的输出特征,导致所需的时间增加。即便如此, DVAE-WAFFN-GAN 所需的时间复杂度仍然很小。

4 乙烯裂解炉系统性能评估应用

4.1 乙烯裂解炉性能评估描述说明

在乙烯生产过程中,裂解炉是生产装置的核心设备,裂解原料(石脑油、乙烷等)在高热度的炉管中发生裂解反应,生成乙烯、丙烯、氢气等基本化工原料^[35-37]。图 11 为乙烯裂解炉工艺结构图。裂解炉生产运行状态是否良好,影响整个乙烯生产装置的产品质量和产量,而且还将影响后续生产环节。通常情况下乙烯生产状态处于良好,但随着时间的推移,过程参数漂移、人工误操作等因素会导致进料温度等过程变量偏离最佳生产状态的值从而影响最终的产率,因此,亟需一套高效、准确的工业过程性能评估方法,以便操作人员全面掌握生产过程运行情况。通过传感器,能够获得大量的现代乙烯裂解生产过程数据,这为性能评估的方法提供了数据支持。在这个过程中,收集到了 18 个关键的过程变量和质量变量-单一高附加值产品的收益数据,具体如表 15 所示。但通常情况下,乙烯裂解装置运行




图 11 乙烯裂解炉工艺图

Fig.11 Process diagram of ethylene cracking furnace

状态良好发生状态变化的情况比较少,传感器获得的过程变量数据分布不均匀,导致模型对运行状态评估的准确性不佳。针对这种情况,结合乙烯裂解工业过程中数据具有强烈的非线性和动态特性的特点,利用本文提出的基于 DVAE-WAFFN 的生成对抗网络将 CNN 和 LSTM 分别与 VAE 网络进行结合,在编码器预训练时充分提取稀少类的时空特征,再利用注意力机制将两个解码器的输出特征分配权重,实现对重要信息的重点关注,生成高质量数据,实现对原始不平衡数据的增强,从而提高乙烯裂解炉性能评估的准确度。

4.2 实验设置说明

为了验证本文所提方法在乙烯裂解过程数据不平衡情况下评估运行状态的有效性,将乙烯裂解运行状态分为最优、一般、较差三个等级。通常情况下乙烯裂解运行状态良好,因此将一般和较差分别设置为不平衡类别,设置多组不平衡比进行实验,对比 LSTM(no sampling)、AdaBoost、VAE-LSTM、LSTM (SMOTE)、NGAN-LSTM、CVGAN-LSTM、LVGAN-LSTM、DVGAN-LSTM 方法在不同不平衡

表 15 乙烯裂解炉过程变量

Table 15 Ethylene cracking furnace process variable

No.	变量	描述	单位
1	ρ_{NAP}	裂解原料密度	$\text{kg} \cdot \text{m}^{-3}$
2	C_{NP}	正构烷烃浓度	%
3	C_{IP}	异构烷烃浓度	%
4	C_{OLE}	烯烃浓度	%
5	C_{NAP}	环烷烃浓度	%
6	C_{BTX}	芳烃浓度	%
7	F_{feed}	原料流量	$\text{t} \cdot \text{h}^{-1}$
8	F_{DS}	稀释蒸汽流量	$\text{t} \cdot \text{h}^{-1}$
9	F_{Bfuel}	底部燃料流量	$\text{m}^3 \cdot \text{h}^{-1}$
10	F_{Sfuel}	侧壁燃料流量	$\text{m}^3 \cdot \text{h}^{-1}$
11	C_{O_2}	排烟氧含量	%
12	T_{g1}	排烟温度 1	$^{\circ}\text{C}$
13	T_{g2}	排烟温度 2	$^{\circ}\text{C}$
14	F_{ss}	高压蒸汽流量	$\text{kg} \cdot \text{h}^{-1}$
15	T_{ss}	高压蒸汽温度	$^{\circ}\text{C}$
16	COT	裂解出口温度	$^{\circ}\text{C}$
17	T_{HK}	初馏点温度	$^{\circ}\text{C}$
18	T_{KK}	终馏点温度	$^{\circ}\text{C}$

比下的评估准确度。(此处所指的不平衡类别,不平衡比详细设置情况及其各种方法的详细说明与 3.2 节一致。)

根据实际生产经验,将乙烯裂解炉运行状态划

分为 3 个等级:最优 [$X_1 \in \mathbf{R}^{400 \times 18}, Y_1 = 100$], 一般 [$X_2 \in \mathbf{R}^{400 \times 18}, Y_2 = 010$], 较差 [$X_3 \in \mathbf{R}^{400 \times 18}, Y_3 = 001$], 其中分类标签 Y_1, Y_2, Y_3 是指如果训练数据属于性能等级 i , 则第 i 个通道为 1, 其余全为 0。在工业生产现场中采集了 1200 个样本数据作为训练数据集, 每类数据各 400 个, 分别对类别设置不同不平衡比进行实验。测试数据集每类包含 80 个样本。

4.3 实验结果与分析

进行了两组实验, 分别将不同状态等级设置为不平衡类别, 数据样本不平衡比为 10:1 时, 得到的各性能状态的评估准确率分别如表 16 和表 17 所示。由表 16 和表 17 可以看出, 不对数据进行任何处理的 LSTM 方法稀少类评估准确率仅为 52.47% 和 55.35%, 表明样本分布不均匀会降低分类器对于稀少类别的评估效果, 使模型更偏向于样本多的类别。如果对稀少类数据进行数据增强再进行状态评估, 可以发现不管使用哪种策略进行增强稀少类别的准确度都有明显的提升。将本文所提方法与 LSTM (SMOTE)、AdaBoost、VAE-LSTM、NGAN-LSTM、CVGAN-LSTM、LVGAN-LSTM、DVGAN-LSTM 对比可以发现, 采用 GAN 网络进行数据增强的方法比采用 SMOTE 的方法在稀少类别的评估准确度高。GAN 网络的生成数据对准确率的提高比 SMOTE 算法更好, 普通的 GAN 网络和 VAE 网络生成数据质量一般, 而采用本文提出的改进生成对抗

表 16 乙烯裂解炉运行状态中等、不平衡比为 10:1 时评估性能等级的准确率

Table 16 Performance evaluation accuracy of ethylene cracking furnace in average working condition for unbalance ratio 10:1

运行状态	LSTM(no sampling)	AdaBoost	VAE-LSTM	LSTM (SMOTE)	NGAN-LSTM	CVGAN-LSTM	LVGAN-LSTM	DVGAN-LSTM	DVAE-WAFFN-GAN-LSTM
最优	98.62%	98.35%	98.74%	98.25%	98.50%	98.78%	98.73%	98.50%	98.81%
中等	52.47%	68.42%	70.15%	60.53%	67.22%	73.50%	81.32%	82.35%	85.45%
较差	98.45%	98.12%	98.37%	98.32%	98.55%	98.43%	98.61%	98.34%	98.63%
总准确率	83.18%	88.29%	89.08%	85.70%	88.09%	90.24%	92.89%	93.06%	94.30%

表 17 乙烯裂解炉运行状态较差、不平衡比 10:1 时评估性能等级的准确率

Table 17 Performance evaluation accuracy of ethylene cracking furnace in bad working condition for unbalance ratio 10:1

运行状态	LSTM(no sampling)	AdaBoost	VAE-LSTM	LSTM (SMOTE)	NGAN-LSTM	CVGAN-LSTM	LVGAN-LSTM	DVGAN-LSTM	DVAE-WAFFN-GAN-LSTM
最优	98.35%	98.61%	98.54%	98.29%	98.42%	98.38%	98.50%	98.33%	98.72%
中等	98.23%	98.42%	98.32%	98.45%	98.36%	98.50%	98.48%	98.45%	98.54%
较差	55.35%	64.85%	68.43%	59.24%	66.57%	72.43%	80.85%	82.32%	84.52%
总准确率	83.98%	87.29%	88.43%	85.33%	87.78%	89.76%	92.61%	93.03%	93.93%

网络的 DVAE-WAFFN-GAN-LSTM 算法对稀少类进行增强后,在稀少类别上的评估准确率可达到 85.45% 和 84.52%, 高于其他 GAN 网络增强方法。实验表明如果先用卷积自编码器或者 LSTM 自编码器学习较少类的性能评估特征,再利用变分自编码器真实样本编码后的隐变量代替原始 GAN 中的随机噪声进行数据生成,可以有助于 GAN 网络生成更高质量的样本,而使用自适应注意力机制将卷积自编码器和 LSTM 自编码器学习到的特征向量融合代替原始 GAN 网络的噪声对准确率的提高效果最好。

图 12 是乙烯裂解炉运行状态为中等、不平衡比为 10:1 时 LSTM 模型训练过程。与 TE 过程数据集

的仿真实验类似,损失函数最终趋近于 0.2,测试集准确率稳步上升,最终稳定在 85%。这表明在训练过程中,没有出现模型过拟合和欠拟合情况。图 13 为设置不同类别不平衡比为 10:1 时,本文算法相对于其他方法对裂解炉乙烯裂解过程性能评估准确率的增量。从图 13 可以清楚地看出,与其他方法相比,本文提出的算法在数据不平衡性能评估方面具有明显的优势。

在不同不平衡比的情况下性能评估准确率如表 18 和表 19 所示。可以看出,在乙烯裂解工艺过程数据不平衡的情况下,本文提出的 DVAE-WAFFN-GAN-LSTM 性能评估方法相比于其他方法对运行状态性能评估的准确率提升具有最好的




图 12 乙烯裂解炉运行状态中等、不平衡比为 10:1 时 LSTM 模型训练过程

Fig.12 LSTM model training process of ethylene cracking furnace in average working condition for unbalance ratio 10:1




图 13 乙烯裂解炉两种运行状态下不平衡比 10:1 时性能评估的增量

Fig.13 Performance evaluation accuracy increment under two working conditions of ethylene cracking furnace for unbalance ratio 10:1

表 18 乙烯裂解炉不同不平衡比下性能一般的评估准确度

Table 18 The evaluation accuracy of the ethylene cracking furnace performance in average working condition at different unbalance ratios

不平衡比	LSTM(no sampling)	AdaBoost	VAE-LSTM	LSTM (SMOTE)	NGAN-LSTM	CVGAN-LSTM	LVGAN-LSTM	DVGAN-LSTM	DVAE-WAFFN-GAN-LSTM
40:1	13.25%	40.45%	43.72%	34.45%	40.62%	48.22%	55.50%	61.25%	64.38%
20:1	30.42%	52.63%	64.25%	47.55%	53.64%	60.25%	70.48%	72.42%	76.15%
10:1	52.47%	65.53%	70.32%	60.53%	67.22%	73.50%	81.32%	83.63%	85.45%
5:1	73.23%	77.32%	83.50%	76.45%	82.89%	84.85%	89.25%	90.35%	92.40%
2:1	93.00%	95.72%	97.15%	94.21%	95.27%	97.60%	98.44%	98.28%	98.85%

表 19 乙烯裂解炉不同不平衡比下性能较差的评估准确度

Table 19 The evaluation accuracy of the ethylene cracking furnace performance in bad working condition at different unbalance ratios

不平衡比	LSTM(no sampling)	AdaBoost	VAE-LSTM	LSTM (SMOTE)	NGAN-LSTM	CVGAN-LSTM	LVGAN-LSTM	DVGAN-LSTM	DVAE-WAFFN-GAN-LSTM
40:1	12.28%	40.84%	43.35%	34.75%	38.56%	45.37%	56.92%	62.53%	64.75%
20:1	28.53%	54.46%	55.48%	46.28%	50.25%	57.62%	65.84%	71.12%	74.25%
10:1	52.47%	69.42%	70.52%	60.53%	67.22%	73.50%	81.32%	83.13%	85.45%
5:1	72.50%	82.32%	84.92%	74.64%	81.73%	85.92%	88.25%	92.25%	94.40%
2:1	93.36%	96.26%	97.23%	94.25%	95.63%	97.48%	97.52%	97.04%	98.45%

效果。

此外,与TE过程数据集的仿真实验类似,对乙烯裂解炉性能评估的不同生成模型的时间复杂度进行了评估,结果如表20所示。可以看出,所有生成模型的时间复杂性都很小,在实际乙烯裂解炉性能评估中可以忽略差异。

表 20 乙烯裂解炉实验中不同算法生成稀少数据的时间复杂度

Table 20 The time complexity of generating sparse data by different algorithms in ethylene cracking furnace experiment

模型	模型训练时间/s	生成样本时间/s	生成单个样本时间/ms
VAE	224	0.132	0.660
NGAN	298	0.208	1.040
CVGAN	673	0.437	2.180
LVGAN	564	0.412	2.060
DVGAN	826	0.784	3.920
DVGAN-WAFFN	1032	1.036	5.180

5 结 论

深度学习可以有效地应用于工业过程运行状

态性能等级评估领域,但当可用的状态等级数据集不平衡时,现有方法评估效果不佳。本文设计了一种双变分自编码器权重特征自适应融合的生成对抗网络。该方法将VAE和GAN网络进行结合,首先用稀少数据集去CNN-VAE和LSTM-VAE网络提取真实数据的时空特征信息。训练生成网络时,随机噪声先输入到预训练的两个解码器中,解码器输出真实样本编码后的特征向量,再利用WAFFN对两个变分自编码器解码器输出的特征向量进行融合,利用融合后的特征向量代替原始GAN中的随机噪声去生成数据,从而提高生成器生成数据的质量。通过在TE工业数据集和乙烯裂解炉数据集上设置多组不平衡比进行实验,验证本文所提方法与其他方法相比在性能等级评估的准确度上有较大的提升,且在不平衡度较大时,该方法依旧有效,证实了本文所提方法的有效性。

参考文献

- [1] Li W Q, Zhao C H, Gao F R. Linearity evaluation and variable subset partition based hierarchical process modeling and monitoring[J]. IEEE Transactions on Industrial Electronics, 2018, 65(3): 2683-2692.
- [2] Jiang Q C, Yan S F, Yan X F, et al. Data-driven two-dimensional

- deep correlated representation learning for nonlinear batch process monitoring[J]. IEEE Transactions on Industrial Informatics, 2020, **16**(4): 2839–2848.
- [3] Liu Y, Chang Y Q, Wang F L. Online process operating performance assessment and nonoptimal cause identification for industrial processes[J]. Journal of Process Control, 2014, **24**(10): 1548–1555.
- [4] Liu Y, Wang F L, Chang Y Q. Online fuzzy assessment of operating performance and cause identification of nonoptimal grades for industrial processes[J]. Industrial & Engineering Chemistry Research, 2013, **52**(50): 18022–18030.
- [5] 刘强, 卓洁, 郎自强, 等. 数据驱动的工业过程运行监控与自优化研究展望[J]. 自动化学报, 2018, **44**(11): 1944–1956.
- Liu Q, Zhuo J, Lang Z Q, et al. Outlook on data-driven industrial process operation monitoring and self optimization research[J]. Journal of Automation, 2018, **44**(11): 1944–1956.
- [6] Wang M Y, Yan G Y, Fei Z Y. Kernel PLS based prediction model construction and simulation on theoretical cases[J]. Neurocomputing, 2015, **165**: 389–394.
- [7] 王浩东, 王昕, 王振雷, 等. 基于Ms-NIPLS-GPR的化工过程性能等级评估方法[J]. 化工学报, 2021, **72**(3): 1549–1556.
- Wang H D, Wang X, Wang Z L, et al. Grading performance assessment method of chemical process based on Ms-NIPLS-GPR[J]. CIESC Journal, 2021, **72**(3): 1549–1556.
- [8] 曹晨鑫, 杜玉鹏, 王昕, 等. 基于Ms-LWPLS的化工过程网络化性能分级评估方法[J]. 化工学报, 2019, **70**(S1): 141–149.
- Cao C X, Du Y P, Wang X, et al. Networked grading performance assessment method of chemical process based on Ms-LWPLS[J]. CIESC Journal, 2019, **70**(S1): 141–149.
- [9] Wu H, Han Y M, Jin J Y, et al. Novel deep learning based on data fusion integrating correlation analysis for soft sensor modeling[J]. Industrial & Engineering Chemistry Research, 2021, **60**(27): 10001–10010.
- [10] Li Y, Cao H T, Wang X, et al. A new correlation-similarity conjoint algorithm for developing encoder-decoder based deep learning multi-step prediction model of chemical process[J]. Chemical Engineering Science, 2024, **288**: 119748.
- [11] Li Y, Li N, Ren J Z, et al. An interpretable light attention-convolution-gate recurrent unit architecture for the highly accurate modeling of actual chemical dynamic processes[J]. Engineering, 2024, **39**: 104–116.
- [12] 褚菲, 傅逸灵, 赵旭, 等. 基于ISDAE模型的复杂工业过程运行状态评价方法及应用[J]. 自动化学报, 2021, **47**(4): 849–863.
- Chu F, Fu Y L, Zhao X, et al. Evaluation method and application of complex industrial process operation status based on ISDAE model[J]. Journal of Automation, 2021, **47**(4): 849–863.
- [13] Jiao J, Zhao M, Lin J, et al. Residual joint adaptation adversarial network for intelligent transfer fault diagnosis[J]. Mechanical Systems and Signal Processing, 2020, **145**: 106962.
- [14] Chai Z, Zhao C H, Huang B. Multisource-refined transfer network for industrial fault diagnosis under domain and category inconsistencies[J]. IEEE Transactions on Cybernetics, 2022, **52**(9): 9784–9796.
- [15] Huang Z L, Lei Z H, Wen G R, et al. A multisource dense adaptation adversarial network for fault diagnosis of machinery[J]. IEEE Transactions on Industrial Electronics, 2022, **69**(6): 6298–6307.
- [16] Freund Y, Schapire R E. A decision-theoretic generalization of on-line learning and an application to boosting[J]. Journal of Computer and System Sciences, 1997, **55**(1): 119–139.
- [17] Chawla N V, Lazarevic A, Hall L O, et al. SMOTEBoost: improving prediction of the minority class in boosting[M]//Lecture Notes in Computer Science. Berlin, Heidelberg: Springer Berlin Heidelberg, 2003: 107–119.
- [18] Goodfellow I, Pouget-Abadie J, Mirza M, et al. Generative adversarial nets[J/OL]. arXiv, 2014, <http://arxiv.org/abs/1406.2661>.
- [19] Reed S, Akata Z, Yan X C, et al. Generative adversarial text to image synthesis[C]//33rd International Conference on Machine Learning, ICML, 2016, **3**: 1681–1690.
- [20] Radford A, Metz L, Chintala S, et al. Unsupervised representation learning with deep convolutional generative adversarial networks[J/OL]. arXiv, 2015, <https://arxiv.org/abs/1511.06434v2>.
- [21] Odena A, Olah C, Shlens J. Conditional image synthesis with auxiliary classifier GANs[J/OL]. arXiv, 2016, <https://arxiv.org/abs/1610.09585v4>.
- [22] Wang R G, Zhang S H, Chen Z Y, et al. Enhanced generative adversarial network for extremely imbalanced fault diagnosis of rotating machine[J]. Measurement, 2021, **180**: 109467.
- [23] Ma L, Ding Y, Wang Z, et al. An interpretable data augmentation scheme for machine fault diagnosis based on a sparsity-constrained generative adversarial network[J]. Expert Systems with Applications, 2021, **182**: 115234.
- [24] Liu J, Zhang C, Jiang X. Imbalanced fault diagnosis of rolling bearing using improved MsR-GAN and feature enhancement-driven CapsNet[J]. Mechanical Systems and Signal Processing, 2022, **168**: 108664.
- [25] Mirza M. Conditional generative adversarial nets[J/OL]. arXiv, 2014, <http://arxiv.org/abs/1411.1784>.
- [26] X. Chen, Y. Duan, R. Houthoofd, et al. InfoGAN: interpretable representation learning by information maximizing generative adversarial nets[J/OL]. arXiv, 2016, <https://doi.org/10.48550/arXiv.1606.03657>.
- [27] Laubscher R, Rousseau P. Application of generative deep learning to predict temperature, flow and species distributions using simulation data of a methane combustor[J]. International Journal of Heat and Mass Transfer, 2020, **163**: 120417.
- [28] Guo F, Xie R M, Huang B. A deep learning just-in-time modeling approach for soft sensor based on variational autoencoder[J]. Chemometrics and Intelligent Laboratory Systems, 2020, **197**: 103922.
- [29] Qi Z F, Liu Q Q, Wang J, et al. Battle damage assessment based on an improved Kullback-Leibler divergence sparse autoencoder[J]. Frontiers of Information Technology & Electronic Engineering, 2017, **18**(12): 1991–2000.
- [30] 张永宏, 张中洋, 赵晓平, 等. 基于VAE-GAN和FLCNN的不均衡样本轴承故障诊断方法[J]. 振动与冲击, 2022, **41**(9): 199–209.
- Zhang Y H, Zhang Z Y, Zhao X P, et al. Unbalanced sample bearing fault diagnosis method based on VAE-GAN and FLCNN[J]. Vibration and Shock, 2022, **41**(9): 199–209.
- [31] Goodfellow I J, Pouget-Abadie J, Mirza M, et al. Generative adversarial networks[J/OL]. arXiv, 2014, <https://arxiv.org/abs/1406.2661v1>.

- [32] 闫琳琦, 王振雷. 基于 STA-BiLSTM-LightGBM 组合模型的多步预测软测量建模[J]. 化工学报, 2023, **74**(8): 3407-3418.
Yan L Q, Wang Z L. Multi-step predictive soft sensor modeling based on STA-BiLSTM-LightGBM combined model[J]. CIESC Journal, 2023, **74**(8): 3407-3418.
- [33] 许泽坤, 付军, 高小永, 等. 基于拉普拉斯特征映射与加权极限学习机的电动潜油离心泵故障诊断方法[J]. 控制与信息技术, 2024(2): 117-125.
Xu Z K, Fu J, Gao X Y, et al. Fault diagnosis method for electric submersible centrifugal pump based on Laplace feature mapping and weighted limit learning machine[J]. Control and Information Technology, 2024(2): 117-125.
- [34] Qiu H D, Liu Y, Subrahmanya N A, et al. Granger causality for time-series anomaly detection[C]//2012 IEEE 12th International Conference on Data Mining. IEEE, 2012: 1074-1079.
- [35] Kerezi J. Computer simulation of an industrial ethane-cracking furnace operation[C]//2013 4th International Youth Conference on Energy (IYCE). IEEE, 2013: 1-5.
- [36] 李平, 李奇安, 雷荣孝, 等. 乙烯裂解炉先进控制系统开发与应用[J]. 化工学报, 2011, **62**(8): 2216-2220.
Li P, Li Q A, Lei R X, et al. Development and application of advanced process control system for ethylene cracking heaters[J]. CIESC Journal, 2011, **62**(8): 2216-2220.
- [37] 江伟, 王昕, 王振雷. 基于 LTSA 和 MICA 与 PCA 联合指标的过程监控方法及应用[J]. 化工学报, 2015, **66**(12): 4895-4903.
Jiang W, Wang X, Wang Z L. LTSA and combined index based MICA and PCA process monitoring and application[J]. CIESC Journal, 2015, **66**(12): 4895-4903.