

学号： 211060015

学校代码： 10336

密级：

杭州电子科技大学

硕士学位论文 (学术学位)



论文题目： 基于条件生成对抗网络的
不平衡质谱分类研究

作者姓名： 王智健

指导教师： 薛凌云 教授

专业名称： 仪器科学与技术

所在学院： 自动化学院

完成时间： 2025 年 3 月

杭州电子科技大学硕士学位论文

基于条件生成对抗网络的
不平衡质谱分类研究

研 究 生：王智健
指导教师：薛凌云 教授

2025 年 3 月

Dissertation Submitted to Hangzhou Dianzi University
for the Degree of Master

Conditionally generated adversarial
networks Classification of
unbalanced mass spectrometry

Candidate : ZhiJian Wang

Supervisor : Assoc.prof. LingYun Xue

March, 2025

摘要

随着质谱检测技术的不断发展,机器学习逐步取代传统检测任务中关键的谱图比对与分析环节。由于应用场景的局限性,导致获取的质谱样本存在严重的非独立同分布(Non-IID)的问题,同时质谱技术的高门槛也导致了质谱数据的匮乏。这两者成为制约质谱分类模型性能的重要因素。对于质谱样本数据存在的 Non-IID 问题,数据增强是解决 Non-IID 问题的常用方法。对此,已有研究表明,应用生成对抗网络进行数据生成的数据增强方案,相较于主流的基于重采样的数据增强算法,对噪声的鲁棒性更佳。另一方面,在应对质谱数据稀缺的问题上,由于数据通常涉及敏感的隐私信息,特别是在医学等核心应用领域,传统集中式训练方式难以满足数据隐私保护的需求。联邦学习作为一种基于隐私保护的新型分布式学习范式,能够实现在不交换原始数据的情况下联合多方完成全局模型训练,使各个参与方从全局模型中获益。

本文利用基于 Wasserstein 距离的条件生成深度卷积对抗网络(CWDCGAN)进行数据增强任务,以增强训练数据的方式进一步提升质谱分类模型在不平衡数据集下的性能。同时设计联邦学习框架,在保护数据隐私的前提下联合多方共同训练并共享全局模型。本文主要工作如下:

(1) 根据质谱数据的分布特点,构建基于一维卷积神经网络(1D-CNN)的质谱分类模型,并在 COVID-19 质谱数据集上对比得出其在质谱分类任务中其性能优于支持向量机(SVM),随机森林(RF),BP 神经网络,空洞卷积神经网络(Dilated Convolution)。同时验证了在质谱分类任务中数据不平衡及数据量不足均会导致模型性能下降。

(2) 设计基于 CWDCGAN 的质谱数据增强方法,在 COVID-19 质谱数据集上设置数据增强实验。对比了主流的基于数据重采样的 ADASYN, Borderline-SMOTE, KMeansSMOTE 三种算法,并横向比较基于数据生成的生成对抗网络(GAN),深度卷积生成对抗网络(DCGAN),基于 Wasserstein 距离的生成对抗网络(WGAN)三种算法,实验证明在数据极端不平衡情况下 CWDCGAN 的数据增强性能最佳。

(3) 构建基于不平衡数据增强的质谱分类模型联邦学习框架,验证在不同平衡度的数据集下,全局模型相较于任何单一节点的本地模型,都有不同程度的性能提升。

关键词: 条件生成对抗网络,一维卷积神经网络,深度卷积对抗网络,联邦学习

ABSTRACT

With the continuous development of mass spectrometry detection technology, machine learning is gradually replacing the key spectral comparison and analysis steps in traditional detection tasks. Due to the limitations of application scenarios, the obtained mass spectrometry samples suffer from serious Non IID issues, and the high threshold of mass spectrometry technology also leads to a scarcity of mass spectrometry data. These two factors have become important constraints on the performance of mass spectrometry classification models. Data augmentation is a commonly used method to address the Non IID issue in mass spectrometry sample data. Previous studies have shown that data augmentation schemes using generative adversarial networks for data generation have better robustness to noise compared to mainstream resampling based data augmentation algorithms. On the other hand, in dealing with the scarcity of mass spectrometry data, traditional centralized training methods are difficult to meet the needs of data privacy protection, as data often involves sensitive privacy information, especially in core application fields such as medicine. Federated learning, as a new type of distributed learning approach based on privacy protection, can achieve joint training of global models by multiple parties without exchanging raw data, allowing each participant to benefit from the global model.

This article uses a Wasserstein distance based Conditional Generative Deep Convolutional Adversarial Network (CWDCGAN) for data augmentation tasks to further improve the performance of mass spectrometry classification models on imbalanced datasets by enhancing training data. Simultaneously design a federated learning framework to jointly train and share a global model with multiple parties while protecting data privacy. The main work of this article is as follows:

(1) Based on the distribution characteristics of mass spectrometry data, a mass spectrometry classification model based on one-dimensional convolutional neural network (1D-CNN) is constructed, and its performance in mass spectrometry classification tasks is compared on the COVID-19 mass spectrometry dataset, which shows that it outperforms support vector machine (SVM), random forest (RF), BP neural network, and dilated convolutional neural network. At the same time, it was verified that data imbalance and insufficient data volume in mass spectrometry classification tasks can lead to a decrease in model performance.

(2) Design a mass spectrometry data augmentation method based on CWDCGAN and conduct data augmentation experiments on the COVID-19 mass spectrometry dataset. We compared three mainstream algorithms based on data resampling, ADASYN, Borderline SMOTE, and KMeansSMOTE, and horizontally compared three algorithms based on data generation: Generative Adversarial Network (GAN), Deep Convolutional Generative Adversarial Network (DCGAN), and Wasserstein Distance based Generative Adversarial Network (WGAN). The experiment proved that CWDCGAN had the best data augmentation performance under extreme data imbalance.

(3) Build a federated learning framework for mass spectrometry classification models based on imbalanced data augmentation, and verify that the global model has varying degrees of performance improvement compared to any single node local model on datasets with different levels of balance.

Keywords: conditional generation adversarial networks, one-dimensional convolutional neural networks, deep convolutional adversarial networks, federated learning

目 录

1 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外现状.....	2
1.2.1 质谱分类模型的研究历程.....	2
1.2.2 数据类别不平衡相关研究.....	3
1.2.3 质谱领域数据类别不平衡研究现状.....	3
1.2.4 集中式学习及分布式学习.....	4
1.2.5 联邦学习在医学隐私敏感领域的应用	5
1.3 主要研究内容.....	5
1.4 全文结构分布.....	6
2 研究基础.....	8
2.1 引言.....	8
2.2 质谱技术基础知识.....	8
2.2.1 质谱检测技术理论依据及硬件构成.....	8
2.2.2 质谱数据预处理技术.....	9
2.3 机器学习分类模型.....	9
2.3.1 支持向量机.....	9
2.3.2 随机森林.....	10
2.3.3 多层感知机.....	10
2.4 基于采样的数据增强算法	12
2.4.1 自适应合成采样(ADASYN)	12
2.4.2 边界合成少数类过采样技术(Borderline-SMOTE).....	13
2.4.3 KMeans 聚类合成少数类过采样技术(KMeans SMOTE)	14
2.5 生成对抗网络(GAN).....	14
2.5.1 深度卷积生成对抗网络(DCGAN).....	15
2.5.2 Wasserstein 距离生成对抗网络(WGAN)	15
2.5.3 条件生成对抗网络(CGAN).....	16
2.6 联邦学习.....	16
2.7 本章小结.....	17
3 基于 1D-CNN 的质谱数据分类模型.....	19
3.1 引言.....	19
3.2 数据集介绍.....	19
3.3 基于一维卷积神经网络质谱分类模型	19
3.3.1 质谱数据预处理.....	19

3.3.2 数据特征分析及分类模型选择.....	20
3.3.3 基于 1D-CNN 的分类模型构建.....	21
3.4 实验设计.....	23
3.4.1 实验环境.....	23
3.4.2 评价标准.....	24
3.4.3 参数配置.....	24
3.4.4 模型评价.....	26
3.4.5 损失函数.....	28
3.5 实验结果分析.....	28
3.6 本章小结.....	30
4 基于 CWDCGAN 的 Non-IID 数据集增强算法.....	31
4.1 引言.....	31
4.2 原始数据分析与处理.....	31
4.3 基于 Wasserstein 距离的条件深度卷积生成对抗网络.....	32
4.4 实验设计.....	34
4.4.1 Non-IID 数据集获取.....	34
4.4.2 数据集划分及节点数据增强.....	34
4.4.3 模型配置.....	36
4.4.4 数据归一化及滤噪.....	38
4.5 实验验证.....	39
4.5.1 数据准备.....	39
4.5.2 生成数据分析及对比.....	39
4.5.3 分类结果统计及分析.....	42
4.6 本章小结.....	44
5 基于 CWDCGAN 不平衡增强算法的联邦学习架构.....	45
5.1 引言.....	45
5.2 样本数量对于模型性能的影响及分析.....	45
5.2.1 数据量不足对于模型的影响.....	45
5.2.2 联邦学习对于数据量问题的解决力.....	46
5.3 实验设计.....	46
5.3.1 中心化的信任方式.....	46
5.3.2 联邦训练框架.....	47
5.3.3 数据集分割.....	49
5.3.4 联邦模型聚合算法-FedAvg.....	50
5.4 实验验证.....	51
5.5 本章小结.....	52
6 全文总结与展望.....	53
6.1 全文总结.....	53

6.2 展望.....	54
参考文献.....	55

1 绪论

1.1 研究背景及意义

质谱技术^[1]作为一种重要的谱学方法,与光谱技术并列,广泛应用于生物学、环境科学、化学、医学等多个学科领域。质谱分析是一种测量离子质荷比(m/z)的分析方法,其基本原理是使试样中各组分在离子源中发生电离,生成不同 m/z 的带电荷的离子,经加速电场的作用,形成离子束,进入质量分析器。然后根据各个粒子的 m/z 以及对应强度进行分析或者数据库比对来得出所检验物质的成分。

谱图分析比对及匹配环节是质谱分析过程中重要的一环。由于质谱分析技术产生的数据量巨大且复杂,传统的人工处理效率低精度差,在过去都是一项劳动密集型的任务。近年来,机器学习在质谱分类领域中的应用日益受到关注。机器学习作为一种强大的数据分析工作,能够有效地处理和分析复杂的质谱数据,从而帮助实现更准确的分类。

在长期研究中,数据的质量和数量一直是制约质谱分类模型性能的两个重要因素。在日益严峻的检测任务考验下,这个问题日益凸显。2019 年爆发的 COVID-19 病毒^[2],由于感染人群基数巨大,产生了大量变异,致使前期许多针对 COVID-19 的特异性检测手段无法检出其变种病毒,学者开始大规模采用质谱技术来实现病毒的高效检测。而机器学习的辅助成了提高质谱检测效率的重要途径^[3],但机器学习需要大量高质量样本数据来参与训练从而增强分类模型性能,质谱数据的质量和数量也就决定了最终分类模型的性能。

质谱数据的质量主要影响因素之一为数据类别不平衡,导致参与训练的样本存在非独立同分布(Non-Independent and Identically Distributed, Non-IID)的问题。在机器学习分类任务中,数据不平衡对于模型性能带来的影响已经成为重要的研究议题^[4]。当前主流的机器学习模型大多通过梯度下降法^[5]来训练模型参数,基本是按照平衡数据集来设计模型结构及评估标准。同时,在设计评估标准时,默认不同类别的误分代价是相等的。而在质谱分析应用于医疗场景中,正类样本占比较少,这是在医疗方面普遍的问题。并且对于医学质谱分析来说,正类样本的误分代价往往是极高的,一个逃逸的阳性样本会带来的医疗后果是无法量化的。比如本文验证采用的 COVID-19 检测数据集,一个误判的正类样本会带来进一步的传播风险,远远大于一个负类样本的错判代价。正是这种类别不平衡的场景下,分类的模型参数更多地受到多类样本(往往是负类)的影响,而少类样本又叠加

了巨大的错判代价。这时需要对分类模型及策略进行研究来进一步提升正类的识别率。

而质谱数据的匮乏源于成本和隐私两方面的原因。首先，质谱分析技术通常需要高精密度的仪器设备和专业的操作人员，这就意味着高昂的购置和维护成本。对于许多实验室和研究机构来说，尤其是那些资源有限的机构，购买质谱仪可能是一项巨大的经济负担。因此，这些机构可能无法承担质谱分析的成本，从而限制了质谱数据的获取。在以往其他领域的机器学习应用实践中，集中式训练能有效缓解数据量不足的问题，但是隐私问题逐渐成为限制集中式训练的主要因素。如近些年 COVID-19 的检测工作中，大规模使用的人体分泌物检测方式也往往强绑定患者生理数据隐私。质谱数据的隐私问题使得各方无法采用集中式训练的方式提升数据利用率，成为了一个个数据孤岛，导致现有提高模型分类效果的研究大多只能停留在优化训练模型质量上。

综上所述，当前质谱分类技术的机器学习应用亟需探索创新性的解决方案。相较于传统的通过深化模型结构来提升性能的方法，需要转变思路，从数据的角度入手，对机器学习模型的性能进行优化和提升。这一新策略旨在以数据驱动的方式实现对模型性能的显著改善。针对数据优化问题，需要从数据的质量（主要是数据不平衡问题）和数量两方面去提升，本文将从这两个方面进行研究。

1.2 国内外现状

质谱技术在多个学科领域的应用过程中，数据分类环节大量采用机器学习来提升效率。同时，原始数据集存在的数据不平衡和数据量匮乏问题成为阻碍机器学习分类效果的两大因素。对于数据不平衡的研究，其他领域已有大量参考经验，在质谱领域的不平衡研究，也已经有一定的进展。而对于数据量不足的问题，联邦学习架构成为敏感数据领域代替集中式学习的优秀方案。关于以上研究在国内外的现状，下文将详细介绍。

1.2.1 质谱分类模型的研究历程

由于质谱分析中核心的谱图比对是一项劳动密集型任务，手工比对难度大，错误率高。质谱仪在设计早期就引入计算机来辅助比对^[6]。随着机器学习的普及，机器学习相关工具被大量应用于质谱分析的辅助，完成质谱分类工作。早期以 SVM 为代表的线性分类模型在分类工作中取得了不错的表现^[7,8]，学者们也横向对比了各类线性回归模型在质谱分类的分类效果^[9]。后来以多层感知机为基础的神经网络成为了机器学习的主流，许多质谱研究的学者也随即投入神经网络应用

于质谱分析的研究^[10, 11]。Kantz Edward 等学者进一步提出应用更高层次的深度神经网络应用于质谱^[12]，中科院^[13]也搭建了相关研究平台来探讨各类网络在质谱分析中的表现，尤其是对于癌症表达蛋白的检测，这也启发了本文对于 COVID-19 表达蛋白检测检测任务中对于深度神经网络的应用。同时，Jiali Lv^[14]等利用卷积神经网络在串联质谱中对于多个化合物的识别工作也表明了 CNN 在质谱序列分析中的潜力。山东大学物理学研究所的研究报告^[15]也表明 CNN 能够胜任质谱分类任务，故本文主要采用 CNN 的变种网络进行质谱分类研究工作。

1.2.2 数据类别不平衡相关研究

机器学习需要大量数据集去训练模型提取特征。主流的机器学习模型中的 SGD 算法要求数据分布符合 IID，而现实训练任务中能够获取的数据往往存在数据不平衡的现象。数据不平衡主要表现为类间不平衡和类内不平衡^[16]，本文研究主要针对类间不平衡这个最广泛存在的情况。类别之间的不平衡普遍存在各个机器学习的领域，如金融领域^[17]，信息安全领域^[18]，计算机视觉领域^[19]以及本文研究的生物医疗^[20]领域。

对于不平衡数据的研究有多个细分方向。技术路线主要分为采用重采样方法（如过采样、欠采样）对不平衡数据进行平衡处理和利用集成学习方法提高模型对少数类样本的识别精度这两大研究方向。蒋盛益^[21]等针对该类问题在分类模型上进行了优化改进，而 van der Putten^[22]等从原始数据的特征选择上研究不同的策略来提高学习器的表现，并认为这个方向比分类算法的选择更有潜力；而大多数研究从数据集本身出发，通过增减数据来实现数据平衡。最主要的研究方向为数据的过采样和欠采样，Nitesh V. Chawla^[23]提出的 SMOTE 算法成为了解决不平衡数据集的经典方法，该算法基于 K 近邻算法通过合成少数类的数据实现过采样，从而平衡数据集。同样是 Nitesh V. Chawla^[24]进一步将 Boosting 和 SMOTE 方法融合后提出 SMOTEBoost，获得了更佳的性能。胡小生^[25]等人尝试用 K-means 从多数类区分出聚类后找出聚类质心，再使用 SMOTE 对少数类完成过采样，也收获了不错的效果。

1.2.3 质谱领域数据类别不平衡研究现状

在质谱数据研究领域，重采样方式占据主导地位，也不乏集成学习方法路线的研究。Meng, Hao-Hua^[26]参考了两种特征选择的策略优化了 EasyEnsemble 集成学习方法，进一步强化了 EasyEnsemble 对于不平衡数据集分类性能的提升。但集成学习由于本身结构的特点，存在设计复杂、计算量大等缺陷。同时整个学

习模型由于集合了不平衡处理环节,导致整体成为一个黑盒,模型的可解释性差,无法对于各个处理环节进行单独分析。所以在大多数质谱研究中,仅对数据进行处理的重采样路线已经成为了解决不平衡问题的首要选择。与其他领域相同,Zhu, Yan^[27]采用了欠采样的方式减少多类样本来平衡数据集。而在 A.K. Tiwari^[28]的质谱分类研究中,也采用了最为广泛认可的合成少数类过采样技术(Synthetic Minority Over-sampling Technique, SMOTE)数据增强技术,通过已有的近邻样本来生成新的质谱数据,从而增加少数类的数量使得整体数据集平衡。而这些过采样技术有一个共同的缺点,即容易受到噪声干扰。不论是随机过采样还是选择利用邻近样本生成,都无法区分噪声与有效数据,在数据增强过程中对噪声进行了等比例放大,数据本身的信噪比没有得到改善。

随着神经网络研究的不断深入,生成对抗网络(Generative Adversarial Networks, GAN)被提出,最初用于图像生成与计算机视觉相关领域。Georgios Douzas^[29]提出利用 GAN 来制造近似真实数据分布的生成数据来填充少数类,以此作为数据类别不平衡问题新的通解,这为各个领域对于不平衡数据集的研究指出了一条新路径。生成网络产生的样本数据分布接近于原始数据的主要特征分布,单一离散的噪声数据对于模型的影响很小,在生成的数据中也将不会出现强度高的噪声数据,相较于过采样的增强方式,噪声抑制效果好。本文将基于 GAN 完成对质谱数据集不平衡问题的改善。

1.2.4 集中式学习及分布式学习

数据是机器学习的核心。普遍认为,参与训练的数据规模越大,最终获得的模型其鲁棒性及准确性表现越佳^[30]。传统的机器学习训练为了追求更大的数据量,往往采用集中式训练的模式。集中式训练要求参与者分享其拥有的数据,这意味着数据中包含的隐私信息也将泄露,这也导致很多机构拒绝数据共享。随着各国法律法规对于公众隐私的进一步保护,传统的集中式训练面临巨大的挑战。

分布式训练早期是为了减轻中心服务器算力压力而诞生的技术方向。随着隐私问题成为集中式训练的重大阻碍,分布式训练中衍生出了一些基于隐私保护的变种,主要分为联合学习,联邦学习和分割学习。

联合学习由 Reza Shokri^[31]等学者提出,其主要过程是有参与训练的机构依次下载全局模型,在本地利用自有数据集进行训练更新后再次上传模型,轮流训练直到模型收敛到一定程度或者完成预先制定的迭代轮次。此训练模式最大的问题是在于单向链式执行,任一节点的故障都会导致整个流程的停滞。

联邦学习^[32]最早是由 Google 提出,用于输入法的词库训练。联邦学习采用

单轮次下所有节点并行训练的模式，并部分选取参与方的模型数据进行聚合，可以在单个节点故障时舍弃该节点继续完成分布式训练。相较于联合训练，联邦学习在效率和容错上都有较为明显的提升。

分割学习^[33]则是直接将模型训练的任务进行切分，先由本地服务器训练神经网络的前面特定几层，然后将输出发送到云服务器，由云服务器进行模型的后半部分训练，训练完毕后，云服务器将反向传播回给该用户。整个流程结束后，第一个用户就会将最终完成的模型传递给下一个用户重复以上流程。这个流程中往往会选取计算量最大的几部分网络交由云端训练，这样就能有效减轻本地服务器的算力压力。

三种方式中，都遵循着共享模型参数但不共享数据的原则，都有效避免了自有数据的隐私泄露。而其中联邦学习的并行机制又决定了在训练过程中相较于其他两种学习模式，对通讯带宽和延时都更为宽容，同时也可以避免节点掉线带来的训练中断。这使得联邦学习已经在各个领域大量运用用于处理隐私问题。

1.2.5 联邦学习在医学隐私敏感领域的应用

联邦学习在保护隐私的前提下能够联合所有参与方的数据进行联合训练，已经被大规模应用于各类隐私数据训练场景。Ha Vu Tran^[34]等在无线网络中应用联邦学习，同时进一步研究资源分配的最优解。Liu Ang^[35]等在智能产品的数据模型训练研究中，也利用联邦学习保证了个人隐私数据不被泄露。

同样的在本文研究方向高度重合的医学领域，联邦学习也已经得到了大量运用。ABDULLAH L 等^[36]等在残疾人数字医疗框架构建上使用联邦学习保护了病人的个人隐私数据。同时在 X-Ray 成像领域，HASSAAN M^[37]等提出多方医院机构使用联邦学习共同训练图像分类机器学习模型，提高全体参与方对于 X-Ray 图像病变识别能力。SADMAN S^[38]等在对于肺部 X-Ray 的 COVID-19 感染等多个肺部疾病的诊断中，也应用了联邦学习作为提高模型分类性能的手段。

综合以上联邦学习在医学诊断领域的成功应用案例，本文将同样将联邦学习应用于唾液质谱中 COVID-19 相关表达蛋白的分类检测任务中。

1.3 主要研究内容

随着机器学习在质谱领域的大规模应用，质谱数据的数量和质量成为限制质谱分类模型性能的关键因素。质谱数据中类别不平衡影响了数据的质量，大多数分类模型是基于 IID 数据集进行设计，不平衡数据集会导致严重的模型性能下降。同时，质谱数据本身的匮乏也直接导致参与训练的数据不足，影响模型训练效果。

因此本文利用生成式对抗网络对不平衡数据集进行数据增强,以提高数据的分布特性,使其更契合主流分类模型。同时,构建了基于数据增强算法的联邦训练模型,在规避数据隐私风险的情况下,联合多方机构共同训练,获得一个接近集中式训练的分类效果,解决数据量不足带来的模型性能下降问题。本文主要的工作及创新点如下:

(1) 构建基于一维卷积神经网络的质谱数据分类模型,作为质谱分类研究的基准模型。基于质谱数据特点,构建不同的分类模型进行分类任务,包括 SVM, RF, 基础 BP 神经网络,空洞卷积网络。实验对比了不同类别比例和不同数量的数据下模型性能的差异,选出最适合质谱数据分类的一维卷积神经网络模型作为后续不平衡数据增强策略及模型训练框架研发中的基准分类模型。同时,根据不同数据集在同一模型下的性能趋势,验证了数据的类别比例和数据量对于模型的影响。

(2) 提出基于 Wasserstein 距离的条件深度卷积生成对抗网络(Conditional Wasserstein Deep Convolutional GAN, CWDCGAN)进行数据增强,完成对不平衡数据的增强任务。该算法基于成熟的 DCGAN 算法,在生成器输入和判别器输入中加入条件向量,使得生成的数据能被定向引导,并引 Wasserstein 距离作为损失函数改善梯度消失问题。实验对比传统的自适应合成采样(Adaptive Synthetic Sampling, ADASYN),边界合成少数类过采样技术(Borderline-SMOTE, Borderline-SMOTE),KMeans 聚类合成少数类过采样技术(KMeansSMOTE)基于采样的数据增强算法,并横向对比 GAN, Wasserstein 距离生成对抗网络(Wasserstein GAN, WGAN),深度卷积生成对抗网络(Deep Convolutional GAN, DCGAN)三种基于生成的增强算法,验证得出在相同的不平衡数据集下,基于 CWDCGAN 的数据增强算法下生成的增强平衡数据,能使模型获得最佳的性能,从而论证 CWDCGAN 有更好的数据增强效果。

(3) 设计在基于不平衡数据增强的联邦学习架构。在使用数据增强算法的基础上,采用联邦学习框架代替传统的可能会导致隐私泄露的集中式训练,使得参与方在不泄露隐私的情况下共享各方数据集对于分类模型的增益,进一步解决数据量不足导致的模型性能落后。

1.4 全文结构分布

第一章绪论,阐述了本文的研究背景即当前质谱分类在机器学习研究路线上的现状及困境并介绍了国内外相关的研究情况,引出本文的研究内容及主要工作,并说明了全文的结构分布。

第二章研究基础，主要包括了本文用到的各种技术方法。首先说明了质谱检测技术及其分类任务中用到相关知识；其次详细列举了当前机器学习中的几种分类算法；然后分析了当前数据增强研究领域几种主流的基于采样的成熟算法，同时阐述了生成对抗网络研究路线的模型架构和数据生成原理；最后引入联邦学习架构，解释了其如何实现非集中式的多方数据集联合训练。

第三到第五章为研究内容章节。第三章研究构建最佳的基础分类模型为第四章第五章服务。第四章针对数据不平衡问题提出增强算法，以改善数据不平衡对于分类性能的影响。第五章在第四章的数据增强算法的基础上，构建联邦学习框架，联合多方数据拥有者训练，取代传统的集中式训练，进一步解决数据量不足的问题。

第三章基于一维卷积神经网络的质谱分类模型，作为数据增强研究的预备工作。该章节将质谱数据进行预处理后，构建了多个主流的分类模型，在不同类别比例和不同数据量的数据集下，对比研究得出一维卷积神经网络在绝大部分工况中都拥有最佳的分类性能，以此确定之后的研究将采用一维卷积神经网络作为统一的基准分类模型。同时验证了在所有分类模型中，不同类别比例和不同数据量的数据集用于分类任务时都呈现统一的规律，即数据类别平衡程度和数据量两者均与模型性能呈现显著正相关。

第四章提出了 CWDCGAN 数据增强算法，作为数据增强的解决方案。该章介绍了 CWDCGAN 的结构组成及构建思路，并设计实验对比了传统主流的基于采样的 ADASYN, Borderline-SMOTE, KMeansSMOTE 算法，同时也横向对比 GAN, WGAN, DCGAN 三种成熟生成网络，得出 CWDCGAN 拥有最佳的数据增强性能。

第五章设计了联邦学习架构下的多方质谱联合训练方案，并加入对不平衡数据的增强算法，使得多方能在保护数据隐私的情况下，各机构能使用自有数据集共同训练全局模型并共享模型收益。

第六章全文总结与展望，总结了全文的工作和结果，并分析了研究尚不完善和仍有研究潜力的方面，为以后的研究做铺垫。

2 研究基础

2.1 引言

本章主要说明了本文需要用到相关背景知识。首先探寻质谱数据的获取、构成与处理，并阐述机器学习模型相关理论。其次解析了基于采样的数据增强算法，同时说明 GAN 的基础结构及其变种网络，为不平衡数据增强提供可行性方案。最后选择联邦学习框架作为集中式训练的替代方案，在规避隐私泄露风险的前提下联合多方共同训练模型，提升模型性能。

2.2 质谱技术基础知识

2.2.1 质谱检测技术理论依据及硬件构成

质谱技术^[39]通过制备、分离和检测气相来鉴定各类化合物。其基本原理就是利用离子源将样品分子离子化，然后通过电场和磁场将离子按质荷比（即离子的质量和电荷的比值）进行分离，并测量其质量和电荷比，从而得到离子的质荷比和相对强度。




图 2.1 质谱仪系统构成示意图

图 2.1 展示的质谱仪主要由离子源、质量分析器和检测器三个部分组成。离子源负责将样品离子化，让样品转换成离子状态。只有使得样品带电，才能利用磁场和电场来分离各质荷比不同的粒子。

通过质谱仪得到的数据，经过一系列处理，可以生成一些直观的质谱图。最

后与标准库谱图比对得出检测样品的类别甚至各物质含量比例,即可完成全过程的质谱检测。

2.2.2 质谱数据预处理技术

质谱的原始数据被称为 **Raw Data**, 在数据进行分析前需要先对数据进行预处理操作, 会经过以下几个步骤:

(1) 数据清洗: 该步骤主要是去除原始质谱数据中的噪声和杂质信号, 提高数据质量和分析结果的准确性。操作包括删除重复数据, 填充缺失数据。

(2) 数据过滤: 此步骤的目的是进一步精炼数据, 提取出对下游分析有用的信息。

(3) 特征提取: 在质谱数据分析环节, 特征提取是一个关键步骤, 这涉及到从清洗和过滤后的数据中识别出与特定生物过程或疾病状态相关的特征。在数据层面, 需要将正负类数据进行比对, 确定出两组数据间存在显著差异的特征值或者特征值区间, 推理得出最终后续分析中能利用的特征。

2.3 机器学习分类模型

2.3.1 支持向量机

支持向量机 (Support Vector Machine, SVM) ^[40] 由数学家 Vapnik 等人早在 1963 年提出。SVM 是一种面向数据的分类算法。它的核心目标是确定一个分类超平面, 以便将不同类别的数据分隔开。




图 2.2 SVM 分类特征空间

图 2.2 中展示的就是在以二维空间为例 SVM 分类的方式, X 代表了数据的不同维度, 圆形和三角形分别代表了被分类的两种物质。图中可以看出, 在这个二维空间内, 两种物质的分界明显, 分布较为集中。这时我们可以找到一条最优分界线来区分两个类别。

2.3.2 随机森林

随机森林 (Random Forest, RF) [41] 算法是一种常见的集成学习算法, 广泛应用与分类任务以及回归任务。其核心思想是通过构建多个决策树并统计它们的预测结果, 使得模型获得更佳的准确度和稳定性。随机森林算法基于两个主要原则, 集成学习和随机性。集成学习通过结合多个模型的预测结果来提高整体性能。随机性则是在构建决策树的过程中引入随机性, 从而提升模型的泛化能力。

2.3.3 多层感知机

多层感知机 (Multilayer Perceptron, MLP) 是一种简单的二分类线性分类模型, 由美国科学家 Frank Rosenblatt 于 1957 年提出。这个机器学习领域的重要基础算法, 被认为是支持向量机以及神经网络的基础。




图 2.3 神经网络层级结构

神经网络由多个层构成, 图 2.3 是一个四层神经网络, 输入层由我们训练数据的输入特征维度决定, 不用参与计算就能直接得出, 所以严格意义上不算感知层。layer1 和 layer2 在结构中都被归纳为隐藏层, 即该层的数据和参数都不直接对外开放, 对外界来说, 相当于这两层在模型中被隐藏。layer3 则是输出层, 它是模型最终对外输出的接口层, 最终模型分类结果将被量化并由该层统一输出。

$h(x)$ 往往代表着一个解析函数。将输出的数字概率转换成实际需要的结果。

(1) BP 神经网络

BP 神经网络是一种常见且广泛应用的前馈型人工神经网络模型。典型的 BP 神经网络有输入层，隐藏层和输出层三种类型的层级。每一层包含着多个神经节点，层级之间通过权重参数相互映射连接。

BP 上神经网络的训练过程主要分为前向传播和反向传播。前向传播是信号从输入到输出，反向传播则让输出层反向调整网络中的权重及偏置参数，从而减少模型输出与真实输出之间的误差。

BP 神经网络的结构使得其可以拟合任何复杂的非线性映射，只要设计足够的隐藏层及神经节点，理论上神经网络可以模拟任何函数。这使得 BP 神经网络被广泛应用与多个领域，展现出强大的学习和适应能力。

(2) CNN 及 1D-CNN

CNN 是一种加入了卷积层的前馈神经网络。卷积使得其隐藏层中的神经节点具备了局部感知能力，对于图像类信息的处理任务拥有出色的表现。

CNN 的核心特点包括以下几个方面：①局部感知；②权值共享；③多卷积核；④池化操作；⑤层次化结构。

卷积神经网络由于其优秀的特征提取能力以及相较于全连接神经网络更少的参数量，被广泛应用于图像类处理任务，包括图像分类，人脸识别，图像分割等。同时，对于一些时间，文本，谱图等序列数据，CNN 演变出了一维卷积神经网络去适配该数据类型，也表现出优秀的分类能力。

1D-CNN^[42]是卷积神经网络针对一维序列数据的特化结构，对于音频、文本等数据的处理有着较为优秀的表现。

1D-CNN 区别于传统 CNN 的地方在于输入层接收的是一维序列数据，对应输入的是一通道的数据，在通过一个卷积层后会用不同的卷积核计算得到多个通道，这样能从多个角度去感知数据特征，有效提升了模型的拟合能力。由于质谱数据由一系列与 m/z 相关的强度值，这些构成了类似于时间序列的数据结构。其中包含了丰富峰形，碎片离子等重要特征。而一维卷积能够有效地捕捉这些序列中的局部特征。

(3) Dilated Convolution

Dilated Convolution^[43]也被称为扩张卷积，是深度学习中的一种卷积算法最初是在图像分割领域的 DeepLab 模型中提出。与传统的卷积操作相比，空洞卷积决加入了名为“扩张率”的超参数，即卷积核处理数据时各值之间的间距值。加入扩张率的卷积网络中，在不增加参数数量或计算量的情况下，卷积核能够覆盖更大的感受野，从而捕获更多的上下文信。这对于想图像识别和时间序列处理

等任务都特别有用，因为这类任务通常理解数据中的全局和局部上下文。与传统的卷积相比，空洞卷积能够在不增加计算成本的情况下，有效地增大卷积操作的感受野，这使得它成为一种有效的扩展标准卷积的方法。

2.4 基于采样的数据增强算法

针对类别不平衡数据的分类任务，研究人员提出了多个不同的解决方法。按照分类中的不同阶段，可以分为特征层面，数据预处理层面，分类器层面以及评估体系层面去做出优化。数据预处理环节是针对原有数据进行二次采样，对原始不平衡的数据进行调整，使得不平衡的数据在一定程度上达到平衡状态，达到优化数据分布的目的，本文将重点在数据预处理环节进行数据平衡。

欠采样和过采样是重要的数据增强方法。欠采样的方法是通过减少多数类样本在训练中的参与比例来平衡少数类的识别能力，随机欠采样作为最简单的欠采样方法，在训练中随机抽取一部分多数类样本来实现样本数量的平衡。与欠采样方法相对，过采样则是不对多数类样本进行处理，转而对少数类样本进行扩增，从而实现数据平衡。以下三种为基于欠采样/过采样策略的代表性算法。

2.4.1 自适应合成采样 (ADASYN)

ADASYN^[47]是一种用于处理类别不平衡问题的机器学习算法。该算法核心思想是采用自适应的合成样本方法，针对样本数据集中的少数类样本进行样本扩充，达到平衡数据分布的目的。

算法1 ADASYN算法实现

```

1: procedure ADASYN( $D, N, k, \beta$ )
2:   输入: 原始数据集 $D$ ，少数类样本数量 $N$ ，近邻数 $k$ ，平衡系数 $\beta$ 
3:   输出: 平衡后的数据集 $D'$ 
4:   初始化空数据集 $D'$ 
5:   for 每个样本  $x_i$  in 少数类样本集  $D_{min}$  do
6:     使用KNN算法找到 $x_i$ 的 $k$ 个最近邻
7:      $d_i \leftarrow$  统计 $k$ 个最近邻中多数类样本的数量
8:      $r_i \leftarrow d_i / k$  # 计算比例
9:      $g_i \leftarrow \beta \times (1 - r_i) \times N$  # 计算需要生成的合成样本数
10:    for  $j \leftarrow 1$  to  $g_i$  do
11:      随机选择一个少数类近邻 $x_{zi}$ 
12:      生成合成样本 $s_{ij}$ 在 $x_i$ 和 $x_{zi}$ 之间 # 例如通过线性插值
13:      将合成样本 $s_{ij}$ 添加到数据集 $D'$ 中
14:    end for

```

```

15:   end for
16:   return  $D' \cup D_{maj}$            # 合并多数类样本和合成样本
17: end procedure

```

ADASYN 算法首先通过 KNN (k-近邻算法) 寻找每个样本的 k-近邻来完成样本的分布密度计算。其中 k 是一个预定义的参数表示与待分类样本距离最近的 k 个样。以下为 ADASYN 的实现过程。

ADASYN 算法生成的样本是基于旧样本的重复, 可能无法完全反映新样本的所有细节和特征。这也带来了以下问题: ①过拟合风险: 由于 ADASYN 是通过生成合成样本来平衡数据集, 这可能会增加模型的复杂性, 并带来过拟合的风险。特别是当原始数据集较小时, 过拟合的风险可能更高。②适用性限制: ADASYN 可能不适用于所有类型的数据集。例如, 对于高度非线性或复杂的数据分布, ADASYN 可能无法生成具有足够代表性的合成样本。

2.4.2 边界合成少数类过采样技术 (Borderline-SMOTE)

Borderline-SMOTE^[48]是一种改进的合成少数类过采样技术。标准的 SMOTE 为所有少数类实例生成合成样本, 而 Borderline-SMOTE 专注于边界上的实例, 通过靠近决策边界的少数类实例来生成新的样本。这有助于减少类间重叠, 并提高分类的准确性。以下为 Borderline-SMOTE 的算法实现流程。

算法2 Borderline-SMOTE 算法实现

```

1: procedure Borderline-SMOTE( $T, N, k, m$ )
2:   初始化一个空集合  $T'$ 
3:   初始化一个空集合  $DANGER$ 
4:   for 每个样本  $i \in T$  do           #  $T$  为少数类样本集合
5:     计算样本  $i$  的  $k$  个最近邻, 记为  $N_k(i)$    #  $k$  代表最近邻数量
6:      $m' \leftarrow$  得到  $N_k(i)$  中多数类样本的数量
7:      $m_l \leftarrow k/2$            #  $m$  表示采样倍率
8:     if  $m' == m_l$  then
9:       将样本  $i$  添加到集合  $DANGER$  中   # 计算需要生成的合成样本数
10:    end if
11:  end for
12:  while  $|T'| < N$  do           #  $N$  表示需要生成的样本数量
13:    从  $DANGER$  中随机选择一个样本  $i$ 
14:    从  $NN_k(i)$  中随机选择一个少数类样本  $j$ 
15:    生成  $diff \leftarrow$  随机数  $\in [0, 1]$ 
16:     $i' \leftarrow i + diff \times (j - i)$        # 生成新样本
17:    将新生成的样本  $i'$  添加到集合  $T'$  中
18:  end while

```

```

19:   return  $T'$ 
20: end procedure

```

Borderline-SMOTE 对于决策边界的样本进行增强同样也会带来以下问题：增加类间重叠；噪声敏感度高；较高的计算复杂度。

2.4.3 KMeans 聚类合成少数类过采样技术 (KMeansSMOTE)

KMeansSMOTE^[49]是一种结合了 KMeans 聚类和 SMOTE 过采样的技术。它基于 KMeans 分析原始样本的聚类分布，通过在安全区域进行过采样来平衡原始数据集，旨在避免产生噪声。以下为该算法的代码实现流程。

算法3 KMeansSMOTE算法实现

```

1: procedure KMeansSMOTE( $D_{min}$ ,  $N$ ,  $k$ ,  $percentage$ )
2:   对  $D_{min}$  使用 K-Means 算法进行聚类, 得到  $k$  个聚类中心及对应的聚类样本
3:   for 每个聚类  $cluster_i$  in  $k$  个聚类 do
4:      $n_i = cluster_i$  中样本的数量
5:      $n_{synthetic} = percentage * n_i$  # 计算每个聚类需要生成的合成样本数量
6:     for  $j = 1$  to  $n_{synthetic}$  do
7:       从  $cluster_i$  中随机选择一个样本  $x_j$ 
8:       从  $x_j$  的  $k$  近邻中随机选择一个近邻  $x_{nn}$ 
9:       生成一个 0 到 1 之间的随机数  $\delta$ 
10:      生成合成样本  $s_j = x_j + \delta * (x_{nn} - x_j)$ 
11:      将合成样本  $s_j$  添加到  $D_{min}$  中
12:     end for
13:   end for
14: end procedure

```

KMeansSMOTE 区别与 Borderline-SMOTE，避开对与决策边界的数据进行过采样，避免了噪声引入，相对的也带来了以下问题：①初始聚类中心的敏感性；②K 值的选取难题；③对非凸数据集的处理局限性。

2.5 生成对抗网络 (GAN)

GAN 是一种深度学习模型，由 Ian Goodfellow 等人于 2014 年首次提出。该网络采用了对抗性训练的方式，通过让 GAN 由生成器 (Generator) 和判别器 (Discriminator) 两部分神经网络相互博弈来进行学习。




图 2.4 GAN 网络架构图

图 2.4 展示了一个基础的生成式网络构架。生成器和判别器都采用神经网络的模型架构。将符合正态分布的随机噪声输入生成器，制造所需的生成样本，同时从数据集中提取真实数据构成真实样本，两者将由判别器来区分其真假。生成器会根据其制造的生成样本在判别器下与真值的损失值，去优化本身模型，从而在下一次制造生成样本时能更加接近真实样本分布。而判别器在不断优化的生成样本训练下，也将进一步强化对于真假样本区分能力。两者在模型的收敛上呈现共轭的形式。在实际训练中，生成器和判别器通常交替进行优化，直到达到一个动态平衡。

2.5.1 深度卷积生成对抗网络(DCGAN)

DCGAN 是 GAN 的一种改进模型。该方法基于 CNN 对于序列数据特征的学习能力，实现原始数据上的特征提取。在 DCGAN 中，生成器和判别器都使用了卷积层来代替传统 GAN 中的多层线性感知机，这种改进有效减少了模型的参数数量，同时提升了模型对于图像类数据的识别和生成能力。

2.5.2 Wasserstein 距离生成对抗网络（WGAN）

原始 GAN 的训练过程中，损失函数最小化是模型的优化目标，同时也带来了一些问题。在传统的损失函数中，当生成器的性能越好时，在大部分与真实数据不重叠的特征上，判别器不会给出梯度信息，导致生成器无法获取到梯度，出现梯度消失的问题。这也导致了生成器能够生成的数据越来越单调，失去多样性，导致模式崩溃。这样生成的数据参与数据增强的话，会使模型对于少数类（往往是正类）的泛化能力减弱。

为了解决这些问题，主要有使用不同的损失函数，训练过程添加噪声和同时使用多个生成器或判别器参与训练等方法。WGAN 作为一种 GAN 的变体，其主

要核心思路是通过使用 Wasserstein 距离来参与计算损失函数。在损失函数的研究中，WGAN 被验证为较为有效的方案。

2.5.3 条件生成对抗网络（CGAN）

条件生成对抗网络（Conditional Generative Adversarial Network, CGAN）是一种在模型输入中加入了条件信息的 GAN 变种网络。

CGAN 在原始 GAN 的基础上引入了额外的条件信息，以根据需求定向指导数据生成过程。如图 2.5 所示，CGAN 在生成网络的结构上的修改包含两个方面：

(1) 生成器：在 CGAN 中，生成器除了接收随机的高斯噪声作为输入外，还接收条件信息来指导生成器生成特定的样本。

(2) 判别器：判别器同样接收条件信息作为输入之一，保证生成的数据能符合条件。

条件信息的加入使得生成的数据能向预期的方向收敛，已经在多个领域被验证为效果优秀的生成网络改进方向。




图 2.5 普通 GAN 与 CGAN 对比

2.6 联邦学习

联邦学习是一种分布式机器学习技术，其核心思想在于利用分散在各个参与方的数据集，在隐私保护技术下融合多方数据信息，协同构建并训练一个全局模型。在模型训练过程中，模型的相关信息能够以明文或者密文的方式在各参与方之间交换，但交换的信息并不包括本地个体或者样本数据，本地训练数据不会离开本地。通过各方联合训练生成的联邦学习模型由各数据参与方之间共享，各方都能享受到其他参与方训练数据对于模型带来的增益。联邦学习的核心理念是

“数据不动模型动，数据可用不可见”。它强调在保护数据隐私的同时，实现数据的共享和计算。这种方式使得原始数据可以不出本地，从而实现数据隐私保护和数据共享分析的平衡。本文根据联邦学习基础框架分析得出应用于质谱分析的联邦学习框架图。




图 2.6 联邦架构信息交换图

图 2.6 此次研究的架构中，三个终端作为联邦学习的三个参与方，它们拥有本地数据以及本地训练以及分析的计算机，也可以称之为边缘算力。联邦学习将联合各节点的算力去生成一个全局模型，各参与方共享全局模型。在训练期间只需要上传每次训练的权重数据，不需要将本地数据直接共享，这样在兼顾保密和隐私的基础上也能利用到所有的数据。

联邦学习是一种具有很大潜力的分布式机器学习技术，它能够在保护数据隐私的同时实现数据的共享和计算。随着技术的不断发展，联邦学习有望在更多领域得到应用，为各个领域带来更加安全、高效的数据处理方式。

2.7 本章小结

本章首先阐明了质谱检测技术中数据的来源。待测样本通过离子源、质量分析器和检测器三部分构成的质谱仪后，获取到质谱 **Raw data**（原始数据）。后续又研究了质谱数据预处理的环节。作为数据应用于机器学习的重要前置流程，数据预处理的策略及效果会直接影响到分类效果。其次，本小节针对各种质谱研究中常用的分类模型进行了详细拆解，同时引出模型的评价标准。然后研究了 GAN

中生成器和判别器式迭代优化方式,使得生成器能够制造高度接近源数据分布的生成数据,同时梳理其重要改进变种 DCGAN, WGAN 及 CGAN,为后续其在数据不平衡问题上发挥的作用做下铺垫。最后说明了研究的核心框架联邦学习,阐述了联邦学习的基础框架构成及协调策略。

3 基于 1D-CNN 的质谱数据分类模型

3.1 引言

本章将基于质谱数据特点，构建不同的分类模型进行分类任务。实验将对不同不平衡比例和不同数量的数据下模型性能的差异，验证并总结数据 Non-IID 及数据数量对于模型性能的影响趋势。同时构建出适用于各类数据集下的最佳分类模型，作为后续不平衡数据增强算法和模型训练框架研究的基准分类模型。

3.2 数据集介绍

在本实验应用的数据集来自 kaggle 上公开的唾液测试数据集，用于 COVID-19 感染者鉴定（下文用 COVID-19 数据集指代），数据背景是当 PCR 检测资源稀缺且抗原检测试剂盒不准确时，临床医生会寻找可在一天内完成并处理数千个样本的替代 COVID-19 检测方法。最终确定采用质谱检测唾液测试数据集的方案，其原理是正常人的唾液中应该缺乏 COVID-19 病毒蛋白，一些独特的蛋白质可能是针对 COVID-19 感染而产生的，可用作识别潜在感染者的特征。因此，患者唾液中的蛋白质谱可以表明他或她感染了 COVID-19。

数据集的正负类标记来源于 PCR 检测结果，正类表示该唾液样本来源于 PCR 确诊的 COVID-19 感染者，负类则来源于非患者。数据集一共有 2405 条唾液样本质谱数据，包含正类数据 1632 条，负类数据 773 条。每条数据中包含 2715 个不同质荷比的数据，这将构成 2715 个分类特征特征。

3.3 基于一维卷积神经网络质谱分类模型

3.3.1 质谱数据预处理

本文介绍的框架下质谱数据应用于神经网络分类模型，原始的质谱数据集需要经过三个阶段的处理^[51]：

(1) Raw data 构成原始数据集 $R = \{R_1, R_2, R_3, \dots, R_N\}$, $R_x = \{m, i, r\}$ 。其中 m 代表 m/z , i 代表强度, r 表示保留时间。

(2) 选定数据集中我们需要的 m 及 i , 通过寻峰算法^[52, 53]选出目标数据范围 ROI, 构成质谱数据 $L = \{L_1, L_2, L_3, \dots, L_n\}$, $L_x = \{m, i\}$ 。

(3) 将质荷比裁剪对齐后作为输入层特征, 将强度值归一化 $i \rightarrow \tilde{i}$ 作为特征的值输入, 通过分类标签数目确定输出层节点数。

3.3.2 数据特征分析及分类模型选择

在原始的 COVID-19 数据集中, 随机抽取了两对正负类数据绘制成柱状图。




图 3.1 正负类数据集质谱对比图 1

图 3.1 中我们可以看到, 正类数据在 0-250 质荷比区间, 出现了多个相对较高的强度峰, 其他范围内强度峰的值相对较低。而其中的负类数据, 在全范围内都没有强度相当的峰值出现。如果仅凭这两张图的对比, 将正类数据进行 PCA (主成分分析) 处理后应用很多模型都能完成分类任务。




图 3.2 正负类数据集质谱对比图 2

然而当抽取另一组数据构成图 3.2 时,通过观察可以发现,有些正类数据中,0-250 区间的强度峰相对较低,而某些负类数据正如图 3.2 中的负类数据,也存在着分布相似,强度相当的强度峰。这时仅靠该范围的数据难以区分两个数据。而对于图 3.2 的正类数据来说,在 1250-1500 质荷比区间内,又存在着一个强度较高的峰,显然能让该正类数据区别于负类数据。




图 3.3 2D-PCA 分析

将随机挑选正负类数据各 100 个,将这些数据进行二维的 PCA 分析[54]得到图 3.3,可以观察到正类数据有两个明显的聚类,且正类数据与负类数据存在一定的重叠,导致在二维下无法通过 SVM 找到明显边界。

综上分析可知,该数据集中正类数据并非在相同特征范围内出现最高强度峰,也并非每个强度峰都能作为区分正负类数据的唯一参考。因此,分类模型构建中,需要将所有质荷比范围的强度数据纳入分类任务中,以区分不同表达蛋白的质谱数据。故最终确定参与分类的特征数为 2000,对应 2000 个质荷比。

3.3.3 基于 1D-CNN 的分类模型构建

正如上文提到,在质谱数据这个特征较多的应用场景下,SVM 很难用单一的线性模型来拟合值质谱数据和对应物质的复杂关系。所以我们选用了层级更多的神经网络来作为训练的模型。

1D-CNN 是 CNN 的一种特殊形式,专门用于处理一维序列数据,如音频信号、时间序列或文本数据。与传统的二维 CNN 不同,1D-CNN 在单一维度上进行卷积操作,使其特别适合处理具有时序特性的数据。本实验从以下几个角度入手,分析决定将 1D-CNN 作为质谱数据的基础分类模型:

(1) 质谱数据的结构特点:质谱数据应用于分类任务时,最广泛的策略是选

取不同 m/z 的离子信号。研究工作中广泛获取到的质谱数据也是质荷比及其强度数据。这种数据结构在构成上表现为随着质荷比以此递增的一维数据，以下即为典型的质谱数据图。




图 3.4 质谱质荷比-强度图

在图 3.4 所示的标准质谱数据中，质荷比构成一维序列进行特征提取，1D-CNN 能够有效地捕捉到质谱数据中的局部关系，这是传统的全连接神经网络所难以实现的。

(2) 对于质谱特征的提取能力：1D-CNN 中的卷积层通过滑动固定大小的窗口在输入数据上进行卷积操作从而有效地捕捉到窗口范围内的特征信息。这种方式无需手动设计和选择特征，减少了人工特征提取的工作量，大大降低了质谱数据的预处理压力。同时，由于无需对数据过多的过滤，也能保证质谱数据中的隐藏信息被最大化保留，使得分类模型具备发掘更为复杂特征表示的能力。此外，在模型结构最后的激活函数对卷积层输出结果进行非线性转换，1D-CNN 能够进一步提升模型的表征能力，从而更精准地拟合出质谱数据的独特性质。

(3) 质荷比降维和减少计算量：质谱数据通常包含大量的质荷比信息，在本实验应用的 COVID-19 数据集中，就包含了 2700 多个质荷比数据作为分类模型的特征，直接处理会面临高维度的挑战。1D-CNN 通过使用池化层可以对卷积层的输出进行降维，减少特征映射的维度和计算量。这不仅提高了模型的鲁棒性和泛化能力，还使得模型能够更高效地处理大规模的质谱数据。

基于以上考量，实验设计了包含卷积层的多层神经网络作为质谱分类的基础模型。




图 3.5 质谱分类的 1D-CNN 模型结构

首先, 质谱数据由一系列峰值数据组成, 这些峰值表示不同 m/z 的离子强度。这些数据可以看作是一个一维的信号或序列, 依次经过图 3.5 所示的神经网络结构:

(1) 输入层: 质谱数据作为一维序列输入, 每个点代表一个特定的 m/z 的离子强度。这个输入可以可视化为一条曲线, 横轴表示 m/z , 纵轴表示离子强度。

(2) 1D 卷积层: 使用一维卷积核对输入数据进行卷积操作, 以捕捉质谱数据中的局部特征。卷积核在质谱数据上滑动, 提取并学习数据的局部模式。由于质谱数据不仅在局部邻近的特征间存在关联, 而且在相距较远的两个强度峰间, 存在着一定的比例关系, 也是质谱信息的重要组成部分。所以单个卷积层用于局部特征的学习, 两层卷积层能够从全局角度去更大范围地获取相距较远的质荷比粒子间存在的关联信息。

(3) 池化层: 在卷积层之后, 可以添加一个池化层来减少数据的维度, 同时保留重要特征。这有助于减少模型的复杂性, 并加速训练过程。

(4) 全连接层: 经过卷积和池化处理后, 数据被展平并输入到一个全连接层中进一步学习和抽象质谱数据的特征。

(5) 输出层: 输出层是一个 *softmax* 分类器, 用于将质谱数据分类到不同的类别中。每个类别的概率由 *softmax* 函数计算得出。

3.4 实验设计

3.4.1 实验环境

实验环境为运行系统为 Win10, CPU 型号为 AMD Ryzen 5 3600X, GPU 型号为 NVIDIA 1050 Ti, 内存 16G。编译环境为 pycharm 2021.3.3, 使用语言 python, python 解释器版本 3.9.12, 用的框架是 pytorch1.12.0 来生成机器学习模型, 使用

的神经网络是调用 `pytorch` 库内的 `torch.nn` 函数。本章和后面两章都将使用这个环境进行实验。

3.4.2 评价标准

实验目的为验证不同分类模型在同样的质谱数据集下的分类性能以确定最适合质谱数据分类的模型。具体的性能指标采用基于混淆矩阵得出的 `ACC`。实验流程为在相同轮次训练下，取模型最终的 `ACC` 作为结果进行对比从而得出性能表现。

3.4.3 参数配置

根据实验需求，按表 3.1 所示参数来配置 1D-CNN 分类模型。

表 3.1 1D-CNN 层级配置

网络层类型	输入通道	输出通道	卷积核大小	步长	激活函数
conv1d	1	64	3	1	relu
pool1	-	-	2	2	-
conv1d	64	128	3	1	relu
pool2	-	-	2	2	-
Linear	64000	256	-	-	relu
Linear	256	2	-	-	Softmax

首先，我们通过卷积层来提取局部特征信息。在质谱数据中，当检测样本中的同位素离子，其 m/z 相差 1，在特征序列上为相邻关系；同时在样本电离过程中，产生的准分子离子（比分子量多或少 1 质量单位的离子，如： $(M+H)^+$ ， $(M-H)^+$ ），其生成过程中 H 原子得到或丢失导致的质荷比差，也正好为 1。这些就导致在某些数据峰的周围分布着相差几个质荷比的特征数据。而这些数据本身就包含着高度的关联性，需要相互结合分析。卷积层能够聚焦局部信息并提取其分布特征，有利于后续对于特征的参数拟合。

其次，池化层主要用于降低减少数据的维度和计算复杂性，这有利于提取出更高层次的特征信息。最重要的是，在质谱数据获取过程中，由于质谱仪精度等各类问题，会导致质谱数据记录的离子和其实际质荷比存在误差。这将导致一部分离子被记录成相邻质荷比的离子。而池化层对于数据的降采样，则能削弱这种随机偏移对于数据峰带来的影响，降低该误差对于模型最终效果的影响。

最后，本实验用两个全连接层完成最终的数据输出。`Liner` 层也叫神经网络的全连接层。两个全连接层我们可以看做一个基础的三层神经网络来配置参数。那么 `Linear1` 的输入由前级层级的输出决定。在本实验使用的 COVID-19 数据集

中,选取了 2000 个特征参与训练。那么经过两个池化层后,数据每次尺寸减半。而最终池化层 pool2 输出的通道数与 Conv2d 输出通道数一致,即为 128。最终可以通过公式 3.1 计算得出特征 F 。

$$F = 128 * 2000 / 2 / 2 = 64000 \quad (3.1)$$

同时, Linear2 的输出通道数由标签数决定。本次实验是一个二分类任务,可以得出 $L = 2$ 。

对于中间的节点数目 H ,我们采用平方根法则,以式 3.2 计算推荐隐藏层节点数:

$$H = \sqrt{F + L} \quad (3.2)$$

根据以上公式可以得出 $H \approx 253$,基于二进制考虑,我们最终设置 $H = 256$ 。这样,我们就确定了网络中所有的节点数目,神经网络 Linear1 输入通道数 N_{in} 等于数据的特征数 F ,输出层的通道数 N_{out} 由数据的标签数 L 决定。最终通过 H 与 L 联合计算得出 H ,构成过渡通道数 N_{hid} 。综合以上计算方式得到公式 3.3。

$$\begin{cases} N_{in} = F = 64000 \\ N_{hid} = H = 256 \\ N_{out} = L = 2 \end{cases} \quad (3.3)$$

完成分类网络的各层设计后,需要确认模型训练过程需要配置的各类算法及参数。

表 3.2 模型超参数配置表

参数名称	参数值
损失函数	CrossEntropyLoss
优化器	Optimizer = SGD
单次训练抓取样本数	Batch size = 64
学习率	Lr = 0.001
学习率调整间隔数	Step_size = 50
学习率调整因子	Gamma= 0.1
训练轮次	Epochs = 500

表 3.2 中列出了模型训练中主要的配置信息。损失函数是表征模型预测结果与真实值之间差距的量化工具。每轮训练后,模型将根据输入数据得出一个预测值,这个值往往是该输入数据属于某个类别的概率值。损失函数将该预测值与输入数据对应的真实值进行计算处理,给出损失值从而量化预测值与真实值的偏差。损失函数不仅能给出损失值作为模型性能的重要指标,还是优化器的主要前级工具。

优化器是训练过程中更新模型参数,调整模型状态的核心工具。优化器会在每轮训练中根据损失函数的梯度信息,通过不同的算法策略俩更新模型的各级参数,从而提升模型的拟合程度。在深度学习中,常用的优化器包括 SGD(随机

梯度下降), Adam (Adaptive Moment Estimation), Mini-Batch Gradient Descent (小批量梯度下降) 和 Momentum 等。本研究中选择优化器是最广泛应用的 SGD。

批处理大小决定了每次训练中数据的数量, 这个值需要根据参与训练的主机性能去调整。由于机器性能充足, 为了避免过多的批影响执行效率, 最终确定 64 作为大小。

lr (学习率) 是控制模型训练过程中每次更新参数幅度的参数。其大小会直接影响到训练的速度与精度。过小的学习率会显著降低模型的收敛速度, 这在联邦学习这种有通讯压力的应用场景中, 会带来更大资源占用和容错降低。而过大的学习率则会导致模型在最有解附近产生较大的震荡, 导致模型无法收敛, 同样会浪费更多训练轮次去完成模型训练。

在 NLP (自然语言处理) 任务中, BERT 类模型的学习率通常选择在 $1e^{-5}$ 数量级附近; 在计算机视觉 (CV) 任务中, 学习率则可能选择在 $1e^{-3}$ 数量级附近。由于质谱数据兼顾两个领域的特点, 同时想让模型最初的轮次快速收敛, 而在高轮次后减少调整幅度避免震荡。实验采用 $1e^{-3}$ 作为起始的 LR, 即 0.001。同时引入一个 `optim.lr_scheduler.StepLR` 学习率调度器, 设定了每 50 轮次后调整一次学习率, 而调整的乘数因子 `gamma`, 则取默认的 0.1。最终在多个学习率的验证对比中, 初始学习率确定为 0.001。

训练轮次表示在该次模型训练中完成了多少次模型更新, 它直接决定了训练任务中的算力开销。同时, 训练轮次不足会导致模型未收敛而达不到最佳性能; 而过多的训练轮次也会需要更多的时间和算力去完成训练。在联邦学习过程中, 由于各个节点需要上传和下载实时的梯度信息, 这也意味着训练轮次同时绑定着通讯开销的大小, 与上文中介绍的学习率呈现共轭相关, 共同决定了模型的训练效果。所以本次研究我们对比了多种训练轮次下模型的收敛情况, 最终确定训练轮次为 500 轮。

3.4.4 模型评价

在机器学习分类任务中, 一般基于混淆矩阵来建立模型评价体系, 以下为一个针对二分类任务的混淆矩阵结构。首先明确矩阵结构中四个重要参数的定义。

TP: True Positive, 表示预测结果为阳性, 且实际类别也是阳性, 即预测类别与实际类别一致, 简称真阳;

FP: False Positive, 表示预测结果为阳性, 但是实际类别为阴性, 即预测类别与实际类别不同, 简称假阳;

TN: True Negative, 表示预测结果为阴性, 且实际类别也是阴性, 即预测结果与实际类别一致, 简称真阴;

FN: False Negative, 表示预测结果为阴性, 但是实际类别为阳性, 即预测结果与实际类别不同, 简称假阴。

根据以上定义得出混淆矩阵的构成结构如图 3.6 所示。

混淆矩阵构成		
真实值 预测值	真-1	假-0
真-1	TP	FP
假-0	FN	TN

图 3.6 混淆矩阵结构图

基于以上参数, 得出以下常用的模型评价公式:

$$accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (3.4)$$

公式 3.4 代表的 accuracy (准确率) 是最为通用的模型评判指标, 其代表着所有预测准确的样本在总样本的占比。但正如前文介绍, 在不平衡样本中, 单一的准确率指标并不能很好的表示少数类样本的分类效果, 需要结合其他指标来联合分析。对于少数样本为正类样本的场景, 为了关注正类样本的分类效果, 以下两个公式效果更佳:

$$Precision = \frac{TP}{TP + FP} \quad (3.5)$$

公式 3.5 展示的 Precision (精确率) 用于判断在所有预测为正的样本中真实为正的样本占比, 可以直观的看出模型对于负类样本的错判率。在不平衡样本训练任务中, 虚高的准确率可能伴随着较低的精确率, 这将表明模型区分效果差但仍表现出虚假的准确率。

$$Recall = \frac{TP}{TP + FN} \quad (3.6)$$

公式 3.6 中的 Recall (召回率) 则关注所有正类样本被正确识别的比例, 非

常直观地展示了模型对于正类样本的判别能力。

以上两个指标都能聚焦于正类样本的分类效果，也各有其包含的特有信息，但这两个指标往往是矛盾的，故将两个指标融合就能进一步获得一个调和指标 F1 Score:

$$F1\ Score = \frac{2}{\frac{1}{Recall} + \frac{1}{Precision}} \quad (3.7)$$

如公式 3.7 代表的 F1-Score^[44]使用精确率和召回率的调和平均数作为模型评估指标，同时兼顾两个指标。在不平衡样本训练场景中，F1-Score 将作为重要的评价标准之一。

3.4.5 损失函数

二元交叉熵损失函数^[45] (Binary Cross Entropy Loss, BCELoss) 是深度学习中的一个损失函数，基于二元交叉熵来计算，它主要用于二分类问题的训练，衡量模型预测的概率分布与真实标签之间的差异。计算。在二分类任务中，模型通常会输出一个介于 0 和 1 之间的概率值，表示样本属于正类的概率。BCELoss 将这个概率值与真实的标签值（通常是二元的，即 0 或 1）进行比较，以计算损失。对于每一个样本，BCELoss 的计算公式如下：

$$BCELoss(p, y) = -y * \log(p) - (1 - y) \log(1 - p) \quad (3.8)$$

公式 3.8 为单个样本的损失值计算， y 代表真实的 0 或 1 的二元标签，在不同取值下会使得左右其中一个公式系数归零而不参与计算。 p 为模型对于该样本的标签预测概率值。

3.5 实验结果分析

将实验数据首先切分成不同数量以及不同比例来分析各个分类模型在不同数据集下的表现。

首先针对本文提出的质谱数据存在数据不足的现状，实验将探究不同数据量下各个分类模型的分类效果。在数据准备阶段将正负类的比例确定为 1:1 保证数据类别保持平衡。再从原始数据集中随机选出 100, 200, 500 三个数量的正类和负类数据，组合构成训练数据集。然后分别用随机森林，SVM 基础 BP 神经网络，Dilated Convolution 和 1D-CNN 来进行 500 轮训练，得出最终的训练结果，下图即为测试结果。

表 3.3 不同数据量对比结果

	P100N100	P200N200	P500N500
RF	0.905	0.83	0.9
SVM	0.89	0.9	0.94
BPNN	0.88	0.895	0.94
Dilated CNN	0.825	0.84	0.865
1D-CNN	0.91	0.915	0.955

从表 3.3 可以看出,不论是哪种分类模型下,随着训练数据的数量增加,最终的准确率呈现显著的上升趋势,说明训练数据量与模型准确率之间存在正相关关系。而在同数据量的各个分类模型之间,1D-CNN 获得了最佳的性能表现。BPNN 在三个数据集上的表现会比 SVM 略差,而在加入卷积的 1D-CNN 模型下,准确率在三个数据集都能略高于 SVM。同时 Dilated Convolution 并不如预期超越 1D-CNN,在性能表现上比 1D-CNN 略低。这是由于质谱数据的特征多且较为离散,普通卷积已经足以完成特征的提取,而 Dilated Convolution 则增加了参数量,反而使得模型更难收敛,从而影响了分类性能。

接着针对本文提出的数据不平衡对于模型分类效果的影响,实验将各类模型在不同的不平衡数据集下的分类效果。在不平衡研究中,业内普遍采用 IR^[55](不平衡比率)来衡量数据集的不平衡程度。其定义如下:

$$IR = \frac{\text{majority class}}{\text{minority class}} = \frac{\text{negative class}}{\text{positive class}} \quad (3.9)$$

公式 3.9 中 majority class 代表着分类数据集中的多数类,在质谱分类中,往往是负类(negative class)数据。而正类(positive class)数据往往是少数类(minority class)。

首先采用前文提到的不平衡数据集获取方法,获得正类:负类为 1:10, 1:5, 1:2 三个比例的数据集。然后用各个分类模型进行训练 500 轮次,记录最终的测试结果。

表 3.4 不同正负类比例下对比实验

	P50N500	P100N500	P250N500
RF	0.7	0.78	0.82
SVM	0.835	0.86	0.92
BPNN	0.835	0.845	0.905
Dilated CNN	0.5	0.805	0.805
1D-CNN	0.845	0.865	0.925

表 3.4 中同样可以得出两个结论：

(1) 在所有分类模型下，模型的准确率随着训练数据的不平衡比例增大而减小。原因在前文已经介绍，由于现在的分类模型都是默认训练集符合 IID，针对的是平衡数据集进行设计。当数据集不平衡时，对多数类和少数类的训练就会失衡，导致多数类的过拟合和少数类的欠拟合。这时也能考验模型训练的特征提取能力和稳定性。

(2) 在各个不平衡数据集下，1D-CNN 的分类效果最佳。在三个不平衡比例下的数据集训练中，1D-CNN 都能优于其他分类模型数据，在 1:10, 1:5, 1:2 三个正类：负类的比例下，分别比其他最好的分类结果高 1%, 0.5%, 0.5%。

3.6 本章小结

本章根据质谱数据特点，对质谱数据进行预处理后使其适配机器学习模型的训练数据格式。然后对比了 SVM, RF, 基础 BP 神经网络, 1D-CNN 以及空洞卷积网络在不同数据类别比例以及不同数据数量下的分类性能，得出数据类别不平衡会导致模型性能下降的结论。最后设置对比实验得出 1D-CNN 在 IR=10, IR=5, IR=2 三种不同数据集构成下分别比其他最好的模型分类结果高 1%, 0.5%, 0.5%，表现出优秀的分类性能。故选定 1D-CNN 作为后续实验的基准分类模型。

4 基于 CWDCGAN 的 Non-IID 数据集增强算法

4.1 引言

本章主要内容为解决质谱数据不平衡问题的研究。在分类数据不平衡的研究中,通过对抗生成网络生成少数类数据来平衡数据集也已经成为重要的研究方向。本章实验通过对比相同不平衡比例的数据集下,基于采样的 ADASYN, Borderline-SMOTE, KMeansSMOTE 三种主流算法和 GAN 与 DCGAN, WGAN 三种数据增强算法与 CWDCGAN 数据增强算法,得出各个增强算法间的性能差异。本章基于第三章的基准分类模型开展研究,研究成果也将作为第五章的前备知识。

4.2 原始数据分析与处理

正如前文介绍的质谱数据特性,在质谱数据中,同位素离子和准分子离子的存在,都会造成某个离子在其主质荷比的强度峰之外,还会随机出现一些质荷比+1 或者-1 的离子峰,甚至两者叠加影响下,质荷比差值能够到 2。将原始数据的多个数据画在同一个横坐标下得到下图。




图 4.1 原始正类数据局部峰图

从图 4.1 中可以观察到,左侧绿色方框中,强度峰十分集中,但也有其中一个强度峰质荷比相较于其他峰,向左偏移了一个单位,最终导致质荷比少 1。而

右侧的红色方框内，各个样本的质荷比较为分散，但都是围绕着主要质荷比左右相差一个单位进行分布，这对应准分子离子 $(M+H)^+$ 和 $(M-H)^+$ 的质荷比大小。

为了使生成的数据更集中于标准质荷比数据，把原始数据中的准分子离子矫正到标准离子的质荷比特征上有利于模型的收敛。将数据矫正处理后得到下图。




图 4.2 标准峰矫正对比图

如图 4.2 所示，在完成寻峰操作后，我们利用所有数据相邻三个质荷比之和求最大值，去判断峰的中心点，将其认定为标准质荷比所在的位置。然后将附近相差 1 的数据进行移动校准。对于左右都存在的准分子离子强度的情况，则将两者强度相加并矫正到标准质荷比上。由此，将质荷比对齐获得更为整齐的质谱数据，避免后续训练中生成模型对于特征的生成过于发散。

4.3 基于 Wasserstein 距离的条件深度卷积生成对抗网络

对于整体 GAN^[18]模型来说，系统会在多轮训练后达到一种博弈均衡状态，即判别器能尽可能判别出真实的质谱数据，而生成器尽可能制造接近于真实质谱数据的生成数据。最终转换成一个极小极大值问题（minimax game），其优化目标的表达式为：

$$\min_G \max_D V(D, G) = E_{r \sim P_{data}(r)} [\log D(r)] + E_{z \sim P_z(z)} [\log(1 - D(G(z)))] \quad (4.1)$$

公式 4.1 中使用 D 代表判别器（Discriminator），G 代表生成器（Generator），我们 $V(D, G)$ 表示生成器和判别器的价值函数。

第一项 $E_{r \sim P_{data}(r)} [\log D(r)]$ 表示从真实数据分布 $P_{data}(r)$ 中采样得到的质谱数

据 r 被判别器正确分类为真实质谱数据的期望。

第二项 $E_{z \sim P_z(z)}[\log(1 - D(G(z)))]$ 表示从某个先验噪声分布 $P_z(z)$ 中采样的噪声 z 经过生成器 G 生成的质谱假数据 $G(z)$ 被判别器识别为假质谱数据的期望。

这个优化目标意味着判别器 D 试图最大化价值函数，即正确区分真实数据和生成数据，而生成器 G 试图最小化由判别器计算的价值函数，即生成尽可能逼真的数据来欺骗判别器。在实际训练中，生成器和判别器通常交替进行优化，直到达到一个动态平衡。




图 4.3 CWDCGAN 模型结构

CWDCGAN 在基础 GAN 架构上引入三重优化机制（如图 4.3 所示）：①判别器与生成器采用一维卷积神经网络适配序列数据特性；②以 Wasserstein 距离替代二元交叉熵损失函数；③在生成器输入中嵌入条件向量实现定向生成。

首先，判别器和生成器中的神经网络加入了 1D-CNN 来适配质谱这种序列数据，使得模型能够更好地识别质谱数据中相邻质荷比间的关联性，从而更加准确地识别出强度峰。这两个网络的架构设计与上文的质谱分类模型保持一致。

其次，传统二元交叉熵损失函数在生成任务中，如果真实分布与预测分布无重叠时，可能会出现梯度消失的问题。基于 Wasserstein 距离的损失函数能够有效避免分布无重叠导致的梯度消失问题，并具有更强的噪声鲁棒性，WGAN^[19]就是基于这个改进策略设计的。其中 Wasserstein 距离^[20]计算公式如下。

$$W(P_r, P_g) = \inf_{\gamma \in \Pi(P_r, P_g)} E_{(x, y) \sim \gamma}[\|x - y\|] \quad (4.2)$$

公式 4.2 中 P_r 和 P_g 分别代表着真实数据的分布和对抗生成网络中生成器生

成的数据分布。 $\Pi(P_r, P_g)$ 是包含所有可能的联合分布集合，而 P_r 和 P_g 是这些联合分布的边际分布。 γ 是联合分布中的一个具体元素，表示从 P_r 到 P_g 的一个传输计划。 $E_{(x,y)} \sim \gamma[\|x - y\|]$ 表示在联合分布 γ 下，样本对 (x, y) （其中 x 来自 P_r ， y 来自 P_g ）之间距离的期望值。计算过程中，通常使用欧几里得 $\|x - y\|$ 作为距离度量的标准。

最后，传统 GAN 中生成器的输入只有单一的高斯噪声，高斯噪声本身分布与真实数据相差较大，使得生成过程难度较大，生成器需要更多轮次才能优化到最佳状态。CGAN^[21] 中提出加入条件信息可以使得生成的数据向预期的方向收敛。基于采样的算法本身就能快速制造接近真实数据的生成数据，将该生成数据作为条件信息去进行生成任务，能更加快速精准地制造高质量的生成数据。

4.4 实验设计

实验中的程序的运行环境和硬件配置都与第三章的实验环境一致。

4.4.1 Non-IID 数据集获取

实验需要验证各类算法在不平衡数据中的表现。首先需要获得一个不平衡数据。目前不平衡分类研究中的 Non-IID 实验数据集大多是从独立同分布的数据集划分而来。针对数据的划分策略，G. Cohen^[56] 等人在 EMNIST 数据集的 Non-IID 划分中参考字母书写者来划分数据，而本文的 COVID-19 数据集中每条数据来源于不同的患者，除此之外没有关于患者间的其他关联信息可以作为参考来划分样本；同时 Mikhail Yurochkin^[57] 等人用参数控制的连续 Dirichlet 分布来生成 Non-IID 数据，这适用于多标签的分类任务，而本研究的数据集仅为二分类任务，正负类样本间的数据为唯一比例。最后，本实验参考 Brendan McMahan^[58] 等在 MNIST 数据集下的研究，对数据进行分块操作来产生 Non-IID 数据集。

4.4.2 数据集划分及节点数据增强

本实验需要通过初始的非平衡数据集去获得一个平衡的数据集。首先需要明确原始数据集中的少数类，在本实验中为正类。然后对比正负类数据的比例来确定需要增强的数据数量。首先通过原始的数据集进行切分获得各个节点的基本数据集，该数据集中的正负类数据比例根据表中的系数决定。以下是按照 $IR=5$ 时数据分割的示意图。




图 4.4 数据集分割示意图

图 4.4 中展示了数据集的划分方式。首先按照 IR 比例从 COVID-19 总数据集中随机获取正类和负类数据。再根据六折交叉验证的思路，将数据集六等分并编号，依次选取各个编号的子数据集作为测试集，其余五份子数据集合并作为训练集参与训练。按照以上流程六次循环后，取六次实验结果的平均值作为最终结果。




图 4.5 不平衡数据增强示意图

图 4.5 中展示了数据增强处理的流程。在一个 IR=5 的数据集中，正类数据 100 条，负类数据 500 条。基于其中 100 条的少数类（正类）数据，利用各个算法的去生成 400 条正类数据，将其与原始的数据集拼接，就能获得一个 IR=1 的平衡数据集。

其中基于重采样的数据生成方式已在第二章给出实现算法。而基于 GAN 进行生成的算法同样利用筛选出的所有少数类数据（正类）作为真实数据样本，完成新数据生成的流程分为以下几步：

- (1) 生成符合正态分布的高斯噪声输入生成器，输出生成数据。

(2) 将真实数据（标签为 1）和生成数据（标签为 0）经过判别器得出预测值，利用损失函数计算预测值与真实值之间的损失值，利用该损失值计算梯度对生成器进行参数更新。

(3) 产生新的生成数据，利用判别器计算出预测值，同样根据预测值和真实值间的损失值计算梯度后更新模型。

(4) 重复执行 1，2，3 三步直到完成指定训练轮次。

(5) 利用最后得到的生成对抗网络产生指定数量的生成数据，与真实数据进行拼接得到最终的正类数据集，实现正类与负类相等。

4.4.3 模型配置

在所有对抗生成模型中，生成器采用统一的参数配置如下：

表 4.1 生成器统一配置参数

	网络层	参数	值
Generator	Linear	input	2000
		output	512
	ReLU		
	Linear	input	512
		output	512
	ReLU		
	Linear	input	512
		output	2000
	Tanh		

如表 4.1 展示的层级结构，输出采用三层全连接层来制造生成数据，原数据样本的特征决定了输出节点数为 2000，而输入来源于噪声，节点数定为 100。输入统一采用函数生成等于 batch 数量，包含 100 个特征的数组，数组总的元素符合标准正态分布，即均值为 0，方差为 1。最终输出采用 Tanh 进行处理将输出范围限制在 $(-1,1)$ ，方便后续反归一化成类质谱数据。

判别器则根据模型的不同采用不同的层级结构，GAN 和 WGAN 在网络层上应用的相同全连接层结构，而 DCGAN 和 WDCGAN 则是加入了相同的卷积层与池化层，使得两组模型的网络层级相同而仅在损失函数上差异化，具体配置如表 4.2 所示。

对于基础 GAN 和 WGAN 来说，判别器采用全连接层，由于本次为二分类任务，最终输出节点定为 1，在全连接层的最后一层采用 Sigmoid 作为激活函数

获得模型对于数据结果的概率判断值。

表 4.2 WGAN 及 GAN 的全连接层判别器配置

WGAN/GAN	网络层	参数	值
Discriminator	Linear	2000	256
	ReLU		
	Linear	256	64
	ReLU		
	Linear	64	1
	ReLU		
	Sigmoid		

而 DCGAN 及 WDCGAN 中的判别器则采用 1D-CNN 的结构，具体的层级配置如下。

表 4.3 DCGAN 及 WDCGAN 的 1D-CNN 判别器

DCGAN/WDCGAN	网络层	参数	值
Discriminator	Conv1d	in_channels	1
		out_channels	64
		kernel_size	4
		padding	4
		kernel_size	2
		stride	2
	ReLU		
	MaxPool1d	kernel_size	2
		stride	2
	view	展平特征图	
	Linear	64000	256
	ReLU		
	Linear	256	1
	ReLU		
	Sigmoid		

在卷积神经网络中，需要加入卷积层和池化层。如表 4.3 所示由于我们实验使用的一维数据，所以在数据处理环节，可以适当上采样来增加数据容量，以提高模型的特征提取能力，所以在卷积层，将输入的单通道数据扩展成 64 通道。然后将数据池化后，再交由全连接层处理。在此期间，由于卷积上采样后生成的

数据拥有了 64 通道的数据，所以想重新转化为全连接层可以处理的一维数据，还需要将特征图展开，并计算展开后的特征数量，从而确定全连接层输入的节点数。

4.4.4 数据归一化及滤噪

原始质谱数据中，可以观察到强度峰最高值能到 260 多，而其他峰强度仅有个位数。如果直接将强度数据送入神经网络，会导致在多层网络下，靠近输入层的权重更新变得非常缓慢，低强度数据会被当做噪声数据被一层层稀释，最后产生梯度消失的情况。

为了避免梯度消失，需要对输入数据进行归一化处理。但要注意的是，由于生成网络最终需要得到的是接近于原数据的结果，所以需要在数据生成后完成反归一化操作，保证生成的数据符合原始数据的分布。实验过程中调用了 `sklearn.preprocessing` 库，这是机器学习中常用的预处理库。使用函数 `MinMaxScaler` 实现归一化操作。

其次是对生成数据的去噪处理，将生成的数据直接与原始数据进行对照可以得到下表：

表 4.4 原始数据与未滤噪生成数据部分强度对比

m/z	x	x+1	x+2	x+3
原始数据	0	0	18.00073446	0
	0	0	12.84498133	0
	0	0	5.11078028	0
生成数据	0.297379762	0.641206026	12.75370026	0.405225277
	0.353506982	0.656607926	15.09770966	0.475888878
	0.302538067	0.62765795	14.32544613	0.356446564

从表 4.4 可以观察到，随机选取 x 质荷比及之后几个特征点的数据。原始数据中，没有检测到离子的质荷比上，强度数据为 0。而在 GAN 生成的数据中，由于数据经过了多个隐藏层，输入数据在多层权重的计算下，在每个输出节点都会产生一定的输出值。然而这个数据对于真实质谱数据来说，是无用的噪声数据，因为他们会将不存在的质荷比带入到模型训练，增加训练难度。所以实验中需要设定一定的阈值来滤除这些基本噪声。观察大量数据后，确定了 1 作为滤波阈值来处理这些数据。

4.5 实验验证

4.5.1 数据准备

首先从原始数据集中，根据前文所介绍的不平衡数据集获取方法，获得一个不平衡数据集和一个平衡的测试数据集，测试集中正负类数量为各为 100，形成 1:1 的配比。而不平衡数据集则采用前文提到的数据分块操作获得，再根据图 4.2 的方式，利用四种增强算法去补齐少数类数据，得到一个平衡数据集。获得的四个数据集采用前文介绍的 1D-CNN 作为基准分类模型，分别训练相同的 500 轮次后取最终的 ACC 和 F1 值作为性能指标。ACC 用于衡量分类模型的整体性能，F1 则用于观察模型在正类和负类上的判别能力是否存在不平衡。

由于分类模型及其他基础参数都严格保持一致，所以增强后的数据集在相同模型下的训练结果可以间接表明对应增强数据集的质量。又因为增强数据集都是基于同一个原始不平衡数据集进行生成的，那么增强数据集的质量取决于增强算法的性能，即该算法生成接近真实数据的能力。

为了进行更全面的对比，需要将数据集切分成不同不平衡度的原始数据集。按正类：负类的比例，分别选取了 1:50，1:20，1:10 这三个不平衡比例下的数据集。同样为了保证数据的一致性，四个数据集的负类都采用同一批切割的数据，而正类数据则先切割出需求最大数量的数据集，再从其中依次向下切割。如本次实验中负类数量定为 500 条，那么首先通过六折交叉验证的分割方式获取 50 条正类数据与 500 条负类数据构成 1:10 的不平衡数据集。再从这 50 条正类数据中随机筛选出 25 条数据，与相同的 500 条负类数据结合，构成 1:20 的不平衡数据集，以此类推。

4.5.2 生成数据分析及对比

利用原始不平衡数据集，进行数据增强后，将得到平衡的增强数据集。将生成的数据和原始数据集进行对比分析。

以 $IR=10$ 的数据集为例，包括了 50 条正类数据。首先通过前文的原始正类数据分析可以知道，原始的正类数据存在着两种不同的数据峰，在分布上构成了两个聚类，在二维 PCA 分析下，可以看出其主要分布。那么以 ADASYN 作为合成算法的代表，在二维 PCA 分析下可以得出下图。




图 4.6 原始正类数据与 ADASYN 合成数据二维 PCA 对比图

从图 4.6 中可以看到，原始数据分布较为分散，导致 ADASYN 的数据合成数据时采用的数据点可能差异较大，导致最终生成的数据的离散程度较大。这样的数据有利于增强模型的泛化性，但也会带来更多的噪声数据。接下来对比 CWDCGAN 生成的数据与原始数据。




图 4.7 原始正类数据与 CWDCGAN 生成数据二维 PCA 对比图

由于生成式算法采用固定的生成模型来生成目标数据，模型参数的唯一性导致数据的输入和输出的对应具有唯一性，数据的随机性由模型的输入 Z （一般使用符合正态分布的高斯噪声）产生，这使得生成的数据都保持在一定的波动范围内。在图 4.7 中可以看到生成式算法得到的数据十分集中，但也保留了一部分偏移。这种数据能使模型更容易拟合，用更少的轮次获得一个优秀的训练结果，作为代价，最终的模型也可能存在过拟合，泛化性不足的问题。

从宏观角度进行算法对比分析，基于采样的算法在处理数据时，不仅保留了原始数据中的噪声特性，而且在面对多聚类数据集时，还可能导致额外噪声的生

成。相比之下，基于生成的算法则能够生成与原始数据分布高度一致的新样本，有效避免了噪声的扩大化，确保了生成数据的分布与原始数据保持较高的相似性。

为进一步探究生成数据的微观特性，我们从原始数据集中随机抽取单条独立数据进行细致分析。鉴于原始数据呈现两个聚类特征，我们首先将原始数据集划分为两个聚类子集，随后分别从每个子集中随机选取一条数据作为该聚类的典型代表。同时，为进行对比分析，我们分别抽取一条由 ADASYN 算法和 CWDCGAN 模型生成的数据样本。

在可视化呈现上，我们以质荷比（即特征维度）为横坐标，以强度为纵坐标，构建二维坐标系来展示数据特性。为确保所有数据的强度特征在可视化范围内得到完整呈现，我们将纵坐标的范围设定为涵盖所有样本强度的最大值，从而保证数据点在图形中的清晰展示和有效对比。




图 4.8 原始正类数据与两种生成数据对比图（强度-质荷比）

图 4.8 中的前两条原始数据中可以看出正类数据存在两种不同的强度峰，这对应数据分布中存在两个聚类。对于质谱数据来说，关键的强度峰即关键的物质是有限的，除了强度最高的几个峰之外，其他强度数据对于分析来说价值较小，这些数据可以被视作为噪声数据，在神经网络训练中会影响模型性能。可以观察发现 ADASYN 的数据由于是从原始数据中合成的，保留了原有数据中的噪声，可以看到除了主峰外，250-750 质荷比范围内明显存在较多的噪声信号。这也印证了合成式数据会等比例放大噪声信号的特点，无法对噪声信号做有效抑制。

而对比观察 CWDCGAN 生成的数据，由于生成模型是基于全部数据进行训练，任一单条数据中存在的噪声对于模型的影响，会在训练中被其他无噪声数据纠正。最终能被模型参数记录保存的特征，都是大量出现占比较大的核心强度峰数据。

4.5.3 分类结果统计及分析

基于相同的不平衡数据集，各算法增强后参与统一的模型训练，得出以下结果。

表 4.5 不同 IR 时各增强算法下模型训练结果

pos : neg		1 : 50	1 : 20	1 : 10
ADASYN	ACC	0.76	0.82	0.875
	F1	0.6883	0.7805	0.8587
Borderline-SMOTE	ACC	0.745	0.8	0.865
	F1	0.6622	0.75	0.8439
KMeansSMOTE	ACC	0.775	0.83	0.895
	F1	0.7096	0.7951	0.8826
GAN	ACC	0.73	0.775	0.85
	F1	0.6301	0.7097	0.8235
DCGAN	ACC	0.76	0.8	0.86
	F1	0.6842	0.75	0.8444
WGAN	ACC	0.77	0.805	0.86
	F1	0.7012	0.7577	0.8372
CWDCGAN	ACC	0.805	0.85	0.9
	F1	0.7577	0.8235	0.8888

表 4.5 记录了各个实验条件下各个模型的最终模型分类数据。表的实际数据中，可以分析得出三个概要结论：

(1) 原始数据集不平衡比例 IR 越高，对应生成的增强平衡数据集的整体准确率越低。这与前文实验中的验证一致。前文验证了相同模型下，数据集不平衡比例越高，训练出来的模型性能越差。同样的在基于不平衡数据集的增强数据集下，虽然已经保证了数据集的正负类平衡，但生成的数据与真实数据仍存在的一定差距，导致最终模型效果相较于全部为真实数据的平衡数据集仍会存在一定差距。同时当不平衡比例越低，模型效果越好。这是由两方面因素共同决定的，一是在本实验的获取平衡数据集的策略下，不平衡比例越小也代表最终增强数据集中需要生成的样本数据越少，相对的真实样本数据的比例就越高，使得模型更容易准确学习到真实样本的特征。二是真实样本数据的相对比例越高，生成模型用于训练的数据量就越大，更容易学习到真实样本的特征，生成出更加接近真实数据的样本。两者共同作用使得原始数据集的不平衡比例与分类的效果呈显著的负相关。以 CWDCGAN 为例，将 1:50 的不平衡比例作为基准，1:20，1:10 两个不平衡比

例下的原始数据集，准确率分别提升了 4.5%，9.5%。其他增强算法也保持一致的规律性。

(2) CWDCGAN 在各个不平衡比例下，相较于三个生成算法都有一定程度的性能提升。在三个不平衡比例下的对比实验中，CWDCGAN 生成的增强数据集始终相对于其他六种对比算法获得了更好地训练结果，从而可以得出 CWDCGAN 能够更加有效地生成接近数据真实分布的样本数据，该生成模型拥有更佳的性能。在 1:50，1:20，1:10 三个不平衡比例下，CWDCGAN 相较于其他六个对比算法中的最优者，分别提升了 3%，2%，0.5% 的准确率。同时 CWDCGAN 的 F1 也优于其他六个对照算法，表明 CWDCGAN 拥有最强的数据增强性能。

(3) 随着不平衡比例 IR 的减小，基于采样的数据增强算法相较于基于生成的数据增强算法性能提升更快。这是由于两种方式的特性决定的。基于采样的增强方式最大的噪声干扰来源是数据中的边缘数据和异常数据，基于采样的算法会等比例放大这些噪声。基于生成的增强算法对于原始真实数据自带噪声有一定的抑制作用，单一异常数据带来的权重变化会在其他正常数据训练过程中被减小。而生成算法由于需要生成器输入高斯噪声来生成数据，导致生成的数据难免带来固有噪声。IR 越大，采样算法会带来更多的噪声信号。而生成算法的噪声影响就相对较小。反之，IR 越小，需要生成的数据越少，原始数据噪声带来的影响减弱，而生成算法的噪声仍无法剔除，导致性能损失。

接着将采样算法和生成算法进行单独对比分析，分析其结果的趋势原理。

(1) 采样算法：在三种采样算法中，ADASYN 作为随机过采样欠采样算法，对于数据的分布并没有分析，可以作为三种采样算法的对照基准。Borderline-SMOTE 作为 SMOTE 的变种，着重选取边缘数据进行生成。之前对于该数据集进行 PCA 分析时可以发现，数据集的正类并非单个聚类，而且正负类数据存在明显的混叠现象。这种情况下，生成的近似边缘数据越多，正负类反倒会更加难以区分，从而降低模型性能，所以其性能表现反倒不如 ADASYN。而 KMeansSMOTE 基于聚类去进行分析，能够捕捉到数据存在的主要聚类，从而生成远离决策边界的数据，使得模型能更清晰地区分正负类数据，因此 KMeansSMOTE 也获得了生成类算法中的最佳性能表现。

(2) 生成算法：从四个生成算法的横向对比来看 DCGAN 和 WGAN 的改进策略能有效提升生成数据的质量。对比 GAN 和 DCGAN，WGAN 和 CWDCGAN 这两组对照算法，能够发现在控制其他变量的情况下，加入卷积层的对抗生成模型能够生成更高质量的数据样本。同样的对比 GAN 和 WGAN，DCGAN 和 CWDCGAN 两组算法，可以发现利用 Wasserstein 距离的损失函数代替传统的二

元交叉熵损失函数，对于模型生成数据的质量，也能有显著的正提升。而条件信息的加入，更使得生成的数据更符合需求，最终使得模型性能也获得了大幅度提升。

4.6 本章小结

本章主要研究了通过 CWDCGAN 算法生成数据来增强不平衡数据集，从而提升最终分类模型的性能。实验从公开的 COVID-19 数据集中分割出不同类别比例以及不同数量的不平衡数据集作为原始数据，应用本章提出的 CWDCGAN 来生成平衡数据集，选取了基于采样的 ADASYN，Borderline-SMOTE，KMeansSMOTE 三种主流算法和 GAN 与 DCGAN，WGAN 三种数据增强算法作为对照，对比各个算法下增强后的平衡数据集训练所得模型性能表现。在 $IR=50$ ， $IR=20$ ， $IR=10$ 三个不平衡比例下，CWDCGAN 相较于其他六个对比算法中的最优者，分别提升了 3%，2%，0.5% 的准确率。结果表明基于条件生成及 Wasserstein 的深度卷积对抗网络 WDCGAN 模型增强算法，在数据增强性能上优于其他六种数据增强算法。

5 基于 CWDCGAN 不平衡增强算法的联邦学习架构

5.1 引言

联邦学习能够实现多机构协同训练,利用多方数据集去提升模型效果。本章研究主要对比全局模型与各参与方单独训练模型的效果,探讨联邦学习框架能在不同的不平衡数据集下对模型的效果提升情况。本章将基于第三章 1D-CNN 基础质谱分类模型去构建联邦学习框架,数据增强采用第四章的条件生成对抗网络进行生成。

5.2 样本数量对于模型性能的影响及分析

5.2.1 数据量不足对于模型的影响

数据量对于分类模型的影响主要体现在模型的训练效果,泛化能力和鲁棒性上。主要从以下几个方面导致模型效果不佳:

(1) 特征学习不足:当数据量不足时,模型可能无法从有限的数据中学习足够的规律和特征。质谱数据中,主要离子团及其官能团碎片之间存在强相关性。而这些关联反映到训练数据的空间关系上,则大多是质荷比相差极大的两个峰值数据间的关系。这种关联在质谱数据这种上千个特征数据中,需要大量数据去拟合这种规律。有限的训练数据会导致这种关系难以被分类模型表达,这也是导致模型泛化能力差的重要因素之一。

(2) 重复训练带来的过拟合:在数据有限的情况下,往往采用增加训练轮次和增加模型复杂度来提升模型的性能。而这些途径都会带来模型过拟合的问题,从而进一步导致模型泛化能力变弱。

(3) 鲁棒性差:质谱数据的获取受到设备,人员操作,采样环境等各方面因素的干扰,导致获取到的数据相较于标准数据,会引入许多未知的噪声信息,影响模型训练效果。甚至在数据处理阶段还会产生一些错误数据污染数据集。在数据总量不足的情况下,这些问题将进一步被放大。由于数据量不足,模型的鲁棒性差,更容易被噪声或错误数据干扰导致模型性能降低。

5.2.2 联邦学习对于数据量问题的解决力

从前文的研究背景中我们已经介绍,当前质谱分析无法采用传统的集中式训练来解决数据量的问题,其核心原因是质谱数据的隐私问题导致各方难以共享数据。联邦学习是一种分布式机器学习框架,它允许多个参与者在保护各自数据隐私的同时共同训练一个模型。这种方法对于解决数据量问题具有以下优势:

(1) 数据隐私保护: 联邦学习能够实现数据在本地进行训练,无需将数据集中到一个中心服务器,这将避免质谱数据中包含的敏感隐私信息泄露。这种训练方式保护了用户的隐私和数据安全,严格遵循了现行的数据保护法律法规,确保了合规性。

(2) 整合分布式数据资源: 通过联邦学习,多个质谱数据训练参与者可以共享他们的本地数据训练出的模型参数,最终聚合形成一个更强大、更全面的全局模型。该训练策略下,分散的数据资源被整合起来,联合各方数据提高了模型的泛化能力和性能。

(3) 解决类别缺失问题: 当单个参与者数据量不足时,其主要分类类别存在缺失的情况,本文研究的 COVID-19 在其传播周期内出现了多种变种,单个机构可能无法得到所有变种的样本数据。通过联邦学习可以与其他参与者共享模型参数,从而间接地利用了其他参与者的数据。这种方式可以在一定程度上弥补类别缺失的问题,提高模型的训练效果。

(4) 提高模型鲁棒性: 由于联邦学习利用了多个参与者的数据进行训练,其数据规模的扩大也使得模型变得更加鲁棒和通用。这种框架下训练所得的模型对于不同来源和分布的数据具有更好的适应性。

综合以上考量,联邦学习作为一种先进的分布式机器学习框架,不仅能够有效解决数据量的问题,从而优化数据量不足带来的一系列问题,还能有效提升单个机构训练模型的鲁棒性,获得更佳优秀的全局模型并共享。

5.3 实验设计

实验中的程序的运行环境和硬件配置都与第三章的实验环境一致。

5.3.1 中心化的信任方式

在质谱分析应用中,本实验采用中心化的信任方式,即有中心协调方的方案,针对主要的应用场景,一般可以找到作为主导的协调方。对于民用质谱分析应用

中,质谱仪的制作厂商可以提供联合训练的服务;在医用领域,各地区的核心医院可以主动牵头发起联合训练。

中心协调者的出现,可以对整个聚合过程产生监督和调整,大大减少不确定性,减少的不确定性主要体现在参与方数据种类的不确定和模型融合方向上的不确定两个方面。

一方面联合训练的机构存在强关联:质谱仪能分析的物质范围十分广泛,分析的物质从无机物到有机物,有机物中又能分为非生物有机物和生物有机物,生物有机物中,蛋白组学和代谢组学又是不同的分支。对于一个需要联合训练的团体,其主要分析的物质必定存在相似性,这就意味着寻找联合训练伙伴的过程也是互相筛选对方所拥有的样本数据的过程,对方所拥有的样本数据与自身需要的是否一致决定了联合训练的作用。不同领域物质的联合训练没有任何意义。以中心化的联合训练组织模式能保证参与成员都是其能号召的同行业机构,参与方都能从其他人数据中获益。比如某地多家医院同一科室的病理采样样本,能够在联邦学习的辅助下建立全市人民在特定疾病表达蛋白的高泛用性检测模型;同样在警方机构下,不同地方收缴的不同毒品数据能在联邦学习后,形成全品类毒品的通用识别模型,使得任何单一机构都能拥有检测本地新型输入毒品,即便该毒品之前从未出现在本地的检测样品训练数据库。

另一方面协调方可主导融合策略:尽管参与方默认都是可信的数据提供者。但其提供的数据仍可能由于纰漏或者本身数据量的匮乏导致上传的参数失真。中心协调方这时就能来解决这些问题,在模型聚合过程中加入准入限制,或者调低小机构提供数据在全局融合过程中的权重来保证数据的可信度,同时在联合训练过程中,对各个节点更新的数据进行验证和检测,来避免一些拜占庭错误甚至是数据投毒。

5.3.2 联邦训练框架

以下为本实验设计中联合训练的基本框架,由公信方担任中心协调者的角色,负责每个轮次下的模型融合,参与节点将使用同一模型初始化后参与训练。




图 5.1 基于神经网络的联邦学习框架

如图 5.1 所示，在有协调方参与的框架下，确定参与节点，以三个为例。每个节点都独立构建了神经网络模型。在初始化操作时，中心协调方会将统一的训练模型进行复制下发。训练中还需要明确在联合训练过程中各节点分享的数据内容。在神经网络中，只要获取到各层的权重 w 和偏置 b 。在同一模型下就能还原该模型，那么模型聚合就转换成了这两个参数的聚合。同时，我们也考虑会加入一些其他模型参数上传，如我们希望了解到各节点的样本数量，以此作为依据来改变各节点在融合时的分配权重；我们还可以希望了解到各节点当前轮次收敛情况的更多数据，比如损失值。

那么在基础那么在每一轮训练过程中，各个节点在第一轮训练中，首先会以初始化的统一模型为基础，用本地数据进行一轮训练。当各节点训练完毕后，各节点需要将本次训练后得到的模型全部权重 w (weight) 和偏置 b (biases) 参数进行上传。中心协调方会用融合算法，如经典的 FedAvg 对各节点上传的参数进行融合。当融合完毕后，新的模型参数将被重新下发给各个节点，由于全局模型和各节点训练用的模型是一致的，所以仅需要重新下发 w 和 b 两个参数就能实现在各节点还原全局模型。

新一轮联合训练中，各个节点就将以全局模型作为新的训练模型进行单独训练，训练完毕后重复以上操作。

值得注意的是，不仅各节点的模型在训练中需要统一，各节点调用的训练程序也需要保持一致，包括但不限于 lr ，单次样本抓包大小等。这些参数可能会导致各模型收敛速度不同使得全局模型更容易发散。

5.3.3 数据集分割

为了模拟实际环境下多方参与联邦训练的场景。首先从数据集中分割出三个独立的节点数据集以及一个公共测试集，代表着三个质谱数据拥有方也就是三个现实质谱检测机构及来源于公共环境下的质谱检测任务。




图 5.2 不平衡数据增强下的联邦训练架构

图 5.2 展示了加入了不平衡数据增强的联邦学习主要架构（以 $IR=4$ 为例），**pos** 代表正类数据，**neg** 表示负类数据。首先按照预设的不平衡比例从总数据集中分割出用于训练的原始数据集，根据数据集的容量，负类数据有 800 多条，保留 100 条作为测试集后，随机选取 600 个负类数据参与实验。那么根据 $IR=4$ ，同步随机选出 150 条正类数据与 600 条负类数据组成总数据集。

架构中三个模拟节点代表三个独立机构，在联邦架构中，他们是数据的持有方，也承担着分布训练的职责。在本次实验中，创建三个独立的模型实例作为模

拟节点，三个模型的参数互相独立，模拟三个不互通的训练节点。节点的训练模型沿用第三章的 1D-CNN 模型。同时三个模型的结构和超参数保持一致，使得模型的参数能在全局模型中融合。将总数据集均分成三份，使得每个节点获得一份包含正类数据 50 个和负类数据 200 个的原始节点数据集。

为了使得数据集保持 1:1 的平衡状态，每个节点都需要生成正类数据来增强数据集。而在 $IR=4$ 的情况下，需要生成 150 条正类数据。生成算法采用的是第四章提出的 CWDCGAN，最终生成的正类数据与原始数据集合并，就成为了一个正负类 1:1，正负类各两百条的增强数据集。

同时为了丰富测试的场景，需要还原模拟各个机构数据量少以及数据不平衡的情况。三个节点的数据集也将拥有不同的不平衡比例作为对照，数据被分割成与上文相同的 1:20，1:10，1:5 三种比例的不平衡数据集。构成每个节点三组比例，全局结构三个节点的测试环境。

5.3.4 联邦模型聚合算法-FedAvg

联邦学习的基本思路是在每次训练任务中，预先下发统一预测模型的初始权重。

$$\omega_{t+1}^k \leftarrow \omega_t \quad (5.1)$$

各参与节点开始训练计算得出局部模型的权重。

$$\omega_{t+1}^k \leftarrow \omega_{t+1}^k - \eta \nabla F_k(\omega; b) \quad (5.2)$$

在式 5.2 每一轮上传本地计算得出的损失值上传到协调方，由协调方进行融合然后调整模型，并将新模型重新下发到各个节点，完成一轮完整的训练。最初的联邦学习大量采用 FedAvg 作为融合算法，其融合策略算法 4 所示。

算法 4 联邦平均算法 (FedAvg)

输入: 全局模型初始参数 θ_0 ，客户端总数 K ，每个客户端的本地训练轮数 E ，学习率 η

输出: 更新后的全局模型参数 θ

for 通信轮次 $t = 1$ 到 T **do**

 服务器随机选择 m 个客户端 ($m \leq K$)

for 每个被选中的客户端 k (并行) **do**

 初始化本地模型参数: $\theta_k^t = \theta^{t-1}$

for 本地训练轮次 $e = 1$ 到 E **do**

 从客户端 k 的本地数据集中采样一个批次 $\{x_i, y_i\}$

 计算损失 $L(\theta_k^t, x_i, y_i)$

```

10:          更新本地模型参数:  $\theta_k^t = \theta_k^t - \eta \nabla L(\theta_k^t, x_i, y_i)$ 
11:          end for
12:          计算本地更新量:  $\Delta\theta_k^t = \theta_k^t - \theta^{t-1}$ 
13:          将本地更新量  $\Delta\theta_k^t$  发送至服务器
14:          end for
15:          服务器聚合更新量:  $\Delta\theta = \frac{1}{m} \sum_{k=1}^m \Delta\theta_k^t$ 
16:          更新全局模型参数:  $\theta^t = \theta^{t-1} + \Delta\theta^t$ 
17:      end for
18:      返回: 更新后的全局模型参数  $\theta^t$ 

```

其算法重要核心思想是默认各参与节点对于全局模型的贡献一直, 所以计算更新量时, 对于所有节点的更新量采用累加并除以节点总数 m 。最终获得的更新量会被协调方重新下发给各个节点进行下一轮训练。如此循环往复, 达到一定轮次后结束。

5.4 实验验证

对比验证的第一步就是先测试各个节点数据集单独训练的模型效果。模拟的是各个节点在数据孤岛情况下的独立训练能获得的模型性能。每个训练参与者根据自身拥有的 150 条原始数据去训练一个独立的 1D-CNN 模型。最终的训练结果分别记录。

而联邦学习下, 协调方将构建一个 1D-CNN, 然后将模型下发给训练参与者。同时, 协调方将下发一个 CWDCGAN 模型用于数据生成。这两个模型的结构一致。在训练过程中, 对于参与方所使用的超参数也要严格保持一致。参与者将采用 CWDCGAN 先将自有数据补全成一个平衡数据集。然后与协调方多轮通讯, 完成联邦学习训练。

实际应用场景中, 参与方在完成训练后需要上传模型参数文件, 常用的是 pth 文件, 协调方加载 pth 文件就能提取节点模型的权重和偏置。在实验中, 采用三个独立模型的方式来进行训练, 其之间通讯就简化成模型参数的直接赋值。将三个节点模型的参数 dict 根据融合算法进行融合, 具体到微观层面就是对 dict 每个 key 值进行运算, key 值中就包含了节点间映射的权重和偏置。

最后应用前文提出的不平衡数据平衡算法, 将各个节点的数据增强成平衡数据集从而能够参加联邦训练。最后, 启动联邦训练流程, 由协调方创建全局模型下发各个节点, 在指定轮次内对全局模型进行训练和同步。实验得到的结果如下表所示。

表 5.1 各节点模型与联邦模型在不同比例下的性能对比

		P10N200	P20N200	P50N200
Node A	ACC	0.72	0.86	0.86
	F1	0.6111	0.8372	0.8372
Node B	ACC	0.805	0.86	0.845
	F1	0.7578	0.8391	0.8166
Node C	ACC	0.665	0.85	0.86
	F1	0.4962	0.8276	0.8372
Fed Model	ACC	0.815	0.875	0.865
	F1	0.7730	0.8571	0.8439

从表 5.1 的实验结果中可以看出，在相同的不平衡比例下，联邦学习下的模型的准确率和 F1 分数均优于其他任一节点单独训练的模型。在三种不同的不平衡比例下，联邦学习的效果均能优于节点的单独训练。这也就意味着对于任一参与方来说，参与联邦学习训练全局模型后，各参与方都能从全局模型中获益，且在训练过程中，参与方只需要上传配合训练的本地模型权重信息，不需要直接上传本地数据，这样也就避免了隐私泄露。所以，联邦学习能够在规避隐私风险的情况下，联合各方进行模型训练，以获得接近集中式训练的结果，从而提升模型的性能。

5.5 本章小结

本章研究主要对比全局模型与各参与方单独训练模型的效果，联邦学习下的全局模型在 $IR=20$ ， $IR=10$ ， $IR=4$ 的三种不平衡数据集下，相较于结果最佳的节点模型，都能分别获得 1%，1.5%，0.5% 的准确率提升，验证了联邦学习框架能在不同的不平衡数据集下对模型的效果进行提升。

6 全文总结与展望

6.1 全文总结

随着机器学习成为质谱分类任务中的重要工具,质谱数据的类别不平衡问题和数据量匮乏问题也成为了制约分类模型性能的重要因素。

本文首先根据质谱数据特点,设计了针对质谱数据的神经网络分类模型,然后应用生成对抗网络的变种网络来实现对数据类别不平衡问题的优化,最后搭建了质谱分类模型的联邦学习框架,实现在保护隐私的前提下改善因训练数据不足而导致的模型性能降的问题,论文的工作总结如下:

(1) 本文根据质谱数据的一维数据特点,选择 1D-CNN 完成了分类模型的设计。在 COVID-19 数据集下,设置了不同数据量和不同正负类配比的数据集作为训练数据。对比 SVM, RF, BP 神经网络, 空洞卷积网络的分类模型, 实验得出 1D-CNN 在不同的数据构成下, 都能有最佳的分类性能。同时对比同个模型在不同数据集和不同平衡比例下的分类表现, 验证了数据不平衡以及数据数量对于模型性能的影响。

(2) 针对数据类别不平衡的问题, 提出一种基于 CWDCGAN 的数据增强方法。数据类别不平衡会导致参与训练的数据无法满足独立同分布, 使得最终的模型对于少数类的识别能力差。本文根据质谱分类模型的结构, 选择了 1D-CNN 作为卷积层去改造 DCGAN, 并用 Wasserstein 距离作为损失函数替换传统的交叉熵损失函数, 并加入生成条件替换传统的生成器高斯噪声输入, 完成对于少数类数据的定向生成, 从而使数据集达到平衡状态。通过实验证明, 相较于主流广泛采用的 ADASYN, Borderline-SMOTE, KMeansSMOTE 三种采样算法和 GAN, DCGAN, WGAN 三种生成算法, 本文提出的 CWDCGAN 算法在 1:50, 1:20, 1:10 四个不平衡比例下, 相较于其他六个对比算法中的最优者, 分别提升了 3%, 2%, 0.5% 的准确率, 证明该算法具备优秀的数据增强性能。

(3) 构建了基于不平衡增强算法的联邦学习架构。数据量不足会导致模型性能较差, 而传统集中式训练在医疗质谱应用领域会受到数据隐私问题的制约。联邦学习框架通过联合多个参与方共同训练全局模型。训练过程中仅上传模型参数不交换原始数据, 在保护各节点的数据隐私的前提下共享各方数据对于全局模型的增益。实验结果表明, 相较于任一单个节点, 联邦学习训练的全局模型获得了更佳的性能表现。

6.2 展望

随着质谱技术的不断发展,与机器学习的交叉研究被业界广泛关注,提升质谱分类模型性能的技术路线变得更加多元化。本文提出的生成对抗网络和联邦学习针对质谱数据类别不平衡问题和数据量匮乏进行研究,虽然取得了一定效果,但仍有许多方向值得进一步研究和完善。主要概括为以下两个方面:

(1) 生成精度的提升。生成网络基于传统神经网络,其可解释性较差,导致生成模型的生成规律无法被总结,也就难以指导数据生成过程。条件生成对抗网络一定程度上使得数据的生成方向可控,但具体条件信息对于生成的影响原理尚在研究中。了解条件信息对于数据生成的控制,也就能更好地指导数据的精细化生成。

(2) 通讯开销的优化。深度学习中模型的参数数量取决于网络层数,输入特征数,隐藏层节点数等多个因素。质谱数据的分类模型需要以质荷比作为特征去进行训练, m/z 的范围和细分度越高,也就意味着输入的特征越多。特征数量带来的参数数量增加在本地训练任务中只会导致算力开销增大,主要包括参与计算的数量变大和模型收敛速度变慢而导致的训练轮次增加。在联邦学习框架下,参数是通讯的主要内容。不管是参数数量级的增加,还是训练轮次的增加,都会带来更大的通讯压力。针对减少联邦学习通讯开销的研究也已经备受关注,而在具体的质谱细分领域,也需要提出针对性的优化策略来有效降低联邦学习训练中的通讯压力。

参考文献

- [1] 武开业. 气相色谱质谱联用仪的原理及分类[J]. 科技视界, 2014, (26): 270.
- [2] Santiago I. Trends and innovations in biosensors for COVID - 19 mass testing[J]. ChemBioChem, 2020, 21(20): 2880-2889.
- [3] Liu J, Li Z B, Lu Q Q, et al. Metabolite profile of COVID-19 revealed by UPLC-MS/MS-based widely targeted metabolomics[J]. Frontiers in immunology, 2022, 13: 894170.
- [4] He H, Garcia E A. Learning from imbalanced data[J]. IEEE Transactions on knowledge and data engineering, 2009, 21(9): 1263-1284.
- [5] 胡越, 罗东阳, 花奎等. 关于深度学习的综述与讨论[J]. 智能系统学报, 2019, 14(01): 1-19.
- [6] Niu W, Knight E, Xia Q, et al. Comparative evaluation of eight software programs for alignment of gas chromatography - mass spectrometry chromatograms in metabolomics experiments[J]. Journal of Chromatography A, 2014, 1374: 199-206.
- [7] Webb-Robertson B J M. Support vector machines for improved peptide identification from tandem mass spectrometry database search[J]. Mass Spectrometry of Proteins and Peptides: Methods and Protocols, 2009: 453-460.
- [8] Zhang X, Lu X, Shi Q, et al. Recursive SVM feature selection and sample classification for mass-spectrometry and microarray data[J]. BMC bioinformatics, 2006, 7: 1-13.
- [9] 罗凯旋, 钟凡, 赵亮等. 评估几种降维分类器应用于生物质谱数据的性能[J]. 中国科学:生命科学, 2010, 40(06): 544-550.
- [10] Woldegebriel M, Derks E. Artificial neural network for probabilistic feature recognition in liquid chromatography coupled to high-resolution mass spectrometry[J]. Analytical Chemistry, 2017, 89(2): 1212-1221.
- [11] 熊行创, 方向, 欧阳证等. 基于人工神经网络的生物组织质谱成像分类与识别方法[J]. 分析化学, 2012, 40(01): 43-49.
- [12] Kantz E D, Tiwari S, Watrous J D, et al. Deep neural networks for classification of LC-MS spectral peaks[J]. Analytical chemistry, 2019, 91(19): 12407-12413.

- [13] Peptides and Proteins - Proteome; Reports from Chinese Academy of Sciences Advance Knowledge in Proteome (MSpectraAI: a powerful platform for deciphering proteome profiling of multi-tumor mass spectrometry data by using deep neural networks)[J]. Network Weekly News, 2020: 2545.
- [14] J Lv , J Wei , Z Wang, et al. Multiple Compounds Recognition from The Tandem Mass Spectral Data Using Convolutional Neural Network[J]. Molecules, 2019, 24(24): 4590.
- [15] B Jiang, D Wei, J Liu , et al. Automated Classification of Massive Spectra Based on Enhanced Multi-Scale Coded Convolutional Neural Network[J]. Journal of Engineering, 2020.
- [16] H He, Garcia, A Edwardo. Learning from Imbalanced Data in Classification[J]. International Journal of Recent Technology and Engineering, 2020, 8(5): 1907-1916.
- [17] Sanz J A, Bernardo D, Herrera F, et al. A Compact Evolutionary Interval-Valued Fuzzy Rule-Based Classification System for the Modeling and Prediction of Real-World Financial Applications With Imbalanced Data.[J]. IEEE Trans. Fuzzy Systems, 2015, 23(4): 973-990.
- [18] Wang S, Yao X. Using Class Imbalance Learning for Software Defect Prediction.[J]. IEEE Trans. Reliability, 2013, 62(2): 434-443.
- [19] Pouyanfar S, Chen S-C. Automatic Video Event Detection for Imbalance Data Using Enhanced Ensemble Deep Learning[J]. International Journal of Semantic Computing, 2017, 11(1): 25.
- [20] Li J, Fong S, Mohammed S, et al. Improving the classification performance of biological imbalanced datasets by swarm optimization algorithms[J]. The Journal of Supercomputing, 2016, 72(10): 3708-3728.
- [21] 蒋盛益, 谢照青, 余雯. 基于代价敏感的朴素贝叶斯不平衡数据分类研究[J]. 计算机研究与发展, 2011, 48(S1): 387-90.
- [22] Van Der Putten P, Van Someren M. A bias-variance analysis of a real world learning problem: The CoIL challenge 2000[J]. Machine learning, 2004, 57: 177-195.
- [23] Chawla N V, Bowyer K W, Hall L O, et al. SMOTE: Synthetic Minority Over-sampling Technique[J]. The Journal of Artificial Intelligence Research, 2002, 16(0): 321-357.

- [24] Chawla N V, Lazarevic A, Hall L O, et al. SMOTEBoost: Improving prediction of the minority class in boosting[C]//European conference on principles of data mining and knowledge discovery. Berlin, Heidelberg: Springer Berlin Heidelberg, 2003: 107-119.
- [25] 胡小生, 张润晶, 钟勇. 两层聚类的类别不平衡数据挖掘算法[J]. 计算机科学, 2013, 40(11): 271-275.
- [26] Meng H H, Li G Z, Wang R S, et al. The imbalanced problem in mass-spectrometry data analysis[J]. Proceedings of the LNOR, 2008, 9: 136-143.
- [27] Zhu Y, Jia C, Li F, et al. Inspector: a lysine succinylation predictor based on edited nearest-neighbor undersampling and adaptive synthetic oversampling[J]. Analytical biochemistry, 2020, 593: 113592.
- [28] Tiwari A K, Nath A, Subbiah K, et al. Effect of varying degree of resampling on prediction accuracy for observed peptide count in protein mass spectrometry data[C]//2015 11th International Conference on Natural Computation (ICNC). IEEE, 2015: 691-695.
- [29] Douzas G, Bacao F. Effective data generation for imbalanced learning using conditional generative adversarial networks[J]. Expert Systems with applications, 2018, 91: 464-471.
- [30] 张蕾, 崔勇, 刘静等. 机器学习在网络空间安全研究中的应用[J]. 计算机学报, 2018, 41(09): 1943-1975.
- [31] Shokri R, Shmatikov V. Privacy-preserving deep learning[C]//Proceedings of the 22nd ACM SIGSAC conference on computer and communications security. 2015: 1310-1321.
- [32] 杨强. AI 与数据隐私保护: 联邦学习的破解之道[J]. 信息安全研究, 2019, 5(11): 961-965.
- [33] Vepakomma P, Gupta O, Swedish T, et al. Split learning for health: Distributed deep learning without sharing raw patient data[J]. arXiv preprint arXiv:1812.00564, 2018.
- [34] Tran H V, Kaddoum G, Elgala H, et al. Lightwave power transfer for federated learning-based wireless networks[J]. IEEE Communications Letters, 2020, 24(7): 1472-1476.

- [35] Ang L, Qiuyu Y, Boming X, et al. Privacy-preserving design of smart products through federated learning[J]. *CIRP Annals - Manufacturing Technology*, 2021, 70(1): 103-106.
- [36] Lakhan A, Hamouda H, Abdulkareem K H, et al. Digital healthcare framework for patients with disabilities based on deep federated learning schemes[J]. *Computers in Biology and Medicine*, 2024, 169: 107845.
- [37] Malik H, Naeem A, Naqvi R A, et al. DMFL_Net: A federated learning-based framework for the classification of COVID-19 from multiple chest diseases using X-rays[J]. *Sensors*, 2023, 23(2): 743.
- [38] Sadman S, Tahrat T, M. F M, et al. DL-CRC: Deep Learning-Based Chest Radiograph Classification for COVID-19 Detection: A Novel Approach[J]. *IEEE ACCESS*, 2020, 8: 171575-171589.
- [39] Cain C N, Synovec R E. Enhancing gas chromatography-mass spectrometry resolution and pure analyte discovery using intra-chromatogram elution profile matching[J]. *Talanta*, 2024, 278: 126453.
- [40] Barea-Sepúlveda M, Ferreiro-González M, Calle J L P, et al. Comparison of different processing approaches by SVM and RF on HS-MS eNose and NIR Spectrometry data for the discrimination of gasoline samples[J]. *Microchemical Journal*, 2022, 172: 106893.
- [41] Yin Y, Li W, Chen R, et al. Random forest algorithm reveals novel sites in HA protein that shift receptor binding preference of the H9N2 avian influenza virus[J]. *Virologica Sinica*, 2025, 40(1): 109-117.
- [42] Teng Y, Chen Y, Chen X, et al. Revealing the adulteration of sesame oil products by portable Raman spectrometer and 1D CNN vector regression: A comparative study with chemometrics and colorimetry[J]. *Food Chemistry*, 2024, 436: 137694.
- [43] Kulkarni S, Rabidas R. Detection of multiple abnormalities of breast cancer in mammograms using a deep dilated fully convolutional neural network[J]. *Computers and Electrical Engineering*, 2024, 120: 109662.
- [44] Alygizakis N, Lestremat F, Gago-Ferrero P, et al. Towards a harmonized identification scoring system in LC-HRMS/MS based non-target screening (NTS) of emerging contaminants[J]. *TrAC Trends in Analytical Chemistry*, 2023, 159: 116944.

- [45] Yeung M, Sala E, Schönlieb C-B, et al. Unified Focal loss: Generalising Dice and cross entropy-based losses to handle class imbalanced medical image segmentation[J]. Computerized Medical Imaging and Graphics, 2022, 95: 102026.
- [46] Shi Y, Zheng L, Quan P, et al. Wasserstein distance regularized graph neural networks[J]. Information Sciences, 2024, 670: 120608.
- [47] Sun L, Li M, Ding W, et al. AFNFS: Adaptive fuzzy neighborhood-based feature selection with adaptive synthetic over-sampling for imbalanced data[J]. Information Sciences, 2022, 612: 724-744.
- [48] Guo J, Wu H, Chen X, et al. Adaptive SV-Borderline SMOTE-SVM algorithm for imbalanced data classification[J]. Applied Soft Computing, 2024, 150: 110986.
- [49] Zeng Q, Gong Z, Wu S, et al. Measuring cyclists' subjective perceptions of the street riding environment using K-means SMOTE-RF model and street view imagery[J]. International Journal of Applied Earth Observation and Geoinformation, 2024, 128: 103739.
- [50] Scalzo V. Existence of doubly strong equilibria in generalized games and quasi-Ky Fan minimax inequalities [J]. Journal of Mathematical Analysis and Applications, 2022, 514(1): 126258.
- [51] Bilbao A, Gibbons B C, Stow S M, et al. A Preprocessing Tool for Enhanced Ion Mobility–Mass Spectrometry-Based Omics Workflows[J]. Journal of Proteome Research, 2022, 21(3): 798-807.
- [52] 孙琳, 张秋菊, 王文佶等. 基于色谱-质谱平台的代谢组学数据预处理方法[J]. 中国卫生统计, 2017, 34(03): 518-522.
- [53] 孟辉, 洪文学. 蛋白质组学质谱数据预处理技术综述[J]. 中国生物医学工程学报, 2009, 28(03): 469-475.
- [54] Folli G S, Nascimento M H C, Lovatti B P O, et al. A generation of synthetic samples and artificial outliers via principal component analysis and evaluation of predictive capability in binary classification models[J]. Chemometrics and Intelligent Laboratory Systems, 2024, 251: 105154.
- [55] Yang Y, Mirzaei G. Performance analysis of data resampling on class imbalance and classification techniques on multi-omics data for cancer classification[J]. PLOS ONE, 2024, 19(2): e0293607.

- [56] Cohen G, Afshar S, Tapson J, et al. EMNIST: Extending MNIST to handwritten letters[C]//2017 international joint conference on neural networks (IJCNN). IEEE, 2017: 2921-2926.
- [57] Yurochkin M, Agarwal M, Ghosh S, et al. Bayesian nonparametric federated learning of neural networks[C]//International conference on machine learning. PMLR, 2019: 7252-7261.
- [58] McMahan B, Moore E, Ramage D, et al. Communication-efficient learning of deep networks from decentralized data[C]//Artificial intelligence and statistics. PMLR, 2017: 1273-1282.