

非平衡小样本条件下基于 CNN-SVM 的 变压器故障诊断方法

张 萍¹ 缪宇峰² 沈 磊² 刘 峰² 沈 毅² 王晓宇³

(1. 国网浙江省电力有限公司杭州市余杭区供电公司

2. 杭州电力设备制造有限公司余杭群力成套电气制造分公司

3. 东北电力大学机械工程学院)

摘 要: 针对变压器故障诊断过程中因故障样本数量不均导致的诊断准确率偏低问题, 本文提出一种基于卷积神经网络-支持向量机 (CNN-SVM) 的变压器故障诊断方法。该方法首先运用局部均值分解 (LMD) 方法对原始信号进行多层次的分解, 进而通过计算模糊熵值筛选出信号中的有效分量, 从而实现信号的有效降噪。随后, 针对预处理后的信号, 采用深度卷积生成对抗网络 (DCGAN) 生成充足且均衡的样本数据。最终, 将生成的数据样本输入至 CNN-SVM 模型进行训练与诊断。实验结果表明, 所提方法在各类故障类型上的诊断准确率均超过 95%, 相较于现有方法, 展现了更高的诊断精度和更强的鲁棒性。

关键词: 变压器故障诊断; 小样本; 局部均值分解; 卷积神经网络

0 引言

变压器作为电力系统中关键的设施之一, 其无故障运行对可靠的电力供应起着决定作用。然而, 变压器在实际工程中往往因为工作环境恶劣或长期过载运行导致绕组变形、绕组松动、铁芯松动等故障类型, 此类故障可能进一步造成不可逆转的后果^[1]。因此确保电力系统能够稳定运行, 实时监测变压器的运行状态, 并对存在潜在安全风险的变压器实施在线故障检测, 显得尤为关键和必要。

近年来, 深度学习技术已被广泛应用于变压器故障诊断领域。文献[2]对应用深度学习框架实现变压器故障智能诊断的可行性进行了系统性探讨, 展示了该技术在提升诊断智能化水平方面的潜力。文献[3]提出了一种基于卷积神经网络 (Convolutional Neural Network, CNN) 的变压器故障诊断方法, 并通过实验证明了 CNN 在故障识别准确性方面的显著优势, 验证了其在实际应用中的有效性与可靠性。然而, 该方法在鲁棒性及特征提取能力方面仍存在一定局限性, 制约了其在复杂工况下的推广与应用潜力。针对 CNN 的局限性, 研究者们继续探索了其他优化策略。文献[4]提出了一种结合烟花算法 (Fireworks Algorithm, FWA) 和支持向量机 (Support Vector Machine, SVM) 的变压器故障诊断模型。该模型采用

萤火虫算法 (FWA) 对支持向量机 (SVM) 的超参数进行自适应优化, 以提升分类性能与模型的泛化能力, 但诊断精度仍有待提高。为进一步提升诊断精度, 文献[5]引入了秃鹰搜索算法 (Bald Eagle Search, BES) 对 SVM 的核函数参数进行优化。实验结果表明, 该模型在诊断精度方面取得了显著进步, 然而在鲁棒性评估中, 该模型表现出一定的局限性。

为了解决上述问题, 本文提出了一种融合卷积神经网络 (CNN) 与支持向量机 (SVM) 的变压器故障诊断方法。该模型结合了 CNN 在自动特征提取方面的优势与 SVM 在小样本条件下良好的分类性能, 从而在故障诊断准确性与鲁棒性方面表现出更优的性能。

1 基于 LMD 分解的振动信号降噪方法

1.1 LMD 分解理论

局部均值分解 (Local Mean Decomposition, 简称 LMD) 是一种自适应的时频分析方法。相较于经验模态分解 (Empirical Mode Decomposition, EMD), LMD 在缓解端点效应、抑制虚假成分的产生以及改善过包络与欠包络现象等方面表现的更为优越, 因此在非平稳信号分析中具有较高的应用价值。LMD 的基本原理是依据信号自身的特征进行自适应分解, 产生具有真实物理意义的乘积函数分量, 其具体过程在文献

[6] 中有详细介绍。振动信号 $X(t)$ 最终被分解为若干个 PF 分量以及差值信号 $u_1(t)$ ，具体公式如式 1 所示：

$$X(t) = \sum_{p=1}^K \delta_{PF}(t) + u_K(t) \quad (1)$$

为了实现故障状态的精准识别，特别是从差异较

小的信号中有效提取故障特征，本文采用了局部均值分解（LMD）方法对振动信号进行细致的分解处理。以绕组变形状态下的振动信号为例，经过 LMD 分解后，得到了如图 1 所示的 PF 分量波形图。




图 1 振动信号经 LMD 分解后的结果

1.2 振动信号有效特征提取

在变压器振动信号的分解过程中，本研究得到了若干具有不同特征尺度的 PF 分量。然而，鉴于这些分量中不可避免地夹杂着噪声信号，为实现噪声的有效排除并最大限度地保留真实信号的完整性，本研究引入了模糊熵值计算。通过精确计算各 PF 分量的模糊熵值，得以量化其内在的复杂度和不确定性^[7]，如图 2 所示，为各种故障状态下 PF 分量的模糊熵值。




图 2 振动信号 PF 分量熵值

如图 2 所示，在所选取的振动信号分解过程中，前 4 个 PF 分量的模糊熵值均显著超过 0.4，而其后各 PF 分量的熵值则普遍低于 0.3。这一显著的熵值差异揭示了不同 PF 分量在信息承载量上的本质区别，前

4 个 PF 分量显然承载了信号中的主要信息^[8]，而后续 PF 分量对于真实信号的信息贡献则相对有限。因此，本研究将 0.4 设定为模糊熵的阈值，将熵值高于 0.4 的分量合成为有效分量。

2 DCGAN 扩充数据集

鉴于实际应用场景中变压器故障样本的稀缺性以及不同故障类型样本数量的显著不均衡性，传统诊断模型在训练过程中往往因样本不足而陷入过拟合困境，进而导致诊断误诊率居高不下^[9]。为有效缓解这一问题，本文引入深度卷积生成对抗网络（DCGAN）对数据集进行对抗性生成。通过该策略，旨在在小样本条件下显著提升诊断模型的诊断准确率，为变压器故障诊断领域提供一种新的解决方案。

DCGAN，即深度卷积生成对抗网络（Deep Convolutional Generative Adversarial Network），是一种利用深度卷积神经网络构建的生成对抗网络（GAN），主要由两部分组成：生成器 G 与判别器 D。

通过随机梯度下降法更新 G 与 D 的参数后得到的结果如图 3 所示。

由图可知， L_D 值与 L_G 值已经足够小^[10]，此时 DCGAN 训练完成，可视判别器已经无法区分生成器生成数据的真假，故生成器所生成的数据可以用于变压器故障诊断的数据集。




图3 DCGAN 训练过程

3 CNN-SVM 模型训练

3.1 CNN 模型

卷积神经网络 (CNN) 是一种常见的深度学习模型,其基本结构包括输入层、卷积层、池化层、全连接层和输出层,各层协同作用以实现对输入数据的多层次特征提取与表示。CNN 结构图如图 4 所示。




图4 CNN 结构图

卷积神经网络首先通过输入层接收原始信号,然后通过卷积层利用卷积核提取局部特征,接着通过池化层减少特征维度,同时保留关键信息。在输入全连接层将特征展平并映射到高维空间^[11],最后通过输出层输出特征向量供 SVM 使用。

卷积层是卷积神经网络 (CNN) 的核心部分,通过局部感知和权重共享的卷积操作提取输入数据的特征,进而有效支持网络的特征学习和参数训练。该过程可用式 (2) 表示:

$$x_j^i = f\left(\sum_{l \in M_j} X_l^{i-1}\right) \cdot W_{ij}^T + B_j^i \quad (2)$$

式中, W 为权值; f 为非线性激活函数; l 为网络的位置层; j 为卷积的位置; B 为偏置。

池化层是卷积神经网络 (CNN) 中的另一关键组成部分,其主要功能在于对卷积层提取的特征图进行采样,从而降低特征维度、减少计算复杂度并增强模

型的平移不变性。本文选用最大池化作为池化策略,其数学表达形式如下所示:

$$p^l = \max_{(j=1) \leq W < i < jw} \{a^l\} \quad (3)$$

式中, a^l 为卷积层的输出结果; p^l 为池化层的输出结果。

在 CNN 架构中, softmax 函数常被用作分类器,它能够将神经网络的输出转换为概率形式,这一过程对于 CNN 的权值更新至关重要。然而, softmax 分类器也存在一些局限性,比如计算复杂度较高、易受数值稳定性问题影响,以及在某些情况下可能出现的非线性问题和性能不佳的情况^[12]。

3.2 SVM 模型

支持向量机 (SVM) 是一种经典且广泛应用于样本分类任务的监督学习算法,具有良好的泛化能力与理论基础。SVM 的基本理念是寻找一个能够准确划分数据集且具有最大几何间隔的分离超平面^[13]。

经预处理后的特征数据被输入至 SVM 模型中以实现故障诊断,采用如下的数学模型:

$$\begin{cases} \min \left\{ \frac{\|\omega\|^2}{2} + C \sum_{i=1}^N (\xi_i) \right\} \\ m_i (\omega \cdot l_i - b) \geq 1 - \xi_i, \xi_i \geq 0, i = 1, 2, N \end{cases} \quad (4)$$

式中, ω 为最优平面法向量; C 为惩罚因子; ξ_i 为松弛因子; m_i 为第 i 个样本的类别; l_i 为第 i 个输入样本特征向量; b 为分类阈值。

本文采用高斯径向基函数 (RBF) 作为核函数以构建支持向量机的决策函数 $f(l)$ 如式 (5) 所示:

$$f(l) = \text{sgn} \left[\sum_{i=1}^n \alpha_i^* \exp \left(\frac{-1}{\gamma^2} \|l_i - l\|^2 \right) + \beta^* \right] \quad (5)$$

式中, sgn 为符号函数; α_i^* 为权重系数; $\exp$ 为以 e 为底的指数函数; l 为待测样本特征向量; γ 为决策函数 $f(l)$ 的参数; β^* 为最优阈值。

3.3 模型搭建

鉴于支持向量机 (SVM) 在处理非线性分类问题中表现出较强的泛化能力与优越的判别性能,本文选用 SVM 替代传统的 softmax 分类器,以提升模型的分类精度与鲁棒性。

CNN 先通过输入层输入原始信号,通过卷积层使用卷积核提取局部特征,进入池化层降低特征维度,保留重要信息,在输入全连接层将特征展平并映射到高维空间,最后通过输出层输出特征向量供 SVM 使用。如图 5 所示,为具体的诊断过程。




图5 模型诊断过程

3.4 评价指标

基于混淆矩阵分类,本文引入查全率(precision)、查准率(recall)、误报率(FNR)、漏报率(FPR)、Kappa系数作为变压器故障诊断综合评价指标^[14]。

$$p_{\text{recision}} = \frac{T_p}{T_p + F_N} \tag{6}$$

$$r_{\text{ecall}} = \frac{T_p}{T_p + F_p} \tag{7}$$

$$F_{\text{NR}} = \frac{F_N}{T_R + F_N} = 1 - p_{\text{recision}} \tag{8}$$

$$F_{\text{PR}} = \frac{F_p}{T_p + F_p} = 1 - r_{\text{ecall}} \tag{9}$$

Kappa 系数公式如下:

$$k = \frac{P_0 - P_e}{1 - P_e} \tag{10}$$

4 算例分析

4.1 样本数据分布

本文共收集某供电公司变压器故障样本 225 例,其中样本的类别、数量、占比和对应标签见表 1。其中绕组松动和铁芯变形仅占总样本数的 14. 22% 和 10. 67%, 体现了样本的不均衡性。

表 1 类别标签及样本分布

状态类型	样本数量	占比	类别标签
正常状态	103	45. 78%	1
绕组松动	66	29. 33%	2
绕组变形	32	14. 22%	3
铁芯变形	24	10. 67%	4

4.2 数据平衡处理

DCGAN 模型的参数见表 2,生成器与判别器均采用学习率为 0. 0003 的 Adam 优化器,其中 Betas 参数设定为 (0. 1, 0. 999),损失函数选用 Binary-crossentropy。

表 2 DCGAN 结构参数

模型	网络层	操作	激活函数
生成器	Input (1, 100)		
	T-Conv2d (100, 512)	BN	ReLU
	T-Conv2d (512, 256)	BN	ReLU
	T-Conv2d (256, 128)	BN	ReLU
	T-Conv2d (128, 64)	BN	ReLU
判别器	T-Conv2d (64, 3)	BN	ReLU
	T-Conv2d (3, 64)		LeakyReLU
	T-Conv2d (64, 128)	BN	LeakyReLU
	T-Conv2d (128, 256)	BN	LeakyReLU
	T-Conv2d (256, 512)	BN	LeakyReLU
	T-Conv2d (512, 1)	Sigmoid	

在数据类别不平衡的情况下,模型的诊断结果往往更偏向于样本数量较多的类别,导致对样本较少类别的召回率下降。为缓解这一问题,本文引入 DCGAN 以生成更加平衡的样本分布。数据增强前后各类样本数量的对比情况见表 3。

表 3 生成前后样本数量对比

状态类型	处理前	处理后
正常状态	103	202
绕组松动	66	199
绕组变形	32	200
铁芯变形	24	199

4.3 模型诊断结果

根据变压器常见的故障特征本次实验共采集及生成 800 份数据,其中训练集、测试集、验证集按照 6: 2: 2 的比例分配,具体分配情况见表 4。

表 4 生成后分配情况

运行状态	样本总数	训练集样本数	测试集样本数	验证集样本数
正常	199	121	39	39
绕组松动	200	120	40	40
绕组变形	199	121	39	39
铁芯变形	202	122	40	40

通过多轮实验与参数调优,最终确定了 CNN-SVM 模型的最优参数配置,具体见表 5。

表 5 CNN-SCM 模型参数设置

参数名称	参数选择
学习率	0.01
批量大小	20
最大训练次数	60
激活函数	ReLU
池化方式	maxpooling
卷积核大小	4
卷积核数量	64
卷积核步长	1
优化器	Adam
Kernel	RBF
惩罚因子	100
核函数参数	0.01

最后,将测试集数据输入至该模型中,得到的混淆矩阵见图 6。




图 6 故障分类混淆矩阵




图 7 不同诊断模型结果对比图

表 7 模型评价指标对比

诊断模型	CNN-SVM	3D-CNN	GWO-SVM	CNN-BiGRU
Kappa 系数	0.9663	0.9662	0.8907	0.8813
诊断准确率	97.5%	93.0%	91.8%	91.1%

根据混淆矩阵中的数据,计算得到评估指标中各个系数的值,具体结果如表 6 所示。

表 6 评价指标

故障类型	评价指标					
	查全率	查准率	误报率	漏报率	Kappa 系数	准确率
正常	94.7%	95.1%	5.3%	4.7%	0.9663	97.5%
绕组松动	94.7%	95.1%	5.3%	4.7%		
绕组变形	100%	100%	0%	0%		
铁芯变形	97.5%	100%	2.5%	0%		

由表中结果可知,在测试集共 158 个样本中,模型成功识别了其中的 154 个,整体诊断准确率达到 97.5%。其中,对于绕组变形故障的识别,模型实现了 100% 的准确率。此外,所构建模型的 Kappa 系数为 0.9663,进一步印证了其在故障识别任务中所具备的较高鲁棒性与准确性。

4.4 不同诊断模型对比分析

为评估 CNN-SVM 模型在故障分类识别中的性能表现,将生成的样本特征分别输入至文献 [15] 所提出的 3D-CNN 模型、文献 [16] 的 GWO-SVM 模型及文献 [17] 的 CNN-BiGRU 模型中进行对比实验,相关诊断结果如图 7 所示,对应的性能指标对比见表 7。实验结果显示,在相同输入特征条件下,CNN-SVM 模型在诊断准确率方面优于其余三种对比模型。此外,从 Kappa 系数角度分析,本文所提出的方法在准确性与稳定性方面均展现出更优的性能,进一步验证了所构建特征提取策略与故障诊断模型的有效性 with 适用性。

5 结束语

- (1) 本文采用的 DCGAN 小样本过采样方法有效解决了变压器故障诊断中由于样本不平衡所导致的诊断准确率较低的问题,从而提升了模型的分类性能。
- (2) 与其他诊断模型相比,本文所提的 CNN-

SVM 模型实现了 97.5% 的准确率和 0.9663 的 Kappa 系数,表明该模型在故障诊断中表现出更优的分类性能与更高的准确性。

参考文献

- [1] 梁栋,朱建华,张翠,等. 变压器状态评估及故障诊断研究综述 [J]. 变压器, 2024, 61 (2): 35-43.
- [2] 谢庆,张煜宇,王春鑫,等. 新一代人工智能技术在输变电设备状态评估中的应用现状及展望 [J]. 高压电器, 2022, 58 (11): 1-16.
- [3] 李浩,魏繁荣,王浩,等. 基于振动信号与深度学习的电力变压器故障诊断方法 [J]. 电工电能新技术, 2024, 43 (10): 1-12.
- [4] 颜锦,马宏忠,朱昊,等. 基于 LMD 边际谱能量熵与 FWA-SVM 的变压器绕组松动诊断 [J]. 电测与仪表, 2021, 58 (11): 74-80.
- [5] 段洁,伍瑞泽,尤敬尧,等. 基于改进秃鹰算法优化 LSSVM 的变压器故障诊断 [J]. 红水河, 2024, 3 (1): 96-101.
- [6] 吴为,曾德辉,聂欣昊,等. 基于局部均值分解和归一化最小均方的宽频振荡检测方法 [J]. 电力系统及其自动化学报, 2024, 36 (3): 48-58.
- [7] 肖俊青,金江涛,李春,等. 基于 CEEMDAN 模糊熵 CNN 轴承故障诊断研究 [J]. 机械强度, 2023, 45 (1): 2633.
- [8] 陈剑,蔡坤奇,陶善勇,等. 基于 IITD 模糊熵与随机森林的滚动轴承故障诊断方法 [J]. 计量学报, 2021, 42 (6): 774-779.
- [9] 段嘉珺,吴晓欣,何怡刚,等. 虚实特征融合与数据-机理驱动的变压器绕组小样本故障诊断 [J]. 电力自动化设备, 2024, 44 (9): 212-218.
- [10] 廖珂,荆晓远,李双远,等. 基于 SC-DCGAN 的不平衡数据轴承故障诊断 [J]. 机床与液压, 2024, 52 (24): 208-213.
- [11] 吉兴全,陈金硕,张玉敏,等. 基于 CNN-SVM 的配电网故障分类研究 [J]. 智慧电力, 2022, 50 (1): 94-100.
- [12] 李浩,魏繁荣,王浩,等. 基于振动信号与深度学习的电力变压器故障诊断方法 [J]. 电工电能新技术, 2024, 43 (10): 1-12.
- [13] 邱海枫,苏宁,田松林. 改进支持向量机在电力变压器故障诊断中的应用研究 [J]. 电测与仪表, 2022, 59 (11): 48-53.
- [14] 汪李忠,池建飞,丁叶强,等. 基于 NNTR-SMOTE 与 GA-XGBoost 的变压器故障诊断方法研究 [J]. 综合智慧能源, 2024, 46 (1): 84-93.
- [15] 崔佳嘉,马宏忠. 基于改进 MFCC 和 3D-CNN 的变压器铁心松动故障声纹识别模型 [J]. 电机与控制学报, 2022, 26 (12): 150-160.
- [16] 陈朝阳,杨文荣,张雨蒙,等. 变压器长圆形绕组振动仿真与机械故障诊断研究 [J]. 传感器与微系统, 2024, 43 (3): 63-66, 75.
- [17] 李浩,魏繁荣,王浩,等. 基于振动信号与深度学习的电力变压器故障诊断方法 [J]. 电工电能新技术, 2024, 43 (10): 1-12.

(收稿日期:2025-05-11)

(上接第 375 页)

参考文献

- [1] 原帅,肖嘉安,陶军,等. 全功率型风电机组故障穿越全过程的短路电流解析方法 [J]. 电力建设, 2025, 46 (3): 85-94.
- [2] 刘思佳,刘海涛,张隽,等. 基于等效阻抗的虚拟同步机电压支撑影响因素分析与改进控制策略研究 [J]. 电工技术学报, 2025, 40 (9): 2738-2751.
- [3] 于琳琳,蒋小亮,贾鹏,等. 基于改进卷积神经网络的新能源并网短路电流预测技术 [J]. 可再生能源, 2025, 43 (3): 408-415.
- [4] 赵舒心,肖仕武,梁伟宸. 基于聚合电流的高比例分布式电源接入配电网短路故障计算与分析 [J]. 电力系统保护与控制, 2025, 53 (7): 16-26.
- [5] 金思淑,张宏鹏,胡晓晨,等. 基于 apFFT 的双馈风电场送出变压器差动保护方法 [J]. 高电压技术, 2025, 51 (4): 1560-1568.
- [6] 吴科成,吴亚雄,陈卓. 考虑安全效能成本的短路电流抑制措施综合优化配置方法研究 [J]. 高压电器, 2025, 61 (5): 279-290.

(收稿日期:2025-05-26)