

表 2 变量表

一级指标	二级指标	对应变量名称
借贷人信息	信用评分	Credit_Score
	债务收入比	Original_Debt_To_Income_DTI_Ratio
	借款人人数	Number_of_Borrowers
	按揭保险比例	Mortgage_Insurance_Percentage
	合并贷款价值比	Original_Combined_Loan_To_Value_CLTV
贷款合约信息	首贷贷款价值比	Original_Loan_To_Value_LTV
	贷款目的	Loan_Purpose
	首次购房者标识	First_Time_Homebuyer_Flag
房产属性	房屋单元数	Number_of_Units
	入住状态	Occupancy_Status
	房产类型	Property_Type
贷款渠道	贷款申办的业务来源路径	Channel
地理位置	房产所在州	Property_State

2.数据预处理

在进行数据均衡及建模之前，本研究将进行对获取的数据集进行数据清洗与预处理工作，预处理过程包括缺失值处理、样本筛选与编码、违约速度标签构建以及特征筛选有效性验证四个步骤。

2.1 缺失值处理

在原始数据集中，由于缺失数据并未采用常规空值表征缺失，而是以特定异常数值作为缺失标识，该类缺失具备明确业务属性，因此本文将上述异常编码统一替换为 0。从业务内涵来看，按揭保险字段标记缺失代表贷款未购置按揭保险；贷款价值比缺失说明不存在次级抵押贷款；债务收入比缺失代表该项信息未统计；房产单元数缺失则判定为场景不适用，0 值能够直观对应上述实际业务含义。

鉴于该类异常编码承载固定业务意义，并非数据记录失误导致的随机缺失。若采用均值、中位数插值等其他插值方式填充，会人为生成不存在的信贷指标，篡改样本真实贷款属性，破坏原始数据结构。为留存数据真实信息、避免引入虚假经济特征，本文采用 0 值填充方式，最大程度还原业务原貌。

对于 Loan_Purpose、First_Time_Homebuyer_Flag 等分类变量，数据内空值与数值 9 缺失标识不作预处理赋值，在后续编码过程中单独划分缺失专属类别，完整保留缺失蕴含的信息特征。

2.2 样本编码与筛选

由于原始数据集中，部分数据如入住状态、贷款目的均为分类文字特征，因此本文采用 One-Hot 编码，进行离散特征的数字化处理，将每一个类别单独生成一列二进制特征，属于该类别的样本标记为 1，其余标记为 0。经编码后，数据集最终扩展为包含 78 个变量的建模样本集，其中 71 个变量为分类变量的独热编码列。

但 71 个的 One-Hot 列的高维结构，对于 GAN 生成器训练来说有较大的挑战：生成器的输出层维数等于特征维数，高维输出显著增加梯度惩罚的估计方差和模式坍塌的风险；同时同一组 One-Hot 列在真实数据中始终满足“有且仅有一列为 1，其余为零”的互斥约束，而连续值输出的生成器，无法天然习得该离散约束，易生成无效的“多列同时为 1”或“全部为 0”的非可行样本。为在不实质性损失地理与类别信息的前提下将特征维数压缩至生成器可学习的范围，本文采用信用评分领域的标准做法——证据权重编码，将高基数分类变量替换为单列连续值。

WOE 的计算公式为：

$$WOE_i = \ln \left(\frac{\text{Dist_Good}_i}{\text{Dist_Bad}_i} \right),$$

其中 Dist_Good_i 与 Dist_Bad_i 分别为第 i 个类别中正常样本与违约样本占全体正常样本和全体违约样本的比例。为提升小类别的估计稳健性，逐类别的分子和分母均施加拉普拉斯平滑。最终各分类变量的 WOE 编码结果如图 2。

WOE编码结果




图 2 WOE 编码结果

经上述 WOE 编码与压缩操作，54 列州 One-Hot 归并为 1 列，14 列非州 One-Hot 列归并为 4 列 WOE 变量与 1 列二值变量。全部预测变量从 78 个降至 13 个，且均为连续型或二值型，生成器输出维度的骤降为后续条件生成网络的稳定训练提供了低维、信息密集的输入空间。

同时为验证 WOE 编码压缩是否会造成预测信息的实质性损失，本文在原 78 维和压缩后 13 维特征上分别训练 XGBoost 分类器（超参数保持一致），并在相同的 80/20 分层划分上进行验证。在三个不同随机种子（42、123、2024）下的分层验证中，78 维特征和 13 维特征的 AUC 如图 3 所示。




图 3 WOE 编码压缩前后分类模型的 AUC 对比图

由图可知，两者的平均差异不足 0.0002，属于随机波动范围，不存在统计显著差异，该结果可以证明 13 维特征集在降维的前提下完整保留了 78 维原始特征的区分能力，可以用于后续的模式训练与预测。

2.3 违约速度标签构建

由于 2023 年 Q4 至 2025 年 Q2 期间的贷款数据观测时间不满足 24 个月的时长，按传统做法应直接删除这部分数据，但在其中已有 8150 条样本已违约，这部分数据全部在发放后 23 个月内触发违约属于“快速恶化”型高风险样本。传统处理将其丢弃的做法，会造成信息损失，让这些样本所携带的“快速违约特征模式”未被利用。

因此本文将这 8150 笔右删失违约样本单独保留，不作为训练样本直接参与模型拟合。为从中提取违约模式信息，本文首先在 2022 年第一季度至 2023 年第三季度 34077 笔完整观测违约贷款上构建违约速度标签（speed_labe），将首次违约时间不超过 12 个月的贷款标记为 Early Default，speed_labe 标签值取 1；首次违约时间在 13-24 个月之间的贷款的标记为 Late Default，speed_labe 标签值取 0。统计结果表明，Early Default 共 13901 笔（占 40.8%），Late Default 共 20176

笔（占 59.2%），两类比例约为 1:1.45。

本文将以这一标签为训练目标，将全部 13 个预测变量作为输入变量，训练违约速度分类器（speed_clf），学习区分快速恶化与缓慢恶化两类违约模式的特征组合。训练完成后，speed_clf 对前述 8150 笔右删失违约样本进行推断，输出违约倾向得分 r ，即给定静态特征下该笔贷款属于快速违约模式的后验概率，以此作为后续条件 GAN 生成器的引导信号。

3.BA-cWGAN-GP 预实验

为验证本文所构建边界感知条件生成对抗网络（BA-cWGAN-GP）算法的可行性与稳定性，确认四阶段核心技术链路可端到端落地运行，规避后续正式实验出现算法适配、训练崩溃、机制失效等问题，在本阶段本文基于预处理完成的数据集开展完整预实验，同步设置多组基线模型对照，系统性验证模型各模块有效性，明确当前模型优势与现存瓶颈，为后续正式实验优化、参数调优、消融实验设计提供依据。

3.1 预实验整体方案与设置

本次预实验核心目标为验证 BA-cWGAN-GP 四大核心环节的可行性：

（1）违约速度分类器与 NN 代理模型可有效输出条件变量 r ；（2）XGBoost 基分类器知识蒸馏可实现决策边界可微分迁移；（3）多损失联合约束下的 BA-cWGAN-GP 可稳定训练收敛；（4）模型生成样本具备边界聚焦优势且可通过裁判模型完成有效性评估。

数据集层面，划分 GAN 训练集与验证集，其中训练集样本量 819790 条，违约样本 35411 条；验证集样本量 202911 条，违约样本 6816 条。其中可构建违约速度标签的完整观测违约样本 27261 条，待推断条件信号的右删失违约样本 8150 条。

对照方法设置四类主流不平衡数据处理模型：原始数据无采样模型、SMOTE 过采样、标准 WGAN-GP 生成模型与本文的 BA-cWGAN-GP 模型，模型超参数统一固化，设置标准见表 3。

表 3 参数设置表

参数		参数设置	
生成器	101→256→512→256→13 层级结构	迭代轮次	200
判别器	13→256→512→256→1 层级结构	梯度惩罚系数	10
噪声	100	边界损失权重	0.1
批次	256	一致性损失权重	0.05
基础学习率	1e-4	判别器迭代频率	5 次/轮

3.2 分阶段预实验结果与分析

3.2.1 第一阶段：违约速度分类器与 NN 代理模型验证

本阶段依托 27261 条完整观测违约样本训练违约速度分类器，区分快速违约与慢速违约特征模式，同时训练神经网络代理模型，实现条件变量 r 的可微分拟合，为生成器提供稳定的条件约束信号，实验结果如图 4 所示。




图 4 违约倾向得分 r 的分布图

由图可以看出模型训练样本类别均衡，输出的违约倾向得分 r 分布稳定，均值为 0.406，标准差 0.074，取值区间为 $[0.08, 0.95]$ ，风险区分度适中。NN 代理模型经 200 轮迭代稳定收敛，最终损失值为 0.668，代理模型与真实违约速度相关系数达 0.822，MAE 误差仅为 0.031，满足大于 0.8 的有效代理标准。

本阶段实验证实，违约速度分类器可精准挖掘信贷样本的违约快慢特征差异，NN 代理模型拟合精度高、误差可控，能够稳定输出可微分的条件变量 r ，彻底解决了右删失样本隐性风险特征无法量化、无法嵌入生成模型训练的问题，第一阶段核心技术链路完全跑通。

3.2.2 第二阶段：XGBoost 基分类器知识蒸馏验证

本阶段以 XGBoost 为基分类器构建信贷风险决策边界，通过知识蒸馏将离散的树模型决策逻辑迁移至神经网络代理模型，实现决策边界的可微分处理，为边界感知损失提供计算支撑，结果如图 5 所示。




图 5 边界判断混淆矩阵图

预实验结果表明，XGBoost 基分类器验证集 AUC 为 0.7354，整体判别精度偏低，样本决策边界较为弥散，距离阈值小于 0.2 的边界附近样本占比达 37.0%。经 300 轮迭代训练后，蒸馏后的 NN 代理模型损失收敛至 0.533，拟合效果稳定。

关键指标层面，蒸馏后 NN 代理模型与 XGBoost 基分类器的输出相关系数高达 0.983，边界判断一致性达到 94.1%，几乎完美复刻了基分类器的风险决策逻辑与边界划分标准，成功实现了传统树模型决策边界的可微分迁移，解决了传统边界约束无法嵌入 GAN 训练的技术痛点，第二阶段技术链路完全可行。同时实验也明确，基分类器 AUC 偏低是后续模型整体性能受限的核心前置问题，并非算法设计缺陷。

3.2.3 第三阶段：生成模型训练稳定性验证

本阶段分别对标准 WGAN-GP 与 BA-cWGAN-GP 模型开展训练，对比两类模型的收敛特性、训练效率与损失优化规律，训练结果如图 6 所示。




图 6 WGAN-GP 和 BA-cWGAN-GP 的训练损失曲线图

由图可知，基线 WGAN-GP 模型训练在经历 200 轮迭代后生成器损失持续下降至-2.41，模型持续学习真实样本分布，但 WGAN-GP 模型仅优化了对抗损失，生成器缺乏对决策边界信息的感知，生成的样本缺乏边界聚焦能力的问题。

但本文提出的 BA-cWGAN-GP 模型融合对抗损失、边界损失与 r 一致性损失三项约束，在训练迭代收敛后，边界损失稳定维持在-0.17，边界损失在训练全程保持稳定，未出现退化或发散，证明生成器持续被精准引导至信贷风险决策边界区域；违约速度一致性损失稳定在 0.080，说明生成样本的违约风险倾向与目标约束偏差仅 8%，条件生成约束有效；对抗损失收敛至-0.98，相较于基线模型更为温和合理，不存在过度拟合与模式崩溃问题。

整体来看，三项损失函数同步稳定收敛、无相互冲突、无梯度爆炸与模式坍塌问题，多损失联合优化机制适配性良好，模型训练稳定性得到充分验证。

3.2.4 第四阶段：样本生成质量与模型性能评估

本阶段通过边界富集度与裁判模型双维度，量化评估合成样本质量与模型预测性能，结果如图 7 所示。在样本边界富集度层面，标准 WGAN-GP 生成的违

约样本仅 33.2%落在决策边界区间，存在大量无效、同质化样本；而 BA-cWGAN-GP 生成的合成样本边界富集度提升至 59.2%，充分验证了边界感知机制的核心优势，从根源上解决了传统生成模型盲目采样、无效生成的缺陷。




图 7 三种来源样本的边界富集度柱状图

同时由图 8 可以看出，相较于原始数据、SMOTE 过采样、标准 WGAN-GP 模型，BA-cWGAN-GP 模型的 Brier 分数降至 0.0623，预测误差显著降低。




图 8 不同数据生成模型 Brier 对比图

此外受限于基分类器判别精度偏低、决策边界弥散、CPU 迭代次数不足等客观因素，模型 AUC 与 F1 分数提升幅度有限，但该结果为实验条件受限导致，可通过后续优化彻底改善。

3.3 预实验核心结论与现存瓶颈

综合四阶段预实验结果，可明确 BA-cWGAN-GP 模型整体技术链路完全可

行，条件生成机制、边界感知损失约束、知识蒸馏迁移、多损失联合优化四大核心创新点均有效落地，模型训练稳定、样本生成质量远超传统算法，完全适配信贷不平衡数据增强场景。

同时预实验厘清了模型性能未充分释放的核心因果逻辑：13 维 WOE 降维特征存在信息损耗，导致基分类器判别精度偏低、决策边界模糊宽泛，使得边界聚焦生成的核心优势被稀释，叠加 CPU 训练迭代次数不足、预测阈值未优化等问题，最终造成模型整体性能提升幅度有限。

基于预实验暴露的问题，本研究已形成完整的优化方案：后续将通过全量数据训练、XGBoost 超参调优提升基分类器判别精度，复用原始高维特征弥补 WOE 编码信息损失，基于 GPU 提升迭代轮次实现模型充分收敛，同时设计多组消融实验量化各模块贡献。

预实验充分证实本算法具备显著的优化潜力与研究价值，为后续正式实证研究、跨周期模型验证、可解释性分析筑牢了技术与实验基础。

一、论文写作进度时间安排

1.第一阶段（5-6 月）：进行文献收集和阅读，完成文献综述和理论基础部分的撰写。同时收集、处理数据，完成实证分析的前置性基础工作。

2.第二阶段（7-11 月）：进行实证研究设计，展开具体实验研究，完成实证分析和案例分析部分的撰写。

3.第三阶段（11-12 月）：提出解决方案和对策，完成解决方案部分的撰写，并对全文进行初步修改和完善。

4.第四阶段（12-次年 3 月）：进行论文的定稿和提交工作，准备答辩和展示。